


# 相关基础知识回顾与补充

---



# 概率论

---



# 随机试验、样本点与样本空间,

---

如果一个试验，具有下列特点：

- (1) 试验可以在相同的条件下重复进行；
- (2) 每次试验的结果可能不止一个，并且能够事先明确所有的可能结果；
- (3) 进行试验之前不能确定哪一个结果将会出现.

这样的试验称为**随机试验**，简称**试验**，E. 随机试验中的每一个可能结果称为一个样本点，记为  $\omega$ ；全体样本点所构成的集合称为**样本空间**，记为  $\Omega$ 。

**Definition 3.1.1. 【随机事件】** 随机试验  $E$  的样本空间  $\Omega$  的子集称为随机事件, 简称事件. 常用大写字母  $A, B, C$  等表示. 事件  $A$  发生, 是指在试验中当且仅当集合  $A$  中所包含的样本点出现, 否则称  $A$  不发生.

特别地, 由一个样本点组成的单点集称为基本事件. 在每次试验中必然发生的事件, 称为必然事件. 由于样本空间  $\Omega$  包含所有的样本点, 在每次试验中  $\Omega$  的样本点总是会出现, 故  $\Omega$  是必然事件. 在每次试验中必然不发生的事件, 称为不可能事件. 由于空集  $\emptyset$  不含任何样本点, 故  $\emptyset$  是不可能事件.

**Definition 3.1.2. 【 $\sigma$ -代数】** 设  $\mathcal{F}$  为空间  $\Omega$  的 子集构成的集合，满足

(1)  $\Omega \in \mathcal{F}$ ;

(2) 若  $A \in \mathcal{F}$ , 则  $\bar{A} \in \mathcal{F}$ ;

(3) 若  $A_n \in \mathcal{F}, n = 1, 2, \dots$ , 则  $\bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$ .

那么称  $\mathcal{F}$  为  $\sigma$ -代数, 也成为  $\sigma$ -域.

$\sigma$ -代数具有如下性质:

(1)  $\emptyset \in \mathcal{F}$ ;

(2) 若  $A_n \in \mathcal{F}, n = 1, 2, \dots$ , 则  $\bigcap_{n=1}^{\infty} A_n \in \mathcal{F}$ ;

(3) 若  $A_n \in \mathcal{F}, n = 1, 2, \dots$ , 则  $\bigcup_{n=1}^k A_n \in \mathcal{F}, \bigcap_{n=1}^k A_n \in \mathcal{F}$ ;

(4) 若  $A_n \in \mathcal{F}, n = 1, 2, \dots$ , 则  $\overline{\lim_{n \rightarrow \infty}} A_n \in \mathcal{F}, \underline{\lim_{n \rightarrow \infty}} A_n \in \mathcal{F}$ .

**Definition 3.1.3. 【事件域】** 设  $\Omega$  是样本空间,  $\mathcal{F}$  是由样本空间  $\Omega$  的一些子集构成的一个  $\sigma$ -代数, 则称  $\mathcal{F}$  为事件域.  $\mathcal{F}$  中的元素称为事件,  $\Omega$  称为必然事件,  $\emptyset$  称为不可能事件.

**Definition 3.1.4. 【概率】** 设  $P(A)$  是定义在事件域  $\mathcal{F}$  上的 实值集合函数，如果满足

(1) 非负性：对任一  $A \in \mathcal{F}$ ,  $P(A) \geq 0$ ;

(2) 规范性：对必然事件  $\Omega$ ,  $P(\Omega) = 1$ ;

(3) 可列可加性：设  $A_1, A_2, \dots$  是两两互不相容事件序列, 即对于  $i \neq j$ ,  $A_i A_j = \emptyset (i, j = 1, 2, \dots)$ , 则有

$$P\left(\bigcup_{k=1}^{\infty} A_k\right) = \sum_{k=1}^{\infty} P(A_k).$$

那么称  $P(A)$  为事件域  $\mathcal{F}$  上事件  $A$  的概率.



# 概率空间

一般称三元组  $(\Omega, \mathcal{F}, P)$  为概率空间, 其中  $\Omega$  是样本空间,  $\mathcal{F}$  是事件域,  $P$  是概率. 可以容易验证概率的如下性质:

(1)  $P(\emptyset) = 0, P(\Omega) = 1.$

(2) 对  $n$  个两两互不相容事件  $A_1, A_2, \dots, A_n$ , 有  $P\left(\bigcup_{k=1}^n A_k\right) = \sum_{k=1}^n P(A_k).$

(3) 对于任一事件  $A$ , 有  $P(\bar{A}) = 1 - P(A).$

(4) 对于任意两个事件  $A$ 、 $B$ , 有  $P(A - B) = P(A) - P(AB).$  特别地, 当  $B \subset A$  时, 有  $P(AB) = P(A) - P(B)$ , 且  $P(A) \geq P(B).$

(5) 对于任意两个事件  $A$ 、 $B$ , 有  $P(A \cup B) = P(A) + P(B) - P(AB).$

**Definition 3.1.5. 【条件概率】** 设  $A$ 、 $B$  是两个事件, 且  $P(A) > 0$ , 称  $P(B|A) = \frac{P(AB)}{P(A)}$  为在事件  $A$  已经发生的条件下事件  $B$  发生的条件概率.

不难验证, 条件概率  $P(\cdot|A)$  符合上面概率定义的三个条件, 即

(1) 非负性: 对于每一事件  $B$ , 有  $P(B|A) \geq 0$ ;

(2) 规范性: 对于必然事件  $\Omega$ , 有  $P(\Omega|A) = 1$ ;

(3) 可列可加性: 设  $B_1, B_2, \dots$  是两两互不相容的事件, 则有  $P\left(\bigcup_{i=1}^{+\infty} B_i|A\right) = \sum_{i=1}^{\infty} P(B_i|A)$ .

由此可知, 概率的有关性质对于条件概率也都适用. 例如

$$P(\bar{B}|A) = 1 - P(B|A)$$

$$P(B_1 \cup B_2|A) = P(B_1|A) + P(B_2|A) - P(B_1 B_2|A)$$

(3.1)

**Theorem 3.1.1.** 设  $A$ 、 $B$  是两个事件, 且  $P(A) > 0$ , 有

$$P(AB) = P(B|A)P(A)$$

若  $P(B) > 0$ , 则有  $P(AB) = P(A|B)P(B)$ .

**Theorem 3.1.2.** 设  $A_1, A_2, \dots, A_n$  是样本空间  $\Omega$  的一个完备事件组, 且  $P(A_i) > 0 (i = 1, 2, \dots, n)$ . 对于任意事件  $B$ , 有

$$P(B) = \sum_{i=1}^n P(B|A_i) P(A_i) \quad (3.3)$$

**Theorem 3.1.3.** 设  $A_1, A_2, \dots, A_n$  是样本空间  $\Omega$  的一个完备事件组, 且  $P(A_i) > 0 (i = 1, 2, \dots, n)$ . 对于任意事件  $B$ ,  $P(B) > 0$ , 则有

$$P(A_i|B) = \frac{P(B|A_i) P(A_i)}{\sum_{i=1}^n P(B|A_i) P(A_i)} \quad (3.4)$$

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

# 随机变量

---

**Definition 3.1.6. 【随机变量】** 设  $(\Omega, \mathcal{F}, P)$  是一概率空间,  $X(\omega)$  是定义在  $\Omega$  上的单值实函数, 若对任意实数  $x \in R$ , 有

$$\{\omega | X(\omega) \leq x\} \in \mathcal{F} \quad (3.6)$$

则称  $X = X(\omega)$  为随机变量.

**Definition 3.1.7. 【分布函数】** 设  $X = X(\omega)$  是定义在概率空间  $(\Omega, \mathcal{F}, P)$  上的随机变量, 对任意  $x \in R$ , 称

$$F(x) = P\{\omega | X(\omega) \leq x\} \quad (3.7)$$

为随机变量  $\omega$  的分布函数. 简记为  $F(x) = P\{X(\omega) \leq x\}$ ,  $F(x)$  有时也记为  $F_X(x)$ .

对于任意实数  $x_1, x_2$  ( $x_1 < x_2$ ), 有

$$P\{x_1 < X \leq x_2\} = P\{X \leq x_2\} - P\{X \leq x_1\} = F(x_2) - F(x_1)$$

**Theorem 3.1.4.** 分布函数  $F(x)$  具有如下性质:

- (1) 不减性. 若  $\forall x_1 < x_2 \in R$ , 则  $F(x_1) \leq F(x_2)$ ;
- (2) 规范性.  $0 \leq F(x) \leq 1$  且  $F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0$ ,  $F(+\infty) = \lim_{x \rightarrow +\infty} F(x) = 1$ ;
- (3) 右连续性. 对  $\forall x_0 \in R$ , 有  $\lim_{x \rightarrow x_0^+} F(x) = F(x_0)$ .

# 概率密度函数

---

**Definition 3.1.8.** 【概率密度函数】如果对随机变量  $X$  的分布函数  $F(x)$ , 存在非负可积函数  $f(x)$ , 使得对任意的实数  $x$ , 有

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t)dt \quad (3.8)$$

其中  $f(x)$  称为随机变量  $X$  的概率密度函数, 简称概率密度或密度函数.



**Theorem 3.1.5.** 概率密度函数具有如下性质:

(1) 非负性.  $f(x) \geq 0, \forall x \in R$ .

(2) 规范性.  $\int_{-\infty}^{+\infty} f(x)dx = 1$ .

(3) 对任意实数  $x_1, x_2$  ( $x_1 \leq x_2$ ),

$$P\{x_1 < X(\omega) \leq x_2\} = F(x_2) - F(x_1) = \int_{x_1}^{x_2} f(x)dx = P(X(\omega) \leq x_2) - P(X(\omega) \leq x_1)$$

(4) 若  $F(x)$  在  $x$  处是连续的, 则  $F'(x) = f(x)$ .

(5) 若  $X$  是连续型随机变量, 则  $\forall a \in R, P\{\omega | X(\omega) = a\} = 0$ .

设  $X$  为一个随机变量,  $g(x)$  为定义在实数集合  $I$  上的实值函数, 而  $X$  的可能取值  $x \in I$ . 由高等数学中函数的定义知, 函数  $g(x)$  的值由自变量  $x$  确定, 所以当随机变量  $X$  的取值具有随机性时, 函数  $Y = g(X)$  的取值也具有随机性, 即  $Y = g(X)$  也是随机变量. 例如  $Y = X, Y = \ln X, Y = \sin X$  等都是随机变量.

**Theorem 3.1.6.** 设连续随机变量  $X$  的取值范围为  $(a, b)$ , 其密度函数为  $f_x(x)$ . 若函数  $y = g(x)$  在  $(a, b)$  内严格单调, 且其反函数  $x = g^{-1}(y)$  有连续导数, 则  $Y = g(X)$  的密度函数为

$$f_y(y) = \begin{cases} f_x(g^{-1}(y)) \left| (g^{-1}(y))' \right|, & \alpha < y < \beta \\ 0, & \text{其他} \end{cases} \quad (3.10)$$

其中,  $\alpha = \min\{g(a), g(b)\}, \beta = \max\{g(a), g(b)\}$ .

# 特征函数

---

设  $X$  为随机矢量，其特征函数定义为

$$\varphi_{\mathbf{x}}(\boldsymbol{\xi}) = \int_{-\infty}^{+\infty} e^{i\mathbf{x}^T \boldsymbol{\xi}} dF_{\mathbf{x}}(\boldsymbol{\xi})$$

# 随机向量及其分布

---

**Definition 3.1.9. 【随机向量】** 设  $X_1(\omega), X_2(\omega), \dots, X_n(\omega)$  是定义在概率空间  $(\Omega, \mathcal{F}, P)$  上的  $n$  个随机变量, 称  $\mathbf{X}(\omega) = [X_1(\omega), X_2(\omega), \dots, X_n(\omega)]^T$  为  $n$  维随机向量.

$n$  维随机向量取值于  $n$  维欧几里得空间  $R^n$ . 对  $n$  个实数  $x_1, x_2, \dots, x_n, \{X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n\} = \bigcap_{i=1}^n \{X_i \leq x_i\}$  有定义, 并属于  $\mathcal{F}$ .

**Definition 3.1.10. 【随机向量分布函数】**  $n$  元函数  $F(x_1, x_2, \dots, x_n) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n)$  称为  $n$  维随机变量  $\mathbf{X}(\omega) = [X_1(\omega), X_2(\omega), \dots, X_n(\omega)]^T$  的 (联合) 分布函数.

**Definition 3.1.11. 【随机向量概率密度】**若对任意的  $n$  个实数  $x_1, x_2, \cdots, x_n$ , 存在非负实函数  $f(x_1, x_2, \cdots, x_n)$ , 使随机向量  $\mathbf{X}$  的分布函数

$$\begin{aligned} F(\mathbf{x}) &= F(x_1, x_2, \cdots, x_n) \\ &= \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} \cdots \int_{-\infty}^{x_n} f(u_1, u_2, \cdots, u_n) \mathrm{d}u_1 \mathrm{d}u_2 \cdots \mathrm{d}u_n \\ &= \int_{-\infty}^{\mathbf{x}} f(\mathbf{u}) \mathrm{d}\mathbf{u} \end{aligned} \quad (3.11)$$

则称函数  $f(\mathbf{x}) = f(x_1, x_2, \cdots, x_n)$  为随机向量  $\mathbf{X}$  的概率分布密度或概率密度函数.

**Theorem 3.1.7.** 随机向量概率密度  $f(\boldsymbol{x})$  具有如下性质:

(1) 对  $\forall \boldsymbol{x} \in R^n$ ,  $f(\boldsymbol{x}) \geq 0$ ;

(2)  $\int_{-\infty}^{+\infty} f(\boldsymbol{x}) d\boldsymbol{x} = \int \cdots \int_{-\infty}^{+\infty} f(x_1, x_2, \cdots, x_n) dx_1 dx_2 \cdots dx_n = 1$ ;

(3) 若  $F(\boldsymbol{x})$  在  $\boldsymbol{x}$  处连续, 则有

$$\frac{\partial^n F(\boldsymbol{x})}{\partial x_1 \cdots \partial x_n} = f(x_1, \cdots, x_n) = f(\boldsymbol{x})$$

(4) 设  $V$  是  $R^n$  中任一区域, 随机点  $\boldsymbol{x}$  落入区域  $V$  内的概率为

$$P(\boldsymbol{x} \in V) = \int_V f(\boldsymbol{x}) d\boldsymbol{x}.$$

注意, 这里我们用  $d\boldsymbol{x}$  表示  $dx_1 dx_2 \cdots dx_n$ .

**Definition 3.1.12. 【边缘分布】** 设  $n$  维随机向量  $\mathbf{X}$  和  $m$  维随机向量  $\mathbf{Y}$  的联合分布函数为  $F_{XY}(\mathbf{x}, \mathbf{y})$ , 其中  $\mathbf{x} \in R^n, \mathbf{y} \in R^m$ , 那么称

$$\begin{aligned} F_X(\mathbf{x}) &= F_{XY}(\mathbf{x}, +\infty) = P(\mathbf{X} \leq \mathbf{x}, \mathbf{Y} \leq +\infty) \\ &= P(X_1 \leq x_1, \cdots, X_n \leq x_n; Y_1 \leq +\infty, \cdots, Y_m \leq +\infty) \end{aligned} \quad (3.14)$$

为随机向量  $\mathbf{X}$  的边缘分布函数. 称

$$\begin{aligned} F_Y(\mathbf{y}) &= F_{XY}(+\infty, \mathbf{y}) = P(\mathbf{X} \leq +\infty, \mathbf{Y} \leq \mathbf{y}) \\ &= P(X_1 \leq +\infty, \cdots, X_n \leq +\infty; Y_1 \leq y_1, \cdots, Y_m \leq y_m) \end{aligned} \quad (3.15)$$

为随机向量  $\mathbf{Y}$  的边缘分布函数.



**Definition 3.1.13. 【边缘分布密度函数】** 设随机向量  $\mathbf{X}$  和随机向量  $\mathbf{Y}$  的联合分布函数为  $F_{XY}(\mathbf{x}, \mathbf{y})$ , 对应的联合概率密度函数为  $f_{XY}(\mathbf{x}, \mathbf{y})$ , 即

$$F_{XY}(\mathbf{x}, \mathbf{y}) = \int_{-\infty}^{\mathbf{x}} \int_{-\infty}^{\mathbf{y}} f_{XY}(\mathbf{u}, \mathbf{v}) d\mathbf{u} d\mathbf{v} \quad (3.16)$$

称

$$f_X(\mathbf{x}) = \int_{-\infty}^{+\infty} f_{XY}(\mathbf{x}, \mathbf{y}) d\mathbf{y} \quad (3.17)$$

为随机向量  $\mathbf{X}$  的边缘分布密度函数. 称

$$f_Y(\mathbf{y}) = \int_{-\infty}^{+\infty} f_{XY}(\mathbf{x}, \mathbf{y}) d\mathbf{x} \quad (3.18)$$

为随机向量  $\mathbf{Y}$  的边缘分布密度函数.



$$F_X(\boldsymbol{x}) = \int_{-\infty}^{\boldsymbol{x}} f_X(\boldsymbol{u}) \mathrm{d}\boldsymbol{u}$$

$$F_Y(\boldsymbol{y}) = \int_{-\infty}^{\boldsymbol{y}} f_Y(\boldsymbol{u}) \mathrm{d}\boldsymbol{u}$$

简化的记号

**Theorem 3.1.8.** 设随机变量  $X, Y$  的联合概率密度为  $f_{XY}(x, y)$ ,  $(x, y) \in D$ . 令  $U = g_1(X, Y), V = g_2(X, Y)$ . 假设  $x = h_1(u, v), y = h_2(u, v)$  对  $u, v$  有连续的偏导数, 并且下述雅可比矩阵:

$$J(u, v) := \frac{\partial(h_1, h_2)}{\partial(u, v)} = \begin{bmatrix} \frac{\partial h_1}{\partial u} & \frac{\partial h_1}{\partial v} \\ \frac{\partial h_2}{\partial u} & \frac{\partial h_2}{\partial v} \end{bmatrix}$$

非奇异. 记

$$G = \{(u, v) | u = g_1(x, y), v = g_2(x, y), (x, y) \in D\}$$

那么

$$f_{UV}(u, v) = \begin{cases} f_{XY}(h_1(u, v), h_2(u, v)) |J(u, v)|^{-1}, & (u, v) \in G; \\ 0, & \text{其他.} \end{cases}$$

## 随机向量的数字特征（低阶统计特性）

---

**Definition 3.1.14. 【数学期望】** 设随机向量  $\mathbf{X}$  的概率密度函数为  $f(\mathbf{x})$ ，如果

$$E(\mathbf{X}) = \int_{-\infty}^{+\infty} \mathbf{x} f(\mathbf{x}) d\mathbf{x} \quad (3.21)$$

存在，则称  $E(\mathbf{X})$  为随机向量  $\mathbf{X}$  的数学期望，有时又称为均值。

上述定义表明，数学期望  $E(\mathbf{X})$  是与随机向量  $\mathbf{X}$  同维的常向量。经常也记为  $E\mathbf{X}, \bar{\mathbf{X}}, \mu(\mathbf{X})$  等。数学期望表示随机量的平均值，我们称扣除均值后的随机变量为中心随机变量，例如  $\overset{\circ}{\mathbf{X}} = \mathbf{X} - E(\mathbf{X})$ 。

**Theorem 3.1.9.** 数学期望具有如下性质：

- (1) 若  $C$  是一个常值向量，则  $E(C) = C$ ;
- (2) 若  $A$  是常值矩阵， $X$  是随机向量，则  $E(AX) = AE(X)$ ;
- (3) 若  $X, Y$  是两个同维的随机向量，那么  $E(X + Y) = E(X) + E(Y)$ .

**Definition 3.1.15. 【协方差矩阵】** 设  $\mathbf{X}$  是随机向量, 若

$$E(\mathring{\mathbf{X}} \mathring{\mathbf{X}}^T) = \int_{-\infty}^{+\infty} \mathring{\mathbf{X}} \mathring{\mathbf{X}}^T f(\mathbf{x}) d\mathbf{x} \quad (3.22)$$

存在, 则称其为随机向量  $\mathbf{X}$  的协方差矩阵, 记为  $\text{cov}(\mathbf{X}, \mathbf{X})$  或  $D(\mathbf{X})$ .

对于随机变量, 即一维随机向量, 上述协方差的概念退化为方差. 随机变量  $X$  的方差记为  $D(X)$  或  $\sigma^2(X)$ . 显然随机变量的方差是非负的, 其平方根称为均方差、标准差, 记为  $\sigma(X)$ . 即  $\sigma(X) = \sqrt{D(X)} = \sqrt{\sigma^2(X)}$ .

**Theorem 3.1.10.** 随机向量的协方差矩阵是对称的非负定方阵.

**Definition 3.1.16. 【互协方差矩阵】** 设  $\mathbf{X}, \mathbf{Y}$  是两个随机向量, 若

$$E(\overset{\circ}{\mathbf{X}}\overset{\circ}{\mathbf{Y}}^T) = \int_{-\infty}^{+\infty} \overset{\circ}{\mathbf{X}}\overset{\circ}{\mathbf{Y}}^T f(\mathbf{x}, \mathbf{y}) d\mathbf{x}d\mathbf{y}$$

存在, 则称其为随机向量  $\mathbf{X}$  与  $\mathbf{Y}$  的 互协方差矩阵, 记为  $\text{cov}(\mathbf{X}, \mathbf{Y})$ .

两个随机变量的互协方差是一个标量, 简称为协方差, 反映了两种之间的统计关联程度.

**Definition 3.1.17. 【独立性】** 设  $X, Y$  是两个随机向量, 如果

$$F_{XY}(\boldsymbol{x}, \boldsymbol{y}) = F_X(\boldsymbol{x})F_Y(\boldsymbol{y})$$

等价地 (假设相应概率密度函数存在)

$$f_{XY}(\boldsymbol{x}, \boldsymbol{y}) = f_X(\boldsymbol{x})f_Y(\boldsymbol{y})$$

那么称  $X$  与  $Y$  相互独立.

**Definition 3.1.18. 【相关性】** 设  $X, Y$  是两个随机向量, 如果

$$E(\overset{\circ}{X}\overset{\circ}{Y}^T) = \mathbf{0}$$

那么称  $X$  与  $Y$  不相关.

如果  $X, Y$  是两个不相关的随机变量, 那么  $E(XY) = E(X)E(Y)$ , 同时  $D(X + Y) = D(X) + D(Y)$ .

**Theorem 3.1.11.** 如果两个随机向量相互独立, 则两者不相关. 反之, 则不一定.



**Definition 3.1.19. 【相关系数】** 设  $X, Y$  是随机变量，两者的方差均存在，那么称

$$r_{XY} = \frac{\text{cov}(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$$

为随机变量  $X$  与  $Y$  之间的相关系数.

**Theorem 3.1.12.** 设随机变量  $X$  与  $Y$  之间的相关系数为  $r_{XY}$ , 那么

(1)  $|r_{XY}| \leq 1$ ;

(2)  $|r_{XY}| = 1$  的充要条件是存在常数  $a, b$ , 使

$$P(Y = aX + b) = 1$$

即  $X$  与  $Y$  以概率 1 存在线性关系.

(3) 如果  $X$  与  $Y$  不相关, 则  $r_{XY} = 0$ .

**Definition 3.1.20.** 对所有使  $f_Y(\mathbf{y}) > 0$  的  $\mathbf{y}$ , 给定  $Y = \mathbf{y}$  条件下的  $X$  的条件分布函数和条件密度函数分别为

$$F_{X|Y}(\mathbf{x}|\mathbf{y}) = \int_{-\infty}^{\mathbf{x}} \frac{f_{XY}(\mathbf{u}, \mathbf{y})}{f_Y(\mathbf{y})} d\mathbf{u} \quad (3.29)$$

$$f_{X|Y}(\mathbf{x}|\mathbf{y}) = \frac{f_{XY}(\mathbf{x}, \mathbf{y})}{f_Y(\mathbf{y})} \quad (3.30)$$

同样地, 对所有使  $f_X(\mathbf{x}) > 0$  的  $\mathbf{x}$ , 给定  $X = \mathbf{x}$  条件下的  $Y$  的条件分布函数和条件密度函数分别为

$$F_{Y|X}(\mathbf{y}|\mathbf{x}) = \int_{-\infty}^{\mathbf{y}} \frac{f_{XY}(\mathbf{x}, \mathbf{v})}{f_X(\mathbf{x})} d\mathbf{v} \quad (3.31)$$

$$f_{Y|X}(\mathbf{y}|\mathbf{x}) = \frac{f_{XY}(\mathbf{x}, \mathbf{y})}{f_X(\mathbf{x})} \quad (3.32)$$

**Theorem 3.1.13. 【贝叶斯法则】** 设  $f_Y(\mathbf{y}) > 0$ , 有

$$f_{X|Y}(\mathbf{x}|\mathbf{y}) = \frac{f_{Y|X}(\mathbf{y}|\mathbf{x})f_X(\mathbf{x})}{f_Y(\mathbf{y})} \quad (3.33)$$

这是我们后面要经常用到的一个结论，以后会称  $f_{X|Y}(\mathbf{x}|\mathbf{y})$  为验后概率密度，称  $f_X(\mathbf{x})$  为验前概率密度.

# 常用的随机分布

---

**Definition 3.1.21. 【均匀分布】** 设随机变量  $X$  具有概率密度

$$f_X(x) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{其他} \end{cases}$$


则称  $X$  在区间  $(a, b)$  上服从均匀分布, 记为  $X \sim U(a, b)$ .

**Theorem 3.1.14.** 设  $X \sim U(a, b)$ , 那么


$$F_X(x) = \int_{-\infty}^x f_X(t) dt = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x < b \\ 1, & x \geq b \end{cases}$$

**Theorem 3.1.15.** 设  $X \sim U(a, b)$ , 那么

$$E(X) = \frac{1}{2}(a + b)$$
$$\sigma^2(X) = \frac{1}{12}(b - a)^2$$



(a) 概率密度函数



(b) 概率分布函数

# 正态分布

---

**Definition 3.1.22.** 【正态分布】 设随机变量  $X$  具有概率密度


$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, -\infty < x < +\infty \quad (3.38)$$

其中  $\mu, \sigma (\sigma > 0)$  为常数, 则称  $X$  服从参数为  $\mu, \sigma$  的 正态分布或高斯 (Gauss) 分布, 记为  $X \sim N(\mu, \sigma^2)$ .


**Theorem 3.1.16.** 设  $X \sim N(\mu, \sigma^2)$ , 那么  $E(X) = \mu, D(X) = \sigma^2$ .

**Theorem 3.1.17.** 设  $X \sim N(\mu, \sigma^2)$ , 则  $Y = \frac{X-\mu}{\sigma} \sim N(0, 1)$ .








(a) 概率密度函数



(b) 概率分布函数





**Definition 3.1.23.** 设随机向量  $\mathbf{X}$  的均值向量为  $\boldsymbol{\mu}$ , 记

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, \quad \boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_n \end{bmatrix}.$$

如果  $\mathbf{X}$  的概率密度为

$$f(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^n |P|}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T P^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}$$

则  $\mathbf{X}$  服从正态分布, 记为  $\mathbf{X} \sim N(\boldsymbol{\mu}, P)$ . 其中  $P = \text{cov}(\mathbf{X}, \mathbf{X})$ , 而且  $P$  对称正定.

**Theorem 3.1.18.** 设  $\mathbf{X}$  和  $\mathbf{Y}$  分别服从正态分布，两者相互独立的充要条件是两者不相关，即

$$f_{XY}(\mathbf{x}, \mathbf{y}) = f_X(\mathbf{x})f_Y(\mathbf{y}) \iff \text{cov}(\mathbf{X}, \mathbf{Y}) = 0.$$

对一维正态分布随机变量来说，即为  $f_{XY}(x, y) = f_X(x)f_Y(y) \iff E(XY) = E(X)E(Y).$

**Theorem 3.1.19.** 设  $n$  维随机向量  $\mathbf{X} \sim N(\boldsymbol{\mu}_X, P_X)$ ,  $M \in R^{m \times n}$  是常值矩阵,  $\mathbf{b} \in R^m$  是常值向量, 则  $m$  维随机向量  $\mathbf{Y} = M\mathbf{X} + \mathbf{b}$  也服从正态分布, 且  $\boldsymbol{\mu}_Y = M\boldsymbol{\mu}_X + \mathbf{b}, P_Y = MP_XM^T$ , 即  $\mathbf{Y} \sim N(M\boldsymbol{\mu}_X + \mathbf{b}, MP_XM^T).$

**Theorem 3.1.20 (中心极限定理).** 设  $\mathbf{X}^i (i = 1, 2, \dots, r)$  是一组相互独立、同分布的  $n$  维随机向量, 具有有限均值  $E(\mathbf{X}^i)$  和协方差矩阵  $P^i$ , 令

$$\mathbf{Y}^r = \sum_{i=1}^r \mathbf{X}^i \quad (3.40)$$

$$\mathbf{Z}^r = (P^r)^{-\frac{1}{2}} (\mathbf{Y}^r - \bar{\mathbf{Y}}^r) \quad (3.41)$$

其中

$$\bar{\mathbf{Y}}^r = \sum_{i=1}^r \mathbf{X}^i, \quad P^r = \sum_{i=1}^r P^i$$

那么

$$\lim_{r \rightarrow +\infty} f(\mathbf{z}^r) = \frac{1}{\sqrt{(2\pi)^n}} \exp\left\{-\frac{\mathbf{z}^T \mathbf{z}}{2}\right\} \quad (3.42)$$

上述定理说明, 当  $r \rightarrow +\infty$  时,  $\mathbf{Z}^r$  趋于标准正态分布的随机向量。因此, 大量的微观上独立随机因素之和在宏观上可以用正态分布来描述.

# 符号简记

---

到目前为止，我们分别用  $X, \mathbf{X}$  表示随机变量和随机向量. 在不会产生歧义情况下，后面我们将分别用  $x, \mathbf{x}$  表示随机变量和随机向量. 例如， $x \sim N(\mu, \sigma^2)$  表示服从均值为  $\mu$ 、方差为  $\sigma^2$  的正态分布随机变量  $x$ ， $\mathbf{x} \sim N(\bar{\mathbf{x}}, P_x)$  表示服从均值为  $\bar{\mathbf{x}}$ 、协方差矩阵为  $P_x$  的正态分布随机向量  $\mathbf{x}$ .