



3 静态参数估计理论

蔡远利

◇ 静态参数估计

- 点估计
- 区间估计

◇ 经典点估计理论

- 最小二乘估计(K.F. Gauss)
- 极大似然估计 (R.A. Fisher)
- 贝叶斯估计(T. Bayes)

◇ 工程应用

■ 系统参数辨识

根据测量到的输入-输出数据来评估已知数学模型中的系数

■ 飞行器气动参数辨识

从飞行测量数据中提取飞行器的气动导数（飞行器气动导数包含在飞行器动态方程系数中）

3.0 问题描述

- ✧ 设 X 为一随机矢量， Z 为另外一个与 X 统计相关随机矢量，已知随机矢量 Z 的一个样本（实现） z ；
- ✧ 推断随机矢量 X 最可能的取值 \hat{x} ，或称想办法获得随机矢量 X 的最优估计值 \hat{x} 。

【Remarks】

- 显然，估计值 \hat{x} 应该是 z 的函数，可以记为 $\hat{x}(z)$ 。
- 更一般地，函数 $\hat{x}(Z)$ 称为由 Z 构成的统计量。
- 在不至混淆的情况下，以后我们将对随机量及其样本采用相同的符号。
- 符号惯例说明见表 3-1。

表 3-1 符号惯例

符号	含义
x	被估计量
z	测量（量测）量
\hat{x}	被估计量的估计值，是量测量的向量函数
\tilde{x}	估计误差， $x - \hat{x}$



3.1 贝叶斯估计(Bayes Estimation)

[定义3-1] (代价函数) 若标量函数 $L[x - \hat{x}(z)] = L(\tilde{x})$ 满足:

- 1) 当 $\|\tilde{x}_2\| \geq \|\tilde{x}_1\|$ 时, 有 $L(\tilde{x}_2) \geq L(\tilde{x}_1)$;
- 2) 当 $\tilde{x} = 0$ 时, $L(\tilde{x}) = 0$;
- 3) $L(\tilde{x}) = L(-\tilde{x})$.

则称 $L(\tilde{x})$ 为用 $\hat{x}(z)$ 对 x 进行估计时的**代价函数**(或**损失函数**).

[定义3-2] (贝叶斯风险) $B(\tilde{x}) = E[L(\tilde{x})]$ 称为估计 $\hat{x}(z)$ 的贝叶斯风险 (Bayes' Risk)。

[定义3-3] (贝叶斯估计) 若 $\hat{x}(z)$ 是使 $B(\tilde{x}) \Rightarrow \min$ 的估计, 那么称 $\hat{x}(z)$ 为 x 的贝叶斯估计。

3.1.1 最小方差估计

[定义3-4] (最小方差估计) 取 $L(\tilde{x}) = [x - \hat{x}(z)]^T [x - \hat{x}(z)]$ 的贝叶斯估计, 称为最小方差估计, 记为 $\hat{x}_{MV}(z)$.

[定理 3-1] (条件均值)

$$\hat{x}_{MV}(z) = E[x|z] \quad (3.1.1)$$

[证明] 根据最小方差估计的定义, 可知

$$\begin{aligned} B(\tilde{x}) &= E[x - \hat{x}(z)]^T [x - \hat{x}(z)] \\ &= \iint_{-\infty}^{+\infty} [x - \hat{x}(z)]^T [x - \hat{x}(z)] f(x, z) dx dz \\ &= \int_{-\infty}^{+\infty} f_z(z) \left\{ \int_{-\infty}^{+\infty} [x - \hat{x}(z)]^T [x - \hat{x}(z)] f(x|z) dx \right\} dz \\ &= \int_{-\infty}^{+\infty} f_z(z) B_z(\tilde{x}) dz \end{aligned}$$

不难发现

$$B(\tilde{x}) \Rightarrow \min \Leftrightarrow B_Z(\tilde{x}) \Rightarrow \min$$

由极值必要条件, 可得

$$\begin{aligned}\frac{\partial B_Z(\tilde{x})}{\partial \hat{x}} &= -2 \int_{-\infty}^{+\infty} (x - \hat{x}) f(x|z) dx = 0 \\ \Rightarrow \hat{x}_{MV}(z) &= \int_{-\infty}^{+\infty} x f(x|z) dx = E[x|z]\end{aligned}$$

验证充分条件

$$\frac{\partial^2 B_Z(\tilde{x})}{\partial^2 \hat{x}} = 2I > 0 \text{ (Positive)}$$

证毕!



[推论 3-1] 最小方差估计的均值及估计误差协方差分别为

$$(1) E\hat{x}_{MV}(z) = Ex \quad (E\tilde{x}_{MV} = 0)$$

$$(2) P_{\tilde{x}_{MV}} = \int_{-\infty}^{+\infty} P_{x|z} f_z(z) dz = E_z P_{x|z}$$

[证明] 根据均值的定义

$$E\overline{x|z} = \int_{-\infty}^{+\infty} \overline{x|z} f_z(z) dz$$



$$\begin{aligned} &= \iint_{-\infty}^{+\infty} x f_{x|z}(x) f_z(z) dx dz \\ &= \iint_{-\infty}^{+\infty} x f_{xz}(x, z) dx dz = \bar{x} \end{aligned}$$

因此 $E\hat{x}_{MV}(z) = Ex$, 即 $E\tilde{x}_{MV} = 0$. 再由协方差的定义

$$\begin{aligned} P_{\tilde{x}_{MV}} &= E\tilde{x}_{MV}\tilde{x}_{MV}^T \\ &= E\{(x - \overline{x|z})(x - \overline{x|z})^T\} \end{aligned}$$



$$\begin{aligned} &= \int_{-\infty}^{+\infty} f_z(z) dz \int_{-\infty}^{+\infty} (x - \bar{x}|z)(x - \bar{x}|z)^T f_{x|z}(x) dx \\ &= E_z P_{x|z} \end{aligned}$$

证毕!

[推论 3-2] 若 x 与 z 相互独立, 则

$$\hat{x}_{MV} = E[x|z] = E x = \bar{x}.$$



[证明] 由贝叶斯公式可知

$$\begin{aligned} E[x|z] &= \int_{-\infty}^{+\infty} x f_{x|z}(x) dx = \int_{-\infty}^{+\infty} x \frac{f_{xz}(x, z)}{f_z(z)} dx \\ &= \int_{-\infty}^{+\infty} x \frac{f_x(x) f_z(z)}{f_z(z)} dx = \int_{-\infty}^{+\infty} x f_x(x) dx \end{aligned}$$

所以, x 与 z 相互独立时 $E[x|z] = E x = \bar{x}$, 得证!



[推论 3-3] (最小方差估计一般求解公式)

$$\hat{x}_{MV}(z) = \frac{\int_{-\infty}^{+\infty} x f_{z|x}(z|x) f_x(x) dx}{\int_{-\infty}^{+\infty} f_{z|x}(z|x) f_x(x) dx} \quad (3.1.2)$$

[证明] 因为

$$\hat{x}_{MV}(z) = \overline{x|z} = \int_{-\infty}^{+\infty} x f_{x|z}(x|z) dx$$



$$= \int_{-\infty}^{+\infty} x \frac{f_{xz}(x, z)}{f_z(z)} dx = \frac{\int_{-\infty}^{+\infty} x f_{xz}(x, z) dx}{\int_{-\infty}^{+\infty} f_{xz}(x, z) dx}$$

分子、分母分别再一次应用贝叶斯公式

$$f_{xz}(x, z) = f_{z|x}(z|x)f_x(x),$$

即得证。



[定理 3-2] (最优估计的不变性) 假设

(1) $L(\tilde{x})$ 关于 $\tilde{x} = 0$ 对称且凹;

(2) $B_z(\tilde{x}) = \int_{-\infty}^{+\infty} L(x - \hat{x}_B) f(x|z) dx$ 存在;

(3) $f(x|z)$ 关于条件均值 $\hat{x}_{MV} = E[x|z]$ 对称且凸。

那么, $\hat{x}_B = \hat{x}_{MV}$.

[证明] (略)



[定理 3-3] (随机正交原理) 设 x 与 z 是两随机矢量, 那么对任意的函数 $g(z)$, 均有

$$E g(z)(x - E[x|z])^T = 0 \quad (3.1.3)$$

[证明]
$$\begin{aligned} E g(z)(x - E[x|z])^T &= E g(z)x^T - E g(z)\overline{x|z}^T \\ &= E g(z)x^T - \int g(z) \left[\int x f_{x|z}(x) dx \right]^T f_z(z) dz \end{aligned}$$



$$= \overline{g(z)x^T} - \iint g(z)x^T f(x,z) dx dz = 0$$

证毕!

[推论 3-4] (随机投影定理) 设 $g(\bullet)$ 为任一函数, 那么

$$E\|x - E[x|z]\|^2 \leq E\|x - g(z)\|^2 \quad (3.1.4)$$



[证明] 根据范数的定义

$$\begin{aligned}\|x - g(z)\|^2 &= \|x - E[x|z] + E[x|z] - g(z)\|^2 \\&= \|x - E[x|z]\|^2 + \|E[x|z] - g(z)\|^2 \\&\quad + (x - E[x|z])^T (E[x|z] - g(z)) + (E[x|z] - g(z))^T (x \\&\quad - E[x|z])\end{aligned}$$

根据随机正交定理(3.1.3), 可知



$$E\|x - g(z)\|^2 = E\|x - E[x|z]\|^2 + E\|E[x|z] - g(z)\|^2$$

因此 $E\|x - E[x|z]\|^2 \leq E\|x - g(z)\|^2$ 。证毕!

[定理 3-4] (高斯条件均值与协方差) 设

$$x \sim N(\bar{x}, P_x), z \sim N(\bar{z}, P_z), \quad y = [x^T, z^T]^T \sim N(\bar{y}, P_y),$$

其中, $P_y = \begin{bmatrix} P_x & P_{xz} \\ P_{zx} & P_z \end{bmatrix}$, $P_{xz} = E(x - \bar{x})(z - \bar{z})^T$. 那么



$$E[x|z] = \bar{x} + P_{xz}P_z^{-1}(z - \bar{z}) \quad (3.1.5)$$

$$P_{x|z} = P_x - P_{xz}P_z^{-1}P_{zx} \quad (3.1.6)$$

【证明】 因为

$$\begin{aligned} f_{x|z}(x|z) &= \frac{f_{xz}(x, z)}{f_z(z)} = \frac{f_y(y)}{f_z(z)} \\ &= \frac{\sqrt{(2\pi)^m |P_z|}}{\sqrt{(2\pi)^{n+m} |P_y|}} \exp\left\{-\frac{1}{2}[(y - \bar{y})^T P_y^{-1}(\cdot) - (z - \bar{z})^T P_z^{-1}(\cdot)]\right\} \end{aligned}$$



考虑到

$$P_y^{-1} = \begin{bmatrix} D^{-1} & -D^{-1}P_{xz}P_z^{-1} \\ -P_z^{-1}P_{zx}D^{-1} & P_z^{-1} + P_z^{-1}P_{zx}D^{-1}P_{xz}P_z^{-1} \end{bmatrix} \quad (3.1.7)$$

其中, $D = P_x - P_{xz}P_z^{-1}P_{zx}$.

从而有

$$\begin{bmatrix} x - \bar{x} \\ z - \bar{z} \end{bmatrix}^T P_y^{-1} \begin{bmatrix} x - \bar{x} \\ z - \bar{z} \end{bmatrix} - (z - \bar{z})^T P_z^{-1} (z - \bar{z}) = [x - E(x|z)]^T P_{x|z}^{-1} [*]$$

其中, $E(x|z) = \bar{x} + P_{xz}P_z^{-1}(z - \bar{z})$, $P_{x|z} = P_x - P_{xz}P_z^{-1}P_{zx}$.



注意到

$$\frac{|P_y|}{|P_z|} = |P_{x|z}| \quad (3.1.8)$$

于是可导出

$$f_{x|z}(x|z) = \frac{1}{\sqrt{(2\pi)^2 |P_{x|z}|}} \exp\left\{-\frac{1}{2} [x - E(x|z)]^T P_{x|z}^{-1} [**]\right\}$$

证毕!



[推论 3-5] 在[定理 3-4]条件下, $P_{\tilde{x}_{MV}} = E_z P_{x|z} = P_{x|z}$, 即

$$\underline{\tilde{x}_{MV} \sim N(0, P_x - P_{xz} P_z^{-1} P_{zx})}.$$

[证明] 由[推论 3-1]可知

$$P_{\tilde{x}_{MV}} = \int_{-\infty}^{+\infty} P_{x|z} f_z(z) dz = E_z P_{x|z}$$

而[定理 3-4]表明 $P_{x|z} = P_x - P_{xz} P_z^{-1} P_{zx}$, 是常值矩阵, 因此



$E_Z P_{x|z} = P_{x|z}$ 。结合最小方差估计是无偏估计的结论，所以[定理 3-4]条件下 $\tilde{x}_{MV} \sim N(0, P_x - P_{xz} P_z^{-1} P_{zx})$ 。证毕！

[定理 3-5] 若 $z = Hx + v, v \sim N(0, R), x \sim N(\bar{x}, P_x)$ ，而且 $Exv^T = 0$ （正交），则有

$$E[x|z] = \bar{x} + P_{x|z} H^T R^{-1} (z - H\bar{x}) \quad (3.1.9)$$

$$P_{x|z} = P_{\tilde{x}_{MV}} = (P_x^{-1} + H^T R^{-1} H)^{-1} \quad (3.1.10)$$



[证明] 根据给定的量测方程 $z = Hx + v$, 可导出

$$\bar{z} = H\bar{x}, \quad \check{z} = z - \bar{z} = Hx + v - H\bar{x} = H\check{x} + v$$

$$P_z = E\check{z}\check{z}^T = E(H\check{x} + v)(H\check{x} + v)^T = HP_xH^T + R$$

$$P_{xz} = E\check{x}\check{z}^T = E\check{x}(H\check{x} + v)^T = P_xH^T$$

根据[定理 3-4]可得

$$\begin{aligned}E[x|z] &= \bar{x} + P_{xz}P_z^{-1}(z - \bar{z}) \\&= \bar{x} + P_x H^T (H P_x H^T + R)^{-1}(z - H\bar{x})\end{aligned}$$

$$P_{x|z} = P_{\tilde{x}_{MV}} = P_x - P_{xz}P_z^{-1}P_{zx} = P_x - P_x H^T (H P_x H^T + R)^{-1} H P_x$$

由矩阵求逆引理

$$[(A_{22} - A_{21}A_{11}^{-1}A_{12})^{-1} = A_{22}^{-1} + A_{22}^{-1}A_{21}(A_{11} - A_{12}A_{22}^{-1}A_{21})^{-1}A_{12}A_{22}^{-1}]$$

$$P_x - P_x H^T (H P_x H^T + R)^{-1} H P_x = (P_x^{-1} + H^T R^{-1} H)^{-1}$$



所以在线性量测高斯分布条件下，最小方差估计为

$$E[x|z] = \bar{x} + P_{x|z}H^TR^{-1}(z - H\bar{x})$$

$$P_{x|z} = P_{\tilde{x}_{MV}} = (P_x^{-1} + H^TR^{-1}H)^{-1}$$

证毕!

上述估计误差协方差关系可以表示为

$$P_{x|z}^{-1} = P_x^{-1} + H^TR^{-1}H \quad (3.1.11)$$



具有重要的物理含义。另外，注意到

$$I - P_{x|z} H^T R^{-1} H = P_{x|z} (P_x^{-1} - H^T R^{-1} H) = P_{x|z} P_x^{-1} \quad (3.1.12)$$

我们可得[定理 3-5]的另外一种形式。

[定理 3-6] (线性量测高斯分布最小方差估计) 若 $z = Hx +$

$v, v \sim N(0, R), x \sim N(\bar{x}, P_x),$ 且 $Exv^T = 0,$ 则

$$\hat{x}_L = P_{\tilde{x}_L} (P_x^{-1} \bar{x} + H^T R^{-1} z) \quad (3.1.13)$$

$$P_{\tilde{x}_L}^{-1} = P_x^{-1} + H^T R^{-1} H \quad (3.1.14)$$



[例3-1] 设 $x \sim U[0,1]$, 即 $f_x(x) = \begin{cases} 1, & 0 \leq x \leq 1 \\ 0, & \text{otherwise} \end{cases}$ 。

(1) 求 x 的验前估计 \bar{x} ;

(2) x 的量测为 $z = \ln \frac{1}{x} + v$, v 服从指数分布, 即

$$f_v(v) = \begin{cases} e^{-v}, & v \geq 0 \\ 0, & v < 0 \end{cases}$$

此外假设 x 与 v 相互独立, 试求 x 的最小方差估计。

[解] (1) $\bar{x} = \int_{-\infty}^{+\infty} x f_x(x) dx = \frac{1}{2}$;



(2) 因为 x 与 v 相互独立, 所以

$$\begin{aligned} f_{z|x}(z|x) &= f_v\left(z - \ln \frac{1}{x}\right) \\ &= \begin{cases} e^{-z - \ln \frac{1}{x}}, & z - \ln \frac{1}{x} \geq 0 \\ 0, & z - \ln \frac{1}{x} < 0 \end{cases} = \begin{cases} \frac{1}{x} e^{-z}, & x \geq e^{-z} \\ 0, & x < e^{-z} \end{cases} \end{aligned}$$

由[推论 3-3]可知



$$\hat{x}_{MV}(z) = \frac{\int_{e^{-z}}^1 e^{-z} dx}{\int_{e^{-z}}^1 \frac{1}{x} e^{-z} dx} = \frac{e^{-z}(1 - e^{-z})}{e^{-z} \ln x \big|_{e^{-z}}^1} = \frac{1 - e^{-z}}{z}.$$

3.1.2 线性最小方差估计

[定义3-5] 取 $L(\tilde{x}) = [x - \hat{x}(z)]^T [x - \hat{x}(z)]$ 且形式上限制为 $\hat{x} = a + Bz$ 的 Bayes 估计, 其中 a 和 B 分别是常系数向量和矩阵, 则称为线性最小方差估计, 记为 $\hat{x}_L(z)$.



[引理3-1] 设 A, B, C 是合适维数的矩阵, 关于矩阵迹有如下公式:

$$\text{tr}(AB) = \text{tr}(BA)$$

$$\frac{\partial \text{tr}(ABA^T)}{\partial A} = AB + AB^T$$

$$\frac{\partial \text{tr}(BAC)}{\partial A} = B^T C^T$$



[引理3-2] 令 $L = [x - a - Bz]^T [x - a - Bz]$, 有

$$\frac{\partial L}{\partial a} = 2(a + Bz - x) \quad (3.1.15)$$

$$\frac{\partial L}{\partial B} = 2(Bz + a - x)z^T \quad (3.1.16)$$

[证明] 展开 L 得

$$L = x^T x + a^T a + z^T B^T B z - 2x^T a + 2a^T B z - 2x^T B z$$



直接可得式(3.1.15)。另外，对于任意相同维数向量 u 和 v ，有

$$u^T v = \text{tr}(vu^T)$$

因此

$$\begin{aligned}\frac{\partial L}{\partial B} &= \frac{\partial}{\partial B} (z^T B^T B z + 2a^T B z - 2x^T B z) \\ &= \frac{\partial}{\partial B} \text{tr}(B z z^T B^T + 2B z a^T - 2B z x^T)\end{aligned}$$



根据[引理 3-1], 可导出

$$\begin{aligned}\frac{\partial L}{\partial B} &= 2Bzz^T + 2az^T - 2xz^T \\ &= 2(Bz + a - x)z^T\end{aligned}$$

证毕!



[定理 3-7] (线性最小方差估计的充要条件)

$$E\{[x - \hat{x}_L(z)]z^T\} = 0 \quad (3.1.17)$$

$$E[x - \hat{x}_L(z)] = 0 \quad (3.1.18)$$

[证明] (1)充分性: 设以上两式成立, 对任意的 \hat{x} , 有

$$\begin{aligned} E\|x - \hat{x}\|^2 &= E\|x - \hat{x}_L(z) + \hat{x}_L(z) - \hat{x}\|^2 \\ &= E\|x - \hat{x}_L(z)\|^2 + E\|\hat{x}_L(z) - \hat{x}\|^2 \end{aligned}$$



$$+E[x - \hat{x}_L(z)]^T [\hat{x}_L(z) - \hat{x}] + E[\hat{x}_L(z) - \hat{x}]^T [x - \hat{x}_L(z)]$$

记 $\hat{x}_L(z) = a_o + B_o z$, $\hat{x} = a + Bz$, 那么 $\hat{x}_L(z) - \hat{x} = (a_o - a) + (B_o - B)z$, 考虑到

$$\begin{aligned} & E[\hat{x}_L(z) - \hat{x}][x - \hat{x}_L(z)]^T \\ &= E[a_o - a][x - \hat{x}_L(z)]^T \\ &+ E\{(B_o - B)z[x - \hat{x}_L(z)]^T\} = 0 \end{aligned}$$



说明 $E[\hat{x}_L(z) - \hat{x}]^T [x - \hat{x}_L(z)] = 0$ 。类似地，可知 $E[x - \hat{x}_L(z)]^T [\hat{x}_L(z) - \hat{x}] = 0$ 。因而有

$$E\|x - \hat{x}\|^2 = E\|x - \hat{x}_L(z)\|^2 + E\|\hat{x}_L(z) - \hat{x}\|^2$$

所以

$$E\|x - \hat{x}_L(z)\|^2 \leq E\|x - \hat{x}\|^2$$

说明 $\hat{x}_L(z)$ 是线性最小方差估计。

(2)必要性: 设 $\hat{x}_L(z) = a_o + B_o z$ 是线性最小方差估计, 由式

(3.1.17)可得

$$\left. \frac{\partial}{\partial a} E \|x - a - Bz\|^2 \right|_{a=a_o, B=B_o} = -2E[x - a_o - B_o z] = 0$$

即 $E[x - \hat{x}_L(z)] = 0$. 而由式(3.1.18)可得

$$\left. \frac{\partial}{\partial B} E \|x - a - Bz\|^2 \right|_{a=a_o, B=B_o} = -2E\{[x - a_o - B_o z]z^T\} = 0$$



因此 $E\{[x - \hat{x}_L(z)]z^T\} = 0$ 。证毕!

[推论 3-6] 对任意合适维数的矩阵 A 和向量 b , 都有

$$E\|x - \hat{x}_L(z)\|^2 \leq E\|x - Az - b\|^2 \quad (3.1.19)$$

[定理 3-8] (线性最小方差估计及其协方差)

$$\hat{x}_L(z) = \bar{x} + P_{xz}P_z^{-1}(z - \bar{z}) \quad (3.1.20)$$

$$P_{\tilde{x}_L} = E\tilde{x}_L\tilde{x}_L^T = P_x - P_{xz}P_z^{-1}P_{zx} \quad (3.1.21)$$



[证明] 设 $\hat{x}_L(z) = a_o + B_o z$, 根据线性最小方差估计充要条件 (3.1.18) 可知

$$\bar{x} = a_o + B_o \bar{z} \quad (3.1.22a)$$

而由 (3.1.17) 可得

$$\begin{aligned} E\{[x - \bar{x} + \bar{x} - \hat{x}_L(z)]z^T\} &= 0 \\ \Rightarrow E\{[x - \bar{x}]z^T\} &= E\{[\hat{x}_L(z) - \bar{x}]z^T\} \end{aligned}$$



因此

$$P_{xz} = E\{[\hat{x}_L(z) - \bar{x}][z - \bar{z}]^T\} \quad (3.1.22b)$$

注意到 $\hat{x}_L(z) - \bar{x} = B_o(z - \bar{z})$

上式两边右乘 $[z - \bar{z}]^T$ 并取数学期望，并带入(3.1.22b)，得

$$P_{xz} = B_o P_z \Rightarrow B_o = P_{xz} P_z^{-1}$$

将上式带入(3.1.22a)，可得

$$a_o = \bar{x} - P_{xz}P_z^{-1}\bar{z}$$

将 a_o, B_o 带入 $\hat{x}_L(z) = a_o + B_o z$, 即得

$$\hat{x}_L(z) = \bar{x} + P_{xz}P_z^{-1}(z - \bar{z})$$

由上式可知

$$\begin{aligned} P_{\hat{x}_L} &= E\{[\hat{x}_L(z) - x][\hat{x}_L(z) - x]^T\} \\ &= E\{[\bar{x} - x + P_{xz}P_z^{-1}(z - \bar{z})][\bar{x} - x + P_{xz}P_z^{-1}(z - \bar{z})]^T\} \\ &= P_x - P_{xz}P_z^{-1}P_{zx} \end{aligned}$$

上式中用到了 $P_z^T = P_z, P_{zx} = P_{xz}^T$ 。证毕!



[定理 3-9] 当 (x, z) 服从高斯分布时, $\hat{x}_L(z) = \hat{x}_{MV}(z)$.

[证明]在高斯分布假设下, 根据[定理 3-4]可知

$$\hat{x}_{MV}(z) = E[x|z] = \bar{x} + P_{xz}P_z^{-1}(z - \bar{z})$$

比较(3.1.20)即得证. 此外, 还有 $P_{x|z} = P_{\hat{x}_L}$. 即在正态分布情况下, 线性最小方差估计即为最小方差估计. 证毕!



[推论 3-7] 设 z 为测量值, x_1, x_2 为未知的随机量, A, B, r 是确定性量, 此外, $y = Ax_1 + Bx_2 + r + w$ 。 w 为噪声, 与 z 不相关, 而且 $Ew = 0$, 那么

$$(1) \hat{y}_L(z) = A\hat{x}_{1L}(z) + B\hat{x}_{2L}(z) + r;$$

$$(2) E\tilde{y}_L(z) = 0.$$

[证明]由[定理 3-8]可知

$$\hat{y}_L(z) = \bar{y} + P_{yz}P_z^{-1}(z - \bar{z})$$

而 $\bar{y} = A\bar{x}_1 + B\bar{x}_2 + r$

$$P_{yz} = E[y - \bar{y}][z - \bar{z}]^T = AP_{x_1z} + BP_{x_2z}$$

所以

$$\begin{aligned}\hat{y}_L(z) &= A\bar{x}_1 + B\bar{x}_2 + r + (AP_{x_1z} + BP_{x_2z})P_z^{-1}(z - \bar{z}) \\ &= A\bar{x}_1 + AP_{x_1z}P_z^{-1}(z - \bar{z}) + B\bar{x}_2 + BP_{x_2z}P_z^{-1}(z - \bar{z}) + r\end{aligned}$$



$$= A\hat{x}_{1L}(z) + B\hat{x}_{2L}(z) + r$$

另外

$$E\hat{y}_L(z) = A\bar{x}_1 + B\bar{x}_2 + r = \bar{y}$$

所以

$$E\tilde{y}_L(z) = E[\hat{y}_L(z) - E\hat{y}_L(z)] = E[\hat{y}_L(z) - \bar{y}] = 0$$

证毕!

[推论 3-8] 若 z_1, z_2, \dots, z_k 互不相关, 那么

$$\begin{aligned}\hat{x}_L(z_1, z_2, \dots, z_k) \\ = \hat{x}_L(z_1) + \hat{x}_L(z_2) + \dots + \hat{x}_L(z_k) - (k-1)\bar{x}\end{aligned}$$

[证明] 令

$$z = [z_1^T, z_2^T, \dots, z_k^T]^T$$

那么



$$\bar{z} = [z_1^T, z_2^T, \dots, z_k^T]^T$$

$$P_{xz} = E(x - \bar{x})(z - \bar{z})^T = [P_{xz_1}, P_{xz_2}, \dots, P_{xz_k}]$$

$$P_z = \begin{bmatrix} P_{z_1} & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & P_{z_k} \end{bmatrix}$$

根据[定理 3-8], 可知



$$\hat{x}_L(z) = \bar{x} + P_{xz} P_z^{-1} (z - \bar{z}) = \bar{x} + \sum_{i=1}^k P_{xz_i} P_{z_i}^{-1}$$

考虑到

$$\hat{x}_L(z_i) = \bar{x} + P_{xz_i} P_{z_i}^{-1}$$

所以

$$\hat{x}_L(z) = \sum_{i=1}^k \hat{x}_L(z_i) - (k-1)\bar{x} \quad \text{证毕!}$$



[例3-2] 设 $x \sim N(\bar{x}, P_x)$, $v \sim N(0, P_v)$, 两者不相关, 如果

$$z = Hx + v \quad (3.1.23)$$

试求 x 的线性最小方差估计。

[解] 根据线性最小方差估计([定理 3-8])

$$\hat{x}_L(z) = \bar{x} + P_{xz}P_z^{-1}(z - \bar{z})$$

$$P_{\tilde{x}_L} = P_x - P_{xz}P_z^{-1}P_{zx}$$



由(3.1.23)可知 $\bar{z} = H\bar{x}$, 令 $\check{x} = x - \bar{x}$, $\check{z} = z - \bar{z} = H\check{x} + v$,
可得

$$P_z = E[\check{z}\check{z}^T] = HP_xH^T + P_v$$

$$P_{xz} = E(\check{x})(\check{z})^T = E(\check{x})(H\check{x} + v)^T = P_xH$$

因此

$$\hat{x}_L(z) = \bar{x} + P_xH(HP_xH^T + P_v)^{-1}(Hz - \bar{z}) \quad (3.1.24)$$



$$P_{\tilde{x}_L} = P_x - P_x H (H P_x H^T + P_v)^{-1} H^T P_x \quad (3.1.25)$$

考虑到

$$I - P_x H (H P_x H^T + P_v)^{-1} H = P_{\tilde{x}_L} P_x^{-1}$$

$$P_x H (H P_x H^T + P_v)^{-1} H = I - P_{\tilde{x}_L} P_x^{-1} = P_{\tilde{x}_L} (P_{\tilde{x}_L}^{-1} - P_x^{-1})$$

将以上两式代入(3.1.24), 可得

$$\hat{x}_L(z) = P_{\tilde{x}_L} P_x^{-1} \bar{x} + P_{\tilde{x}_L} (P_{\tilde{x}_L}^{-1} - P_x^{-1}) z \quad (3.1.26)$$



另外应用矩阵求逆引理，由(3.1.25)可知

$$P_{\tilde{x}_L}^{-1} = P_x^{-1} + H^T P_v^{-1} H \quad (3.1.27)$$

代入(3.1.26)，最后导出

$$\hat{x}_L(z) = P_{\tilde{x}_L} P_x^{-1} \bar{x} + P_{\tilde{x}_L} H^T P_v^{-1} H z \quad (3.1.28)$$

(3.1.27)和(3.1.28)即为简化表达的结果。总结起来， x 的线性最小方差估计及协方差矩阵为

$$\hat{x}_L(z) = P_{\tilde{x}_L} (P_x^{-1} \bar{x} + H^T P_v^{-1} H z) \quad (3.1.29)$$

$$P_{\tilde{x}_L}^{-1} = P_x^{-1} + H^T P_v^{-1} H \quad (3.1.30)$$

以上两式和(3.1.24)与(3.1.25)数学上是等价的。



[例3-3] 已知 $z = x + v$, $x \sim N(\bar{x}, \sigma_x^2)$, $v \sim N(0, \sigma_v^2)$, 试求 x 的线性最小方差估计。

[解] 由于 $H = 1$, $P_v = \sigma_v^2$, 所以

$$H^T P_v^{-1} H = \sigma_v^{-2}$$

又 $P_x = \sigma_x^2$, 由(3.1.30)可知

$$P_{\tilde{x}_L}^{-1} = \sigma_{\tilde{x}_L}^{-2} = \sigma_x^{-2} + \sigma_v^{-2}$$



由(3.1.29)可以求得

$$\hat{x}_L(z) = \frac{\sigma_x^2 \sigma_v^2}{\sigma_x^2 + \sigma_v^2} \left(\frac{1}{\sigma_x^2} \bar{x} + \frac{1}{\sigma_v^2} z \right)$$

- 如果没有任何先验信息, 意味着 $\sigma_x^{-2} = 0$, 此时 $\hat{x}_L(z) = z$.
- 如果量测误差特别大, 即 $\sigma_v^{-2} \rightarrow 0$, 则 $\hat{x}_L(z) = \bar{x}$ (称为先验估计)。



[例3-4] 已知 $z = \ln \frac{1}{x} + v$, $x \sim U[0, 1]$, v 服从指数分布, 即

$$f_v(v) = \begin{cases} e^{-v}, & v \geq 0 \\ 0, & v < 0 \end{cases}$$

假设 x 与 v 相互独立, 试求 x 的线性最小方差估计。

[解] 因为

$$\bar{x} = \frac{1}{2}, \quad f_{xz}(x, z) = f_{z|x}(z|x)f_x(x),$$



$$f_{z|x}(z|x) = f_v(z - \ln \frac{1}{x}) = \begin{cases} e^{-(z - \ln \frac{1}{x})}, & z - \ln \frac{1}{x} \geq 0 \\ 0, & z - \ln \frac{1}{x} < 0 \end{cases}$$
$$= \begin{cases} \frac{1}{x} e^{-z}, & x \geq e^{-z} \\ 0, & x < e^{-z} \end{cases}$$

$$f_{xz}(x, z) = f_{z|x}(z|x)f_x(x) = \begin{cases} \frac{1}{x}e^{-z}, & 1 \geq x \geq e^{-z} \\ 0, & 0 \leq x < e^{-z} \end{cases}$$

所以

$$f_z(z) = \int_{-\infty}^{+\infty} f_{xz}(x, z)dx = \begin{cases} ze^{-z}, & z \geq 0 \\ 0, & z < 0. \end{cases}$$

因此



$$Exz = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xz f_{xz}(x, z) dx dz = \frac{3}{4},$$

$$P_{xz} = E(x - \bar{x})(z - \bar{z}) = Exz - \bar{x}\bar{z} = -\frac{1}{4},$$

$$\begin{aligned} P_z &= E(z - \bar{z})^2 = Ez^2 - \bar{z}^2 \\ &= \int_{-\infty}^{+\infty} z^2 f_z(z) dz - \left[\int_{-\infty}^{+\infty} z f_z(z) dz \right]^2 = 6 - 2^2 = 2. \end{aligned}$$

根据[定理 3-8], 可得

$$\begin{aligned}x_L &= \bar{x} + P_{xz}P_z^{-1}(z - \bar{z}) \\&= \frac{1}{2} - \frac{1}{4} \cdot \frac{1}{2}(z - 2) = \frac{3}{4} - \frac{1}{8}z\end{aligned}$$



注:

$$P(Z \leq z|X = x) = P\left(\frac{1}{\ln x} + V \leq z\right) = P\left(V \leq z - \frac{1}{\ln x}\right)$$

$$\Rightarrow F_{Z|x}(z|x) = F_v\left(z - \frac{1}{\ln x}\right)$$

$$\Rightarrow f_{Z|x}(z|x) = f_v\left(z - \frac{1}{\ln x}\right)$$



3.1.3 极大验后估计

[定义3-6] 使 $f(x|z) \Rightarrow \max$ 的估计称为 x 的极大验后估计, 记为 $\hat{x}_{MA}(z)$ 。称

$$\left. \frac{\partial \ln f(x|z)}{\partial x} \right|_{x=\hat{x}_{MA}} = 0 \quad (3.1.31)$$

为验后方程。

[定理 3-10] 若 (x, z) 服从联合高斯分布, 那么

$$\hat{x}_{MA}(z) = \hat{x}_{MV}(z) \text{ 。}$$

$$[\text{证明}] f_{x|z}(x|z) = \frac{1}{\sqrt{(2\pi)^n |P_{x|z}|}} \exp\left\{-\frac{1}{2} (x - \overline{x|z})^T P_{x|z} (x - \overline{x|z})\right\}$$

$$\frac{\partial \ln f_{x|z}(x|z)}{\partial x} = 0 \Leftrightarrow \frac{1}{2} (x - \overline{x|z})^T P_{x|z} (x - \overline{x|z}) \Rightarrow \min$$

$$\Rightarrow \hat{x}_{MA}(z) = \hat{x}_{MV}(z) = \overline{x|z}.$$



[定理 3-11] 取代价函数为

$$L(\tilde{x}) = \begin{cases} 0, & \|\tilde{x}\| < \frac{\varepsilon}{2} \\ \frac{1}{\varepsilon}, & \|\tilde{x}\| \geq \frac{\varepsilon}{2} \end{cases} \quad (\varepsilon > 0 \text{ 且足够小})$$

由此获得的 Bayes 估计 $\hat{x}_B(z)$ 即为 $\hat{x}_{MA}(z)$.

[证明] (参考资料)



3.2 极大似然估计(Maximum-Likelihood Estimation)

[定义3-7] 使似然函数

$$\Lambda(x) = f(z|x) \quad (3.2.1)$$

最大的估计称为 x 的极大似然估计, 记为 $\hat{x}_{ML}(z)$. 称

$$\left. \frac{\partial \ln \Lambda(x)}{\partial x} \right|_{x=\hat{x}_{ML}} = \left. \frac{\partial \ln f(z|x)}{\partial x} \right|_{x=\hat{x}_{ML}} = 0 \quad (3.2.2)$$

为似然方程。



[例3-5] 已知 $z = \ln \frac{1}{x} + v$, $x \sim U(0, 1)$, v 服从指数分布, 即

$$f_v(v) = \begin{cases} e^{-v}, & v \geq 0 \\ 0, & v < 0 \end{cases}$$

假设 x 与 v 相互独立, 试求 x 的极大似然估计 \hat{x}_{ML} 。

【解】 因为

$$f_{z|x}(z|x) = f_v\left(z - \ln \frac{1}{x}\right)$$



$$= \begin{cases} e^{-(z - \ln \frac{1}{x})}, & z - \ln \frac{1}{x} \geq 0 \\ 0, & z - \ln \frac{1}{x} < 0 \end{cases}$$
$$= \begin{cases} \frac{1}{x} e^{-z}, & x \geq e^{-z} \\ 0, & x < e^{-z} \end{cases}$$

所以 $\hat{x}_{ML} = e^{-z}$.

[定理 3-12] 当对 x 的验前信息一无所知时,

$$\hat{x}_{ML}(z) = \hat{x}_{MA}(z).$$

【证明】 由

$$f_{z|x}(z|x) = \frac{f_{zx}(z, x)}{f_x(x)} = \frac{f_{x|z}(x|z)f_z(z)}{f_x(x)}$$

可知



$$\ln f_{z|x}(z|x) = \ln f_{z|x}(x|z) + \ln f_z(z) - \ln f_x(x)$$

当对 x 的验前信息一无所知时

$$\frac{\partial \ln f_x(x)}{\partial x} = 0$$

因此
$$\frac{\partial \ln f_{z|x}(z|x)}{\partial x} = \frac{\partial \ln f_{x|z}(x|z)}{\partial x},$$

$$\Rightarrow \hat{x}_{ML}(z) = \hat{x}_{MA}(z).$$

[定理 3-13] (Linear Gaussian Measurement)

若

$$z = Hx + v, v \sim N(0, R)$$

则

$$\hat{x}_{ML}(z) = (H^T R^{-1} H)^{-1} H^T R^{-1} z \quad (3.2.3)$$

【证明】

$$\begin{aligned}f_{z|x}(z|x) &= f_v(z - Hx) \\&= \frac{1}{\sqrt{(2\pi)^n |R|}} \exp\left\{-\frac{1}{2} v^T R^{-1} v\right\} \Bigg|_{v=z-Hx} \\&= \frac{1}{\sqrt{(2\pi)^n |R|}} \exp\left\{-\frac{1}{2} (z - Hx)^T R^{-1} (z - Hx)\right\}\end{aligned}$$

显然，极大化似然函数相当于



$$J = \frac{1}{2}(z - Hx)^T R^{-1}(z - Hx) \Rightarrow \min$$

由此，有

$$\frac{\partial J}{\partial x} = -H^T R^{-1}(z - Hx) = 0.$$

当 $H^T R^{-1}H$ 非奇异时，即有

$$\hat{x}_{ML}(z) = (H^T R^{-1}H)^{-1}H^T R^{-1}z.$$

[推论 3-9] 线性量测高斯噪声条件下

$$(1) E\tilde{x}_{ML} = 0 \text{ (无偏估计)}$$

$$(2) P_{\tilde{x}_{ML}} = (H^T R^{-1} H)^{-1}$$

$$(3) \hat{x}_{ML} = P_{\tilde{x}_{ML}} H^T R^{-1} z$$

Remarks:

(1) [推论 3-9]中(2)、(3)合称为 Gauss-Markov 估计器;



- (2) 特别地, $P_{\tilde{x}_{ML}}$ 与测量值无关。
- (3) 当 $H = I, P_{\tilde{x}_{ML}} = R$, 此时 $\hat{x}_{ML} = z$;
- (4) 如果没有先验知识, 可以认为 $\bar{x} = 0, P_x \rightarrow \infty$, 由线性高斯量测最小方差估计知

$$\begin{cases} E[x|z] = \bar{x} + P_{x|z} H^T R^{-1} (z - H\bar{x}) \\ P_{x|z} = P_{\tilde{x}_{MV}} = (P_x^{-1} + H^T R^{-1} H)^{-1} \end{cases}$$

可见, 此时 $E[x|z] \rightarrow \hat{x}_{ML}, P_{\tilde{x}_{MV}} = P_{\tilde{x}_{ML}} = (H^T R^{-1} H)^{-1}$ 。

[例3-6] 设 x 是服从参数为 (μ, σ) 的正态分布的随机变量, 即

$$f(x|\mu, \sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\}$$

假设进行了 N 次独立的采样, 获得了相互独立的 x_1, x_2, \dots, x_N ,
试估计参数 (μ, σ) 。



[解]根据独立性假设, 可知

$$\Lambda(\mu, \sigma) = f(x_1, x_2, \cdots, x_N | \mu, \sigma)$$

$$= \frac{1}{\sqrt{(2\pi)^N \sigma^N}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^N (x_i - \mu)^2\right\}$$

根据似然函数极大化条件 $\frac{\partial \Lambda(\mu, \sigma)}{\partial \mu} = 0$, $\frac{\partial \Lambda(\mu, \sigma)}{\partial \sigma} = 0$, 可得



$$\sum_{i=1}^N (x_i - \mu) = 0, \quad \sum_{i=1}^N (x_i - \mu)^2 - N\sigma^2 = 0$$

由此可得两个参数的极大似然估计如下：

$$\hat{\mu} = \frac{1}{N} \sum_{i=1}^N x_i, \quad \hat{\sigma}^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$



[例3-7] 设估计确定性电压 x 有两种不同的方案，其一是用两个昂贵的电压表，它们的测量噪声为 $N(0,2)$ ；其二是用四个廉价的电压表，它们的测量噪声为 $N(0,3.5)$ 。试问哪一种方案测量到的结果更加可靠？

[解] (a)用两个昂贵的电压表时

$$z = \begin{bmatrix} 1 \\ 1 \end{bmatrix} x + v$$



其中, $v \sim N(0, \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix})$. 因此

$$P_{\tilde{x}} = (H^T R^{-1} H)^{-1} = \left[(1,1) \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}^{-1} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right]^{-1} = 1.$$

(b)用四个廉价电压表时

$$z = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} x + v$$



其中, $v \sim N(0, 3.5I)$. 此时

$$P_{\tilde{x}} = (H^T R^{-1} H)^{-1} = \frac{7}{8}$$

结论: 第二个方案更可靠些。



Remarks:

- 似然函数比验后概率要容易获得。
- 极大似然估计中，被估计量 x 可以是随机变量，也可以是非随机参数。
- 当有先验信息时，极大似然估计的精度不如极大验后估计。



3.2.1 Cramer-Rao Lower Bound

[定理 3-14] (1) 设 \hat{x} 为确定性量 x 基于测量 z 的无偏估计, 那么

$$P_{\tilde{x}} \geq J_F^{-1}$$

(3.2.4)

其中

$$J_F = E \left\{ \left[\frac{\partial \ln \Lambda(x)}{\partial x} \right] \left[\frac{\partial \ln \Lambda(x)}{\partial x} \right]^T \right\} \quad (3.2.4a)$$

$$= -E \left[\frac{\partial^2 \ln \Lambda(x)}{\partial x \partial x^T} \right] \quad (3.2.4b)$$

称为费希尔信息矩阵(Fisher information matrix). 此外, $\Lambda(x) = f(z|x)$ 。



(2) 设 \hat{x} 为随机量 x 基于量测 z 的无偏估计, 那么

$$P_{\hat{x}} \geq L^{-1} \quad (3.2.5)$$

其中

$$L = E \left\{ \left[\frac{\partial \ln f(x, z)}{\partial x} \right] \left[\frac{\partial \ln f(x, z)}{\partial x} \right]^T \right\} \quad (3.2.6a)$$

$$= -E \left[\frac{\partial^2 \ln f(x, z)}{\partial x \partial x^T} \right] \quad (3.2.6b)$$



称为信息矩阵(information matrix).

下面将针对确定性标量估计情况进行证明，要用到著名的施瓦尔兹不等式。



[引理3-3] (Schwarz Inequality) 设 $f, g \in L^2$, 那么

$$\begin{cases} \langle f, g \rangle \leq \|f\| \cdot \|g\| \\ \int_{-\infty}^{+\infty} f(x)g(x)dx \leq \sqrt{\int_{-\infty}^{+\infty} |f(x)|^2 dx} \sqrt{\int_{-\infty}^{+\infty} |g(x)|^2 dx} \end{cases} \quad (3.2.7)$$

(注: 在空间解析几何中, 一般向量的点积公式为 $\vec{a} \cdot \vec{b} \leq |\vec{a}| |\vec{b}|$)



对于确定性标量估计情况, $\Lambda(x) = f(z|x)$.

$$E[\hat{x}(z) - x] = \int_{-\infty}^{+\infty} [\hat{x}(z) - x] f(z|x) dz = 0$$

$$\Rightarrow \frac{d}{dx} \int_{-\infty}^{+\infty} [\hat{x}(z) - x] f(z|x) dz = 0$$

$$\Rightarrow - \int_{-\infty}^{+\infty} f(z|x) dz + \int_{-\infty}^{+\infty} [\hat{x}(z) - x] \frac{\partial}{\partial x} f(z|x) dz = 0$$



$$\Rightarrow \int_{-\infty}^{+\infty} [\hat{x}(z) - x] \frac{\partial \ln f(z|x)}{\partial x} f(z|x) dz = 1$$

根据施瓦尔兹不等式

$$\Rightarrow \int_{-\infty}^{+\infty} [\hat{x}(z) - x]^2 f(z|x) dz \int_{-\infty}^{+\infty} \left[\frac{\partial \ln f(z|x)}{\partial x} \right]^2 f(z|x) dz \geq 1$$

$$\Rightarrow P_{\tilde{x}} \geq \{E\left[\frac{\partial \ln f(z|x)}{\partial x}\right]^2\}^{-1}$$



由于 $\int_{-\infty}^{+\infty} f(z|x)dz = 1$, 可导出

$$\begin{aligned} & \int_{-\infty}^{+\infty} \frac{\partial \ln f(z|x)}{\partial x} f(z|x) dz = 0 \\ \Rightarrow & \int_{-\infty}^{+\infty} \frac{\partial^2 \ln f(z|x)}{\partial x^2} f(z|x) dz \\ = & - \int_{-\infty}^{+\infty} \left[\frac{\partial \ln f(z|x)}{\partial x} \right]^2 f(z|x) dz \end{aligned}$$



$$\Rightarrow E\left[\frac{\partial^2 \ln f(z|x)}{\partial x^2}\right] = -E\left\{\left[\frac{\partial \ln f(z|x)}{\partial x}\right]^2\right\}$$



极大似然估计随着量测样本数 N 增加, 具有许多优良的性质:

- (1) 对于确定性未知量 x , 当 $N \rightarrow +\infty$, \hat{x}_{ML} 依概率收敛于真值 x ; (任何具有该性质的估计称为**一致的**)
- (2) 极大似然估计是**渐进**高斯的, 即当 $N \rightarrow +\infty$, $\hat{x}_{ML} \sim N(x, P_{\hat{x}})$;
- (3) 当 $N \rightarrow +\infty$, 极大似然估计 \hat{x}_{ML} 是**有效的** (估计误差协方差达到Cramer-Rao 下界)。



3.3 最小二乘估计(Least-square Estimation)

设 x 是未知的常值向量, 考虑线性量测

$$z = Hx + v \quad (3.3.1)$$

其中, v 为测量误差或噪声. 我们的问题是基于 z 求 x 的最佳估计 \hat{x} 。



3.3.1 基本最小二乘估计

[定义3-8] 使指标函数

$$J(\hat{x}) = (z - H\hat{x})^T(z - H\hat{x}) \Rightarrow \min \quad (3.3.2)$$

的估计 \hat{x} 称为 x 的最小二乘估计, 记为 $\hat{x}_{LS}(z)$.



[定理 3-15]

(1) 当 $H^T H$ 非奇异时, $\hat{x}_{LS}(z) = (H^T H)^{-1} H^T z$.

(2) 若 v 为零均值噪声, 那么 $E\tilde{x}_{LS}(z) = 0$.

[证明] 由

$$\frac{\partial J(\hat{x})}{\partial \hat{x}} = -2H^T(z - H\hat{x}) = 0$$



可知

$$H^T H \hat{x} = H^T z$$

$H^T H$ 是方阵，如果非奇异，则

$$\hat{x}_{LS}(z) = (H^T H)^{-1} H^T z \quad (3.3.3)$$

$H^T H$ 非奇异保证了 $J(\hat{x})$ 关于的二阶导数矩阵非负定，说明上式的确是最优解。



将(3.3.1)代入(3.3.3), 得

$$\hat{x}_{LS}(z) = x + (H^T H)^{-1} H^T v$$

如果 $Ev = 0$, 则

$$E\hat{x}_{LS}(z) = x$$

即

$$E\tilde{x}_{LS}(z) = 0.$$



[例3-8] 用万用表对未知阻值的电阻进行 k 次测量值，根据含噪声的 k 个测量 $z_i (i = 1, 2, \dots, k)$ 对电阻值 x 进行估计。此时， x 是一个标量， k 个含噪声的测量值如下：

$$z_1 = x + v_1$$

$$\vdots$$

$$z_k = x + v_k$$



写成矩阵方程形式

$$\begin{bmatrix} z_1 \\ \vdots \\ z_k \end{bmatrix} = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} x + \begin{bmatrix} v_1 \\ \vdots \\ v_k \end{bmatrix}$$

由(3.3.3)可得电阻值 x 的最小二乘估计为

$$\hat{x}_{LS}(z) = (H^T H)^{-1} H^T z$$



$$= \left([1 \cdots 1] \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \right)^{-1} [1 \cdots 1] \begin{bmatrix} z_1 \\ \vdots \\ z_k \end{bmatrix} = \frac{1}{k} (z_1 + z_2 + \cdots + z_k)$$

3.3.2 加权最小二乘估计

在基本最小二乘估计中，假设了对所有的量测值具有相同的置信度。但在一定的条件下，我们可能对某些测量比其他的



更有信心。在这种情况下，可以对上一节的结果进行推广，从而获得加权最小二乘估计。

[定义3-9] 设 W 是正定对称方阵，使指标函数

$$J(\hat{x}) = (z - H\hat{x})^T W (z - H\hat{x}) \quad (3.3.3)$$

最小的估计 \hat{x} 称为 x 的加权最小二乘估计，记为 $\hat{x}_{WLS}(z)$ 。



[定理 3-16] 当 H^TWH 非奇异

$$\hat{x}_{WLS}(z) = (H^TWH)^{-1}H^TWz \quad (3.3.4)$$

若 v 为零均值噪声, $\hat{x}_{WLS}(z)$ 是 x 的无偏估计。如果进一步假设

$R = E[vv^T]$, 那么

$$P_{\hat{x}_{WLS}} = (H^TWH)^{-1}H^TWRWH(H^TWH)^{-1} \quad (3.3.5)$$



[定理 3-17] (Markov 估计) 设 $v \sim N(0, R)$ ($R > 0$), 取 $W = R^{-1}$,
那么

$$\hat{x}_{WLS}(z) = (H^T R^{-1} H)^{-1} H^T R^{-1} z \quad (3.3.6)$$

而且此时估计的均方误差最小,

$$P_{\tilde{x}_{WLS}} = (H^T R^{-1} H)^{-1} \quad (3.3.7)$$



[证明]将 $W = R^{-1}$ 带入一般的加权最小二乘估计(3.3.4), 即可得到(3.3.6). 同时由(3.3.6)可导出(3.3.7). 此外, 根据线性量测高斯分布情况下的[定理 3-6], 可知

$$\hat{x}_L = P_{\tilde{x}_L} (P_x^{-1} \bar{x} + H^T R^{-1} z) \quad (3.1.13)$$

$$P_{\tilde{x}_L}^{-1} = P_x^{-1} + H^T R^{-1} H \quad (3.1.14)$$

在最小二乘估计中, 认为没有 x 的先验信息($P_x^{-1} = 0$), 所以此



时的最小方差估计为

$$\hat{x}_L = P_{\tilde{x}_{LMV}} H^T R^{-1} Z$$

$$P_{\tilde{x}_L}^{-1} = H^T R^{-1} H$$

与(3.3.6), (3.3.7)是一致的, 即说明了此时的加权最小二乘估计的均方误差最小。证毕!



[例3-9] 在[例 3-8]中, 假设 $v_i \sim N(0, \sigma_i^2) (i = 1, \dots, k)$, 同时认为每次测量是独立进行的, 即

$$R = \text{diag}(\sigma_1^2, \dots, \sigma_k^2)$$

此时电阻值的最优估计为

$$\hat{x}_{WLS}(z) = (H^T R^{-1} H)^{-1} H^T R^{-1} z$$



$$\begin{aligned}
 &= \left([1 \cdots 1] \begin{bmatrix} \sigma_1^2 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sigma_k^2 \end{bmatrix}^{-1} \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \right)^{-1} [1 \cdots 1] \begin{bmatrix} \sigma_1^2 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sigma_k^2 \end{bmatrix}^{-1} \begin{bmatrix} z_1 \\ \vdots \\ z_k \end{bmatrix} \\
 &= \frac{1}{\sum_{i=1}^k 1/\sigma_i^2} \left(\frac{z_1}{\sigma_1^2} + \frac{z_2}{\sigma_2^2} + \cdots + \frac{z_k}{\sigma_k^2} \right)
 \end{aligned}$$

可见每次的测量精度作为权重进入了最后的估计，当 $\sigma_i^2 = \sigma^2$ (每次测量精度相同)，则退化为[例 3-8]了。



3.3.3 递推最小二乘估计

如果我们持续地进行测量，并希望随着每次新的测量值更新 x 的估计值，我们需要不断扩大 H 矩阵并完全重新计算估计值 \hat{x} 。当测量的次数变得很大时，计算量将变得非常大。例如，如果我们每秒测量一次卫星的高度，一小时就要测量 3600 次。显然，随着时间的增加，最小二乘估计的计算量可能很快超过我们的计算资源。因此，建立递推形式的最小二乘估计是非常有必要的。



假设我们已经获得了 k 时刻的最小二乘估计, 即由

$$z_k = H_k x + v_k \quad (3.3.15)$$

得到了加权最小二乘估计

$$P_k = (H_k^T W_k H_k)^{-1} \quad (3.3.16)$$

$$\hat{x}_k = P_k H_k^T W_k z_k \quad (3.3.17)$$

如果现在又获得了 $k + 1$ 时刻的量测, 即



$$z_{k+1} = H_{k+1}x + v_{k+1} \quad (3.3.18)$$

综合考虑(3.3.15)和(3.3.18), 加权最小二乘意味着

$$\left(\begin{bmatrix} z_k \\ z_{k+1} \end{bmatrix} - \begin{bmatrix} H_k \\ H_{k+1} \end{bmatrix} \hat{x}_{k+1} \right)^T \begin{bmatrix} W_k & 0 \\ 0 & w_{k+1} \end{bmatrix} \left(\begin{bmatrix} z_k \\ z_{k+1} \end{bmatrix} - \begin{bmatrix} H_k \\ H_{k+1} \end{bmatrix} \hat{x}_{k+1} \right) \\ \Rightarrow \min$$

即为



$$\begin{aligned} & (z_k - H_k \hat{x}_{k+1})^T W_k (z_k - H_k \hat{x}_{k+1}) \\ & + (z_{k+1} - H_{k+1} \hat{x}_{k+1})^T w_{k+1} (z_{k+1} - H_{k+1} \hat{x}_{k+1}) \\ & \Rightarrow \min \end{aligned}$$

由极值必要条件, 可得

$$H_k^T W_k (z_k - H_k \hat{x}_{k+1}) + H_{k+1}^T w_{k+1} (z_{k+1} - H_{k+1} \hat{x}_{k+1}) = 0$$



$$\begin{aligned} &\Rightarrow (H_k^T W_k H_k + H_{k+1}^T w_{k+1} H_{k+1}) \hat{x}_{k+1} \\ &\quad = H_k^T W_k z_k + H_{k+1}^T w_{k+1} z_{k+1} \\ &\Rightarrow (H_k^T W_k H_k + H_{k+1}^T w_{k+1} H_{k+1}) \hat{x}_{k+1} \\ &\quad = P_k^{-1} \hat{x}_k + H_{k+1}^T w_{k+1} z_{k+1} \end{aligned} \quad (3.3.19)$$

而由(3.3.16)可知



$$\begin{aligned} P_{k+1} &= \left(\begin{bmatrix} H_k \\ H_{k+1} \end{bmatrix}^T \begin{bmatrix} W_k & 0 \\ 0 & w_{k+1} \end{bmatrix} \begin{bmatrix} H_k \\ H_{k+1} \end{bmatrix} \right)^{-1} \\ &= (H_k^T W_k H_k + H_{k+1}^T w_{k+1} H_{k+1})^{-1} \end{aligned}$$

帶入(3.3.16), (3.3.19)化為出

$$\hat{x}_{k+1} = P_{k+1}(P_k^{-1}\hat{x}_k + H_{k+1}^T w_{k+1} z_{k+1}) \quad (3.3.20)$$

其中



$$P_{k+1} = (P_k^{-1} + H_{k+1}^T w_{k+1} H_{k+1})^{-1} \quad (3.3.21)$$

(3.3.20)和(3.3.21)一起构成了递推最小二乘估计。如果知道 $v_{k+1} \sim N(0, R_{k+1})$, 可以取 $w_{k+1} = R_{k+1}^{-1}$, 此时递推最小二乘估计算法公式为

$$\hat{x}_{k+1} = P_{k+1}(P_k^{-1}\hat{x}_k + H_{k+1}^T R_{k+1}^{-1} z_{k+1}) \quad (3.3.22)$$

$$P_{k+1}^{-1} = P_k^{-1} + H_{k+1}^T R_{k+1}^{-1} H_{k+1} \quad (3.3.23)$$



递推最小二乘估计也有其他等价形式，例如由(3.3.23)可知

$$P_{k+1}P_k^{-1} = I - P_{k+1}H_{k+1}^T R_{k+1}^{-1} H_{k+1} \quad (3.3.24)$$

代入(3.3.22)，可得如下结构的递推最小二乘估计

$$\hat{x}_{k+1} = \hat{x}_k + K_{k+1}[z_{k+1} - H_{k+1}\hat{x}_k] \quad (3.3.25)$$

其中

$$K_{k+1} = P_{k+1} H_{k+1}^T R_{k+1}^{-1} \quad (3.3.26)$$

由矩阵求逆引理, (3.3.21)可以化为

$$P_{k+1} = P_k - P_k H_{k+1}^T (R_{k+1} + H_{k+1} P_k H_{k+1}^T)^{-1} H_{k+1} P_k \quad (3.3.27)$$

这样可以减小递推计算量。(3.3.25)、(3.3.26)和(3.3.27)构成了一组完整的递推算法。

由(3.3.26), 可得



$$P_{k+1}H_{k+1}^T = K_{k+1}R_{k+1} \quad (3.3.28)$$

代入(3.3.27)可知

$$\begin{aligned} P_{k+1}H_{k+1}^T &= P_kH_{k+1}^T \\ &\quad - P_kH_{k+1}^T(R_{k+1} + H_{k+1}P_kH_{k+1}^T)^{-1}H_{k+1}P_kH_{k+1}^T \\ &= P_kH_{k+1}^T(R_{k+1} + H_{k+1}P_kH_{k+1}^T)^{-1}[(R_{k+1} + H_{k+1}P_kH_{k+1}^T) \\ &\quad - H_{k+1}P_kH_{k+1}^T] \end{aligned}$$



$$= P_k H_{k+1}^T (R_{k+1} + H_{k+1} P_k H_{k+1}^T)^{-1} R_{k+1}$$

比较(3.3.24), 可得 K_{k+1} 的另外一个计算公式

$$K_{k+1} = P_k H_{k+1}^T (R_{k+1} + H_{k+1} P_k H_{k+1}^T)^{-1} \quad (3.329)$$

代入(3.3.27), 可得

$$P_{k+1} = (I - K_{k+1} H_{k+1}) P_k \quad (3.3.30)$$

(3.3.25)、(3.3.29)和(3.3.30)是另外一组常见的递推公式,



重写如下:

$$\hat{x}_{k+1} = \hat{x}_k + K_{k+1}[z_{k+1} - H_{k+1}\hat{x}_k] \quad (3.3.25)$$

$$K_{k+1} = P_k H_{k+1}^T (R_{k+1} + H_{k+1} P_k H_{k+1}^T)^{-1} \quad (3.3.29)$$

$$P_{k+1} = (I - K_{k+1} H_{k+1}) P_k \quad (3.3.30)$$



[例3-10] 仍然考虑[例 3-8]中的问题，即用万用表对未知阻值的电阻进行测量，这里用递推最小二乘估计来求解。 k 时刻的量测方程为

$$z_i = x + v_i$$

假设 $v_i \sim (0, R_i)$, $R_i = R$. 本问题 $H_k = 1$.

$k = 0$: (给定 \hat{x}_0, P_0)



$$K_1 = \frac{P_0}{R + P_0}, P_1 = (1 - K_1)P_0 = \frac{RP_0}{R + P_0}$$

$$\begin{aligned}\hat{x}_1 &= \hat{x}_0 + K_1(z_1 - \hat{x}_0) = (1 - K_1)\hat{x}_0 + K_1z_1 \\ &= \frac{R}{R + P_0}\hat{x}_0 + \frac{P_0}{R + P_0}z_1\end{aligned}$$

$k = 1$:



$$K_2 = \frac{P_1}{R + P_1} = \frac{P_0}{R + 2P_0}, P_2 = (1 - K_2)P_1 = \frac{RP_0}{R + 2P_0}$$

$$\hat{x}_2 = \hat{x}_1 + K_2(z_2 - \hat{x}_1) = \frac{R + P_0}{R + 2P_0} \hat{x}_1 + \frac{P_0}{R + 2P_0} z_2$$

一般地 $k \geq 1$

$$K_k = \frac{P_{k-1}}{R + P_{k-1}} = \frac{P_0}{R + kP_0}, P_k = \frac{RP_0}{R + kP_0}$$



$$\begin{aligned}\hat{x}_k &= \hat{x}_{k-1} + K_k(z_k - \hat{x}_{k-1}) = (1 - K_k)\hat{x}_{k-1} + K_k z_k \\ &= \frac{R + (k-1)P_0}{R + kP_0} \hat{x}_{k-1} + \frac{P_0}{R + kP_0} z_k\end{aligned}$$

我们分三种初始条件讨论：

(1) $\hat{x}_0 = \bar{x}_0, P_0 = 0.$

$$K_k = 0: \hat{x}_k = \hat{x}_{k-1} = \cdots = \bar{x}_0$$



说明无需量测。

$$(2) R = +\infty.$$

$$K_k = 0: \hat{x}_k = \hat{x}_{k-1} = \cdots = \bar{x}_0$$

说明量测不能带来任何有意义信息。

$$(3) \hat{x}_0 = \bar{x}_0, P_0 = +\infty.$$



$$K_k = \frac{1}{k}: \hat{x}_k = \frac{k-1}{k} \hat{x}_{k-1} + \frac{1}{k} z_k = \frac{1}{k} [(k-1) \hat{x}_{k-1} + z_k]$$

说明电阻值的最优估计就是量测值的几何平均，即

$$\begin{aligned} \hat{x}_k &= \frac{1}{k} \sum_{i=1}^k z_i = \frac{1}{k} \left[(k-1) \frac{1}{k-1} \sum_{i=1}^{k-1} z_i + z_k \right] \\ &= \frac{1}{k} [(k-1) \hat{x}_{k-1} + z_k] \end{aligned}$$



Remarks:

- 最小二乘估计不需要任何统计信息，但精度较低。适用于确定量或变化规律确定的量之估计。
- 在递推最小二乘估计中，初始估计可取为零、初始 P_0 矩阵可取为元素足够大的对角线阵。若干步后，初值的影响就会逐渐消失。
- 滑动窗技术与遗忘因子法是工程中有效的改进算法。



3.4 本章小结 ($z = Hx + v$)

- (1) 最小二乘估计;
- (2) 线性最小方差估计;
- (3) 最小方差估计;
- (4) 极大似然估计;
- (5) 极大验后估计.

