

The background of the slide features a series of thin, dark grey lines forming overlapping circles and arcs, creating a complex, geometric pattern that resembles a Venn diagram or a network graph. This pattern is visible in the top and bottom white sections of the slide.

鲁棒 H_∞ 滤波

Prof. Yuan-Li Cai

Spring 2024

0. Outline

- 1 动态约束优化 / 3
- 2 H_∞ 滤波算法 / 11
- 3 卡尔曼滤波的另一种形式 / 49
- 4 H_∞ 滤波和卡尔曼滤波的区别和联系 / 53
- 5 小结 / 56

当系统模型及噪声统计特性存在大的不确定性或未知时，标准的 Kalman 滤波算法将无法保证状态估计在最小均方误差意义下的最优，甚至会出现发散现象。为此，近年人们基于 H_∞ 控制理论，发展起来了一种称为 H_∞ 滤波的方法，在理论界和工程领域引起了极大关注。

本节将在讨论动态约束优化的基础上，介绍 H_∞ 滤波的基本原理，并讨论、分析与 Kalman 滤波之间的区别和联系。

1. 动态约束优化

考虑如下动态系统:

$$\mathbf{x}_{k+1} = \mathbf{F}_k \mathbf{x}_k + \mathbf{w}_k \quad (k = 0, \dots, N-1) \quad (1)$$

式中, \mathbf{x}_k 为 n 维状态向量。我们的目标是最小化如下标量函数:

$$J = \psi(\mathbf{x}_0) + \sum_{k=0}^{N-1} \mathcal{L}_k(\mathbf{x}_k, \mathbf{w}_k) \quad (2)$$

式中, $\psi(\mathbf{x}_0)$ 是关于 \mathbf{x}_0 的已知函数, $\mathcal{L}_k(\mathbf{x}_k, \mathbf{w}_k)$ 是关于 \mathbf{x}_k 和 \mathbf{w}_k 的已知函数。通常要求 $\psi(\mathbf{x}_0)$ 和 $\mathcal{L}_k(\mathbf{x}_k, \mathbf{w}_k)$ 关于相关变量是光滑可导的。

(1) 和 (2) 便构成了一个带有约束的动态优化问题, (1) 称为动态约束, (2) 称为优化目标函数或性能指标。和经典的最优控制问题略有不同, 主要差异在 $\psi(\mathbf{x}_0)$ 项。和所有约束优化问题一样, 我们通过引入拉格朗日乘子来解决上述动态约束优化问题。

设拉格朗日乘子为 λ_{k+1} (对应动态约束方程, 共有 N 个 n 维向量), 我们可以获得如下增广目标函数:

$$\mathbf{J}_a = \psi(\mathbf{x}_0) + \sum_{k=0}^{N-1} [\mathcal{L}_k(\mathbf{x}_k, \mathbf{w}_k) + \lambda_{k+1}^T (\mathbf{F}_k \mathbf{x}_k + \mathbf{w}_k - \mathbf{x}_{k+1})] \quad (3)$$

上式可以改写整理为

$$\begin{aligned} J_a &= \psi(\mathbf{x}_0) + \sum_{k=0}^{N-1} [\mathcal{L}_k + \boldsymbol{\lambda}_{k+1}^T (\mathbf{F}_k \mathbf{x}_k + \mathbf{w}_k)] - \sum_{k=0}^{N-1} \boldsymbol{\lambda}_{k+1}^T \mathbf{x}_{k+1} \\ &= \psi(\mathbf{x}_0) + \sum_{k=0}^{N-1} [\mathcal{L}_k + \boldsymbol{\lambda}_{k+1}^T (\mathbf{F}_k \mathbf{x}_k + \mathbf{w}_k)] - \sum_{k=0}^N \boldsymbol{\lambda}_k^T \mathbf{x}_k + \boldsymbol{\lambda}_0^T \mathbf{x}_0 \end{aligned}$$

式中, $\boldsymbol{\lambda}_0$ 为拉格朗日乘子序列的附加项, 它并不在原始的增广目标函数中。后面我们将会看到当约束优化问题得到解决后, 它的取值也随之可以确定下来。

定义如下 Hamilton 函数:

$$\mathcal{H}_k(\mathbf{x}_k, \mathbf{w}_k, \boldsymbol{\lambda}_{k+1}) = \mathcal{L}_k(\mathbf{x}_k, \mathbf{w}_k) + \boldsymbol{\lambda}_{k+1}^T (\mathbf{F}_k \mathbf{x}_k + \mathbf{w}_k) \quad (4)$$

增广目标函数可以重写为

$$\begin{aligned} J_a &= \psi(\mathbf{x}_0) + \sum_{k=0}^{N-1} \mathcal{H}_k - \sum_{k=0}^N \lambda_k^T \mathbf{x}_k + \lambda_0^T \mathbf{x}_0 \\ &= \psi(\mathbf{x}_0) + \sum_{k=0}^{N-1} \mathcal{H}_k - \sum_{k=0}^{N-1} \lambda_k^T \mathbf{x}_k - \lambda_N^T \mathbf{x}_N + \lambda_0^T \mathbf{x}_0 \\ &= \psi(\mathbf{x}_0) + \sum_{k=0}^{N-1} (\mathcal{H}_k - \lambda_k^T \mathbf{x}_k) - \lambda_N^T \mathbf{x}_N + \lambda_0^T \mathbf{x}_0 \end{aligned}$$

显然，最优解的必要条件（驻点）如下：

$$\frac{\partial \mathbf{J}_a}{\partial \mathbf{x}_k} = 0 \quad (k = 0, \dots, N)$$

$$\frac{\partial \mathbf{J}_a}{\partial \mathbf{w}_k} = 0 \quad (k = 0, \dots, N-1)$$

$$\frac{\partial \mathbf{J}_a}{\partial \boldsymbol{\lambda}_k} = 0 \quad (k = 0, \dots, N)$$

进一步地可以写为

$$\frac{\partial \mathbf{J}_a}{\partial \mathbf{x}_0} = 0 \quad (5)$$

$$\frac{\partial \mathbf{J}_a}{\partial \mathbf{x}_N} = 0 \quad (6)$$

$$\frac{\partial \mathbf{J}_a}{\partial \mathbf{x}_k} = 0 \quad (k = 1, \dots, N-1) \quad (7)$$

$$\frac{\partial \mathbf{J}_a}{\partial \mathbf{w}_k} = 0 \quad (k = 0, \dots, N-1) \quad (8)$$

$$\frac{\partial \mathbf{J}_a}{\partial \boldsymbol{\lambda}_k} = 0 \quad (k = 0, \dots, N) \quad (9)$$

即

$$\boldsymbol{\lambda}_0 + \frac{\partial \psi_0}{\partial \mathbf{x}_0} = 0 \quad (10)$$

$$\boldsymbol{\lambda}_N = 0 \quad (11)$$

$$\boldsymbol{\lambda}_k = \frac{\partial \mathcal{H}_k}{\partial \mathbf{x}_k} \quad (k = 0, 1, \dots, N-1) \quad (12)$$

$$\frac{\partial \mathcal{H}_k}{\partial \mathbf{w}_k} = 0 \quad (k = 0, 1, \dots, N-1) \quad (13)$$

$$\mathbf{x}_{k+1} = \mathbf{F}_k \mathbf{x}_k + \mathbf{w}_k \quad (k = 0, 1, \dots, N-1) \quad (14)$$

通过求解上述方程组，即可获得动态约束优化问题的最优解（如果存在）。按惯例，我们用上标“*”表示最优解，将 $\boldsymbol{\lambda}_k$ 称为协态变量，对应这

里的动态约束优化问题，求得的最优解可表示为

$$\{\mathbf{x}_k^* | k = 0, 1, 2, \dots, N\} \quad (15)$$

$$\{\mathbf{w}_k^* | k = 0, 1, 2, \dots, N-1\} \quad (16)$$

$$\{\boldsymbol{\lambda}_k | k = 0, 1, 2, \dots, N\} \quad (17)$$

不能发现，未上述知变量的个数与约束方程个数相等，理论上有解。以上关于动态约束优化的方法及结果可以用来解决下面的 H_∞ 滤波问题。

2. H_∞ 滤波算法

考虑如下离散时间系统:

$$\mathbf{x}_{k+1} = \mathbf{F}_k \mathbf{x}_k + \mathbf{w}_k \quad (18)$$

$$\mathbf{y}_k = \mathbf{H}_k \mathbf{x}_k + \mathbf{v}_k \quad (19)$$

式中, \mathbf{w}_k 和 \mathbf{v}_k 为噪声项, 分别表示模型及数据的不确定性。这些噪声可能是随机的 (统计特性未知) 也可能是确定的, 它们的均值可能不为 0。

我们的目标是对状态的线性组合进行估计，可以表示为

$$\mathbf{z}_k = \mathbf{L}_k \mathbf{x}_k \quad (20)$$

其中， \mathbf{L}_k 是自定义的矩阵（假设 \mathbf{L}_k 满秩）。如果我们想要直接估计 \mathbf{x}_k ，设置 $\mathbf{L}_k = \mathbf{I}$ 。但通常情况下我们可能只对状态量的某种线性组合感兴趣。

设 \mathbf{z}_k 的估计量表示为 $\hat{\mathbf{z}}_k$ ，我们的目的是利用所有可能的信息获得使 $\sum_{k=0}^{N-1} \|\mathbf{z}_k - \hat{\mathbf{z}}_k\|_{\mathbf{S}_k}^2$ 尽可能小的估计 $\hat{\mathbf{z}}_k$ ，建立类似 Kalman 滤波那样的递推算法。其中， \mathbf{S}_k 是对称正定的权重矩阵。

显然，代表不确定性的环境（以后称为对方）不会配合我们，而会使得我们希望的估计变差。在 H_∞ 滤波中，假设对方可以调动所有资源，即最优地选择 \mathbf{w}_k 、 \mathbf{v}_k 和初始状态 \mathbf{x}_0 ，使得 $\sum_{k=0}^{N-1} \|\mathbf{z}_k - \hat{\mathbf{z}}_k\|_{\mathbf{S}_k}^2$ 尽可能的大。

如果不加限制, 对方可以取 \mathbf{w}_k 、 \mathbf{v}_k 和初始状态 \mathbf{x}_0 为无穷大, 这种情况明显没有实际意义。

因此, 我们可以利用博弈理论的思想, 定义如下目标函数:

$$\mathbf{J}_1 = \frac{\sum_{k=0}^{N-1} \|\mathbf{z}_k - \hat{\mathbf{z}}_k\|_{\mathbf{S}_k}^2}{\|\mathbf{x}_0 - \hat{\mathbf{x}}_0\|_{\mathbf{P}_0^{-1}}^2 + \sum_{k=0}^{N-1} (\|\mathbf{w}_k\|_{\mathbf{Q}_k^{-1}}^2 + \|\mathbf{v}_k\|_{\mathbf{R}_k^{-1}}^2)} \quad (21)$$

式中, \mathbf{P}_0 、 \mathbf{Q}_k 、 \mathbf{R}_k 和 \mathbf{S}_k 均为对称正定权重矩阵, 是设计参数。

于是，我们得到如下 min-max 问题：

$$\mathbf{J}_1^* = \min_{\hat{\mathbf{z}}_k} \max_{\mathbf{w}_k, \mathbf{v}_k, \mathbf{x}_0} \mathbf{J}_1 \quad (*)$$

由此可见 H_∞ 滤波和卡尔曼滤波本质上的区别。在卡尔曼滤波中，我们对对方是漠不关心的，同时认为噪声的统计特性是已知的，我们可以利用先验知识得到统计意义下的最优状态估计，可以认为是一种单边最优控制，对方无法改变噪声的统计特性来影响我们的状态估计效果。然而在 H_∞ 滤波中，认为对手会想尽办法降低我们的估计效果。可以认为是双方智能博弈。

在卡尔曼滤波中，没有考虑矩阵 \mathbf{S}_k 。如果在卡尔曼滤波中，最小化 \mathbf{S}_k 矩阵加权的估计误差方差，结果不受影响。而在 H_∞ 滤波中，后面会发现， \mathbf{S}_k 矩阵的取值会影响滤波增益。

直接求解上述 min-max 问题 (*) 非常困难, 下面通过设定一个性能边界来获取满足边界条件的估计策略, 即保证一定性能的鲁棒策略。

数学上, 我们把问题转化为寻找估计 \hat{z}_k , 同时使得

$$\mathbf{J}_1 < \epsilon \quad (22)$$

式中, $\epsilon(> 0)$ 为自定义的性能边界参数。结合 \mathbf{J}_1 的表达式, 上式可以重写为

$$\mathbf{J} = -\epsilon \|\mathbf{x}_0 - \hat{\mathbf{x}}_0\|_{\mathbf{P}_0^{-1}}^2 + \sum_{k=0}^{N-1} [\|\mathbf{z}_k - \hat{\mathbf{z}}_k\|_{\mathbf{S}_k}^2 - \epsilon(\|\mathbf{w}_k\|_{\mathbf{Q}_k^{-1}}^2 + \|\mathbf{v}_k\|_{\mathbf{R}_k^{-1}}^2)] < 1 \quad (23)$$

于是，我们的问题转化为如下 min-max 问题：

$$\mathbf{J}^* = \min_{\hat{\mathbf{z}}_k} \max_{\mathbf{w}_k, \mathbf{v}_k, \mathbf{x}_0} \mathbf{J} \quad (24)$$

由于 $\mathbf{z}_k = \mathbf{L}_k \mathbf{x}_k$ ，很自然地可以选择 $\hat{\mathbf{z}}_k = \mathbf{L}_k \hat{\mathbf{x}}_k$ ，从而只需要设法获得最小化 \mathbf{J} 的状态估计 $\hat{\mathbf{x}}_k$ 。因此，上述 min-max 问题可以改写为

$$\mathbf{J}^* = \min_{\hat{\mathbf{x}}_k} \max_{\mathbf{w}_k, \mathbf{v}_k, \mathbf{x}_0} \mathbf{J} \quad (25)$$

在博弈过程中，对方将选择 \mathbf{x}_0 、 \mathbf{w}_k 和 \mathbf{v}_k 去最大化 \mathbf{J} 。在给定 \mathbf{x}_0 和 \mathbf{w}_k 条件下， \mathbf{v}_k 完全决定了 \mathbf{y}_k ，所以我们可以将上述 min-max 问题进一步化为

$$\mathbf{J}^* = \min_{\hat{\mathbf{x}}_k} \max_{\mathbf{w}_k, \mathbf{y}_k, \mathbf{x}_0} \mathbf{J} \quad (26)$$

由 $\mathbf{y}_k = \mathbf{H}_k \mathbf{x}_k + \mathbf{v}_k$, 可知

$$\|\mathbf{v}_k\|_{\mathbf{R}_k^{-1}}^2 = \|\mathbf{y}_k - \mathbf{H}_k \mathbf{x}_k\|_{\mathbf{R}_k^{-1}}^2 \quad (27)$$

另外, $\mathbf{z}_k = \mathbf{L}_k \mathbf{x}_k$, $\hat{\mathbf{z}}_k = \mathbf{L}_k \hat{\mathbf{x}}_k$, 所以

$$\begin{aligned} \|\mathbf{z}_k - \hat{\mathbf{z}}_k\|_{\mathbf{S}_k}^2 &= (\mathbf{z}_k - \hat{\mathbf{z}}_k)^\top \mathbf{S}_k (\mathbf{z}_k - \hat{\mathbf{z}}_k) \\ &= (\mathbf{x}_k - \hat{\mathbf{x}}_k)^\top \mathbf{L}_k^\top \mathbf{S}_k \mathbf{L}_k (\mathbf{x}_k - \hat{\mathbf{x}}_k) \\ &= \|\mathbf{x}_k - \hat{\mathbf{x}}_k\|_{\bar{\mathbf{S}}_k}^2 \end{aligned} \quad (28)$$

式中, $\bar{\mathbf{S}}_k$ 定义为

$$\bar{\mathbf{S}}_k = \mathbf{L}_k^\top \mathbf{S}_k \mathbf{L}_k \quad (29)$$

综合上述讨论，我们可导出

$$\begin{aligned} \mathbf{J} &= -\epsilon \|\mathbf{x}_0 - \hat{\mathbf{x}}_0\|_{\mathbf{P}_0^{-1}}^2 + \sum_{k=0}^{N-1} [\|\mathbf{x}_k - \hat{\mathbf{x}}_k\|_{\mathbf{S}_k}^2 - \epsilon(\|\mathbf{w}_k\|_{\mathbf{Q}_k^{-1}}^2 + \|\mathbf{y}_k - \mathbf{H}_k \mathbf{x}_k\|_{\mathbf{R}_k^{-1}}^2)] \\ &= \psi(\mathbf{x}_0) + \sum_{k=0}^{N-1} \mathcal{L}_k \end{aligned} \quad (30)$$

上式给出了 $\psi(\mathbf{x}_0)$ 和 \mathcal{L}_k 的定义。

为了解决上述 min-max 问题，我们首先寻找目标函数 \mathbf{J} 关于 \mathbf{x}_0 和 \mathbf{w}_k 的驻点，然后求解 \mathbf{J} 关于 $\hat{\mathbf{x}}_k$ 和 \mathbf{y}_k 的驻点。

2.1 关于 \mathbf{x}_0 和 \mathbf{w}_k 的驻点

本小节的问题是寻找 $\mathbf{J} = \psi(\mathbf{x}_0) + \sum_{k=0}^{N-1} \mathcal{L}_k$ (满足约束条件 $\mathbf{x}_{k+1} = \mathbf{F}_k \mathbf{x}_k + \mathbf{w}_k$) 关于 \mathbf{x}_0 和 \mathbf{w}_k 的驻点。显然, 这是我们前面讨论过的动态约束优化问题。

现在的 Hamilton 函数定义为

$$\mathcal{H}_k = \mathcal{L}_k + 2\epsilon \boldsymbol{\lambda}_{k+1}^T (\mathbf{F}_k \mathbf{x}_k + \mathbf{w}_k) \quad (31)$$

式中, $2\epsilon \boldsymbol{\lambda}_{k+1} (k = 0, \dots, N-1)$ 为时变的拉格朗日乘子。需要注意的是此时拉格朗日乘子由 $\boldsymbol{\lambda}_{k+1}$ 变为了 $2\epsilon \boldsymbol{\lambda}_{k+1}$ 。但这并不改变问题的解, 而只是

利用一个常数对拉格朗日乘子进行了缩放，从而使得问题的数学描述更加简洁。

根据上小节介绍的动态约束优化，不难发现， J 关于 \mathbf{x}_0 和 \mathbf{w}_k 的驻点方程为

$$2\epsilon\boldsymbol{\lambda}_0 + \frac{\partial\psi_0}{\partial\mathbf{x}_0} = 0 \quad (32)$$

$$2\epsilon\boldsymbol{\lambda}_N = 0 \quad (33)$$

$$\frac{\partial\mathcal{H}_k}{\partial\mathbf{w}_k} = 0 \quad (34)$$

$$2\epsilon\boldsymbol{\lambda}_k = \frac{\partial\mathcal{H}_k}{\partial\mathbf{x}_k} \quad (35)$$

由 (32) 式可得

$$\mathbf{x}_0 = \hat{\mathbf{x}}_0 + \mathbf{P}_0 \boldsymbol{\lambda}_0 \quad (36)$$

由 (33) 式可得

$$\boldsymbol{\lambda}_N = 0 \quad (37)$$

由 (34) 式可得

$$\mathbf{w}_k = \mathbf{Q}_k \boldsymbol{\lambda}_{k+1} \quad (38)$$

代入到状态方程 (18), 则有

$$\mathbf{x}_{k+1} = \mathbf{F}_k \mathbf{x}_k + \mathbf{Q}_k \boldsymbol{\lambda}_{k+1} \quad (39)$$

令

$$\theta = \frac{1}{\epsilon} \quad (40)$$

由 (35) 式可导出

$$\lambda_k = F_k^T \lambda_{k+1} + \theta \bar{S}_k (x_k - \hat{x}_k) + H_k^T R_k^{-1} (y_k - H_k x_k) \quad (41)$$

考虑到 $x_0 = \hat{x}_0 + P_0 \lambda_0$, 我们假定

$$x_k = \mu_k + P_k \lambda_k \quad (42)$$

式中, μ_k 和 P_k 待定, 但它们的初值分别由初始估计 $\mu_0 = \hat{x}_0$ 和权重矩阵 P_0 决定。将 (42) 代入 (39), 可以得到

$$\mu_{k+1} + P_{k+1}\lambda_{k+1} = F_k\mu_k + F_kP_k\lambda_k + Q_k\lambda_{k+1} \quad (43)$$

将 (42) 代入 (41), 可得

$$\lambda_k = F_k^T\lambda_{k+1} + \theta\bar{S}_k(\mu_k + P_k\lambda_k - \hat{x}_k) + H_k^TR_k^{-1}[y_k - H_k(\mu_k + P_k\lambda_k)] \quad (44)$$

上式可以进一步整理为

$$\lambda_k = [I - \theta\bar{S}_kP_k + H_k^TR_k^{-1}H_kP_k]^{-1} \times \\ [F_k^T\lambda_{k+1} + \theta\bar{S}_k(\mu_k - \hat{x}_k) + H_k^TR_k^{-1}(y_k - H_k\mu_k)]$$

将上式代入 (43), 可导出

$$\begin{aligned} \mu_{k+1} + P_{k+1}\lambda_{k+1} = & F_k\mu_k + F_kP_k[I - \theta\bar{S}_kP_k + H_k^TR_k^{-1}H_kP_k]^{-1} \times \\ & [F_k^T\lambda_{k+1} + \theta\bar{S}_k(\mu_k - \hat{x}_k) + H_k^TR_k^{-1}(y_k - H_k\mu_k)] + Q_k\lambda_{k+1} \end{aligned}$$

由上式, 可导出

$$\begin{aligned} \mu_{k+1} - F_k\mu_k - F_kP_k[I - \theta\bar{S}_kP_k + H_k^TR_k^{-1}H_kP_k]^{-1} \times \\ [\theta\bar{S}_k(\mu_k - \hat{x}_k) + H_k^TR_k^{-1}(y_k - H_k\mu_k)] = \\ [-P_{k+1} + F_kP_k[I - \theta\bar{S}_kP_k + H_k^TR_k^{-1}H_kP_k]^{-1}F_k^T + Q_k]\lambda_{k+1} \end{aligned} \quad (45)$$

在假设的解式 (42) 中, 我们未对 μ_k 和 P_k 的取值引入任何限制。式 (45) 两边都等于 0, (45) 仍然成立。

令 (45) 左边为 0, 可导出

$$\begin{aligned}\boldsymbol{\mu}_{k+1} = & \mathbf{F}_k \boldsymbol{\mu}_k + \mathbf{F}_k \mathbf{P}_k [\mathbf{I} - \theta \bar{\mathbf{S}}_k \mathbf{P}_k + \mathbf{H}_k^T \mathbf{R}_k^{-1} \mathbf{H}_k \mathbf{P}_k]^{-1} \times \\ & [\theta \bar{\mathbf{S}}_k (\boldsymbol{\mu}_k - \hat{\mathbf{x}}_k) + \mathbf{H}_k^T \mathbf{R}_k^{-1} (\mathbf{y}_k - \mathbf{H}_k \boldsymbol{\mu}_k)]\end{aligned}\quad (46)$$

这是关于 $\boldsymbol{\mu}_k$ 的演化方程, 其初始条件为

$$\boldsymbol{\mu}_0 = \hat{\mathbf{x}}_0 \quad (47)$$

令 (45) 右边为 0, 可导出

$$\begin{aligned}\mathbf{P}_{k+1} = & \mathbf{F}_k \mathbf{P}_k [\mathbf{I} - \theta \bar{\mathbf{S}}_k \mathbf{P}_k + \mathbf{H}_k^T \mathbf{R}_k^{-1} \mathbf{H}_k \mathbf{P}_k]^{-1} \mathbf{F}_k^T + \mathbf{Q}_k \\ = & \mathbf{F}_k \tilde{\mathbf{P}}_k \mathbf{F}_k^T + \mathbf{Q}_k\end{aligned}\quad (48)$$

这是关于 P_k 的演化方程，式中 \tilde{P}_k 的定义为

$$\begin{aligned}\tilde{P}_k &= P_k [I - \theta \bar{S}_k P_k + H_k^T R_k^{-1} H_k P_k]^{-1} \\ &= [P_k^{-1} - \theta \bar{S}_k + H_k^T R_k^{-1} H_k]^{-1}\end{aligned}\quad (49)$$

公式 (49) 表明，如果 P_k 、 S_k 和 R_k 均为对称矩阵，那么 \tilde{P}_k 也是对称矩阵。从 (48) 可以看出，如果 Q_k 也是对称矩阵，则 P_{k+1} 对称。所以如果 P_0 、 Q_k 、 R_k 和 S_k 均为对称矩阵，那么 \tilde{P}_k 和 P_k 也是对称的。

优化目标函数 J 的最优解 x_0 和 w_k 的求解过程可以总结如下:

$$x_0 = \hat{x}_0 + P_0 \lambda_0 \quad (50)$$

$$w_k = Q_k \lambda_{k+1} \quad (51)$$

$$\lambda_k = [I - \theta \bar{S}_k P_k + H_k^T R_k^{-1} H_k P_k]^{-1} \times \\ [F_k^T \lambda_{k+1} + \theta \bar{S}_k (\mu_k - \hat{x}_k) + H_k^T R_k^{-1} (y_k - H_k \mu_k)], \quad \lambda_N = 0 \quad (52)$$

$$P_{k+1} = F_k P_k [I - \theta \bar{S}_k P_k + H_k^T R_k^{-1} H_k P_k]^{-1} F_k^T + Q_k, \quad P_0 = P_0 \quad (53)$$

$$\mu_{k+1} = F_k \mu_k + F_k P_k [I - \theta \bar{S}_k P_k + H_k^T R_k^{-1} H_k P_k]^{-1} \times \\ [\theta \bar{S}_k (\mu_k - \hat{x}_k) + H_k^T R_k^{-1} (y_k - H_k \mu_k)], \quad \mu_0 = \hat{x}_0 \quad (54)$$

2.2 关于 \hat{x}_k 和 y_k 的驻点

假定 x_0 和 w_k 已经取得最大值的前提下, 本小节的问题是寻找 $J = \psi(x_0) + \sum_{k=0}^{N-1} \mathcal{L}_k$ (满足约束条件 $x_{k+1} = F_k x_k + w_k$) 关于 \hat{x}_k 和 y_k 的驻点。根据 (42) 和初始条件 (47), 可以得到

$$\lambda_k = P_k^{-1}(x_k - \mu_k) \quad (55)$$

$$\lambda_0 = P_0^{-1}(x_0 - \hat{x}_0) \quad (56)$$

由此可知

$$\begin{aligned}\|\boldsymbol{\lambda}_0\|_{\boldsymbol{P}_0}^2 &= \boldsymbol{\lambda}_0^T \boldsymbol{P}_0 \boldsymbol{\lambda}_0 \\ &= (\boldsymbol{x}_0 - \hat{\boldsymbol{x}}_0)^T \boldsymbol{P}_0^{-T} \boldsymbol{P}_0 \boldsymbol{P}_0^{-1} (\boldsymbol{x}_0 - \hat{\boldsymbol{x}}_0) \\ &= (\boldsymbol{x}_0 - \hat{\boldsymbol{x}}_0)^T \boldsymbol{P}_0^{-1} (\boldsymbol{x}_0 - \hat{\boldsymbol{x}}_0) \\ &= \|\boldsymbol{x}_0 - \hat{\boldsymbol{x}}_0\|_{\boldsymbol{P}_0^{-1}}^2\end{aligned}$$

因此, 性能指标 (30) 可以改写为

$$\boldsymbol{J} = -\epsilon \|\boldsymbol{\lambda}_0\|_{\boldsymbol{P}_0}^2 + \sum_{k=0}^{N-1} [\|\boldsymbol{x}_k - \hat{\boldsymbol{x}}_k\|_{\bar{\boldsymbol{S}}_k}^2 - \epsilon (\|\boldsymbol{w}_k\|_{\boldsymbol{Q}_k^{-1}}^2 + \|\boldsymbol{y}_k - \boldsymbol{H}_k \boldsymbol{x}_k\|_{\boldsymbol{R}_k^{-1}}^2)] \quad (57)$$

将代 (42) 入上式, 有

$$\begin{aligned} J = & -\epsilon \|\lambda_0\|_{P_0}^2 + \\ & \sum_{k=0}^{N-1} [\|\mu_k + P_k \lambda_k - \hat{x}_k\|_{\bar{S}_k}^2 - \epsilon (\|w_k\|_{Q_k^{-1}}^2 + \|y_k - H_k(\mu_k + P_k \lambda_k)\|_{R_k^{-1}}^2)] \end{aligned} \quad (58)$$

将 (38) 式代入到 $\|w_k\|_{Q_k^{-1}}^2$, 得到

$$\|w_k\|_{Q_k^{-1}}^2 = \lambda_{k+1}^T Q_k^T Q_k^{-1} Q_k \lambda_{k+1} = \lambda_{k+1}^T Q_k \lambda_{k+1} \quad (59)$$

于是, 式 (58) 可以重写为

$$\begin{aligned} J = & -\epsilon \|\lambda_0\|_{P_0}^2 - \epsilon \sum_{k=0}^{N-1} \|\lambda_{k+1}\|_{Q_k}^2 + \\ & \sum_{k=0}^{N-1} [\|\mu_k + P_k \lambda_k - \hat{x}_k\|_{\bar{S}_k}^2 - \epsilon \|\mathbf{y}_k - \mathbf{H}_k(\mu_k + P_k \lambda_k)\|_{R_k^{-1}}^2] \end{aligned} \quad (60)$$

由于 $\lambda_N = 0$, 可以得到如下等式

$$\sum_{k=0}^N \lambda_k^T P_k \lambda_k - \sum_{k=0}^{N-1} \lambda_k^T P_k \lambda_k = 0 \quad (61)$$

上式可以改写为

$$\begin{aligned} 0 &= \lambda_0^T P_0 \lambda_0 + \sum_{k=1}^N \lambda_k^T P_k \lambda_k - \sum_{k=0}^{N-1} \lambda_k^T P_k \lambda_k \\ &= \lambda_0^T P_0 \lambda_0 + \sum_{k=0}^{N-1} \lambda_{k+1}^T P_{k+1} \lambda_{k+1} - \sum_{k=0}^{N-1} \lambda_k^T P_k \lambda_k \\ &= -\epsilon \|\lambda_0\|_{P_0}^2 - \epsilon \sum_{k=0}^{N-1} (\lambda_{k+1}^T P_{k+1} \lambda_{k+1} - \lambda_k^T P_k \lambda_k) \end{aligned}$$

性能指标 (60) 减去上式的零项, 有

$$\begin{aligned}
 J &= \sum_{k=0}^{N-1} [\|\mu_k + P_k \lambda_k - \hat{x}_k\|_{\bar{S}_k}^2 - \epsilon \|y_k - H_k(\mu_k + P_k \lambda_k)\|_{R_k^{-1}}^2] - \\
 &\quad \epsilon \sum_{k=0}^{N-1} \|\lambda_{k+1}\|_{Q_k}^2 + \epsilon \sum_{k=0}^{N-1} (\lambda_{k+1}^T P_{k+1} \lambda_{k+1} - \lambda_k^T P_k \lambda_k) \\
 &= \sum_{k=0}^{N-1} [(\mu_k - \hat{x}_k)^T \bar{S}_k (\mu_k - \hat{x}_k) + 2(\mu_k - \hat{x}_k)^T \bar{S}_k P_k \lambda_k + \\
 &\quad \lambda_k^T P_k \bar{S}_k P_k \lambda_k + \epsilon \lambda_{k+1}^T (P_{k+1} - Q_k) \lambda_{k+1} - \epsilon \lambda_k^T P_k \lambda_k - \\
 &\quad \epsilon (\lambda_k - H_k \mu_k)^T R_k^{-1} (y_k - H_k \mu_k) + \\
 &\quad 2\epsilon (y_k - H_k \mu_k)^T R_k^{-1} H_k P_k \lambda_k - \epsilon \lambda_k^T P_k H_k^T R_k^{-1} H_k P_k \lambda_k] \quad (62)
 \end{aligned}$$

考虑上式中的 $\lambda_{k+1}^T (P_{k+1} - Q_k) \lambda_{k+1}$ 项, 将 P_{k+1} 表达式 (48) 代入其中, 可得

$$\begin{aligned}\lambda_{k+1}^T (P_{k+1} - Q_k) \lambda_{k+1} &= \lambda_{k+1}^T (Q_k + F_k \tilde{P}_k F_k^T - Q_k) \lambda_{k+1} \\ &= \lambda_{k+1}^T F_k \tilde{P}_k F_k^T \lambda_{k+1}\end{aligned}$$

根据 (44) 式, 有

$$F_k^T \lambda_{k+1} = \lambda_k - \theta \bar{S}_k (\mu_k + P_k \lambda_k - \hat{x}_k) + H_k^T R_k^{-1} [y_k - H_k (\mu_k + P_k \lambda_k)] \quad (63)$$

因此

$$\begin{aligned}
 & \lambda_{k+1}^T (P_{k+1} - Q_k) \lambda_{k+1} \\
 = & \{ \lambda_k - \theta \bar{S}_k (\mu_k + P_k \lambda_k - \hat{x}_k) + H_k^T R_k^{-1} [y_k - H_k (\mu_k + P_k \lambda_k)] \}^T \times \\
 & \tilde{P}_k \{ \lambda_k - \theta \bar{S}_k (\mu_k + P_k \lambda_k - \hat{x}_k) + H_k^T R_k^{-1} [y_k - H_k (\mu_k + P_k \lambda_k)] \} \\
 = & \{ \lambda_k^T (I - \theta P_k \bar{S}_k + P_k H_k^T R_k^{-1} H_k) - \theta (\mu_k - \hat{x}_k)^T \bar{S}_k - \\
 & (y_k - H_k \mu_k)^T R_k^{-1} H_k \} \tilde{P}_k \{ \lambda_k^T (I - \theta P_k \bar{S}_k + P_k H_k^T R_k^{-1} H_k) - \\
 & \theta (\mu_k - \hat{x}_k)^T \bar{S}_k - (y_k - H_k \mu_k)^T R_k^{-1} H_k \}^T
 \end{aligned}$$

因为 $(I - \theta P_k \bar{S}_k + P_k H_k^T R_k^{-1} H_k) = P_k \tilde{P}_k^{-1}$, 代入上式中可得

$$\begin{aligned}
 & \lambda_{k+1}^T (P_{k+1} - Q_k) \lambda_{k+1} \\
 &= \{ \lambda_k^T P_k \tilde{P}_k^{-1} - \theta (\mu_k - \hat{x}_k)^T \bar{S}_k - (y_k - H_k \mu_k)^T R_k^{-1} H_k \} \\
 & \tilde{P}_k \{ \lambda_k^T P_k \tilde{P}_k^{-1} - \theta (\mu_k - \hat{x}_k)^T \bar{S}_k - (y_k - H_k \mu_k)^T R_k^{-1} H_k \}^T \\
 &= \lambda_k^T P_k \tilde{P}_k^{-1} P_k \lambda_k - \theta (\mu_k - \hat{x}_k)^T \bar{S}_k P_k \lambda_k - (y_k - H_k \mu_k)^T R_k^{-1} H_k P_k \lambda_k - \\
 & \theta \lambda_k P_k \bar{S}_k (\mu_k - \hat{x}_k) + \theta^2 (\mu_k - \hat{x}_k)^T \bar{S}_k \tilde{P}_k \bar{S}_k (\mu_k - \hat{x}_k) + \\
 & \theta (y_k - H_k \mu_k)^T R_k^{-1} H_k \tilde{P}_k \bar{S}_k (\mu_k - \hat{x}_k) - \lambda_k^T P_k H_k^T R_k^{-1} (y_k - H_k \mu_k) + \\
 & \theta (\mu_k - \hat{x}_k)^T \bar{S}_k \tilde{P}_k H_k^T R_k^{-1} (y_k - H_k \mu_k) + \\
 & (y_k - H_k \mu_k)^T R_k^{-1} H_k \tilde{P}_k H_k^T R_k^{-1} (y_k - H_k \mu_k)
 \end{aligned}$$

这里需要注意的是，上式的结果是一个标量，即等式右边的每一项均为标量。由于是标量，所以有 $\theta(\boldsymbol{\mu}_k - \hat{\mathbf{x}}_k)^T \bar{\mathbf{S}}_k \mathbf{P}_k \boldsymbol{\lambda}_k = \theta \boldsymbol{\lambda}_k^T \mathbf{P}_k \bar{\mathbf{S}}_k (\boldsymbol{\mu}_k - \hat{\mathbf{x}}_k)$ 。因此，上式可以重写为

$$\begin{aligned}
 & \boldsymbol{\lambda}_{k+1}^T (\mathbf{P}_{k+1} - \mathbf{Q}_k) \boldsymbol{\lambda}_{k+1} \\
 &= \boldsymbol{\lambda}_k^T \mathbf{P}_k \tilde{\mathbf{P}}_k^{-1} \mathbf{P}_k \boldsymbol{\lambda}_k - 2\theta(\boldsymbol{\mu}_k - \hat{\mathbf{x}}_k)^T \bar{\mathbf{S}}_k \mathbf{P}_k \boldsymbol{\lambda}_k - \\
 & \quad 2(\mathbf{y}_k - \mathbf{H}_k \boldsymbol{\mu}_k)^T \mathbf{R}_k^{-1} \mathbf{H}_k \mathbf{P}_k \boldsymbol{\lambda}_k + \theta^2 (\boldsymbol{\mu}_k - \hat{\mathbf{x}}_k)^T \bar{\mathbf{S}}_k \tilde{\mathbf{P}}_k \bar{\mathbf{S}}_k (\boldsymbol{\mu}_k - \hat{\mathbf{x}}_k) + \\
 & \quad 2\theta(\boldsymbol{\mu}_k - \hat{\mathbf{x}}_k)^T \bar{\mathbf{S}}_k \tilde{\mathbf{P}}_k \mathbf{H}_k^T \mathbf{R}_k^{-1} (\mathbf{y}_k - \mathbf{H}_k \boldsymbol{\mu}_k) + \\
 & \quad (\mathbf{y}_k - \mathbf{H}_k \boldsymbol{\mu}_k)^T \mathbf{R}_k^{-1} \mathbf{H}_k \tilde{\mathbf{P}}_k \mathbf{H}_k^T \mathbf{R}_k^{-1} (\mathbf{y}_k - \mathbf{H}_k \boldsymbol{\mu}_k)
 \end{aligned} \tag{64}$$

从 (49) 式可以得到

$$\begin{aligned}\tilde{P}_k^{-1} &= [I - \theta \bar{S}_k P_k + H_k^T R_k^{-1} H_k P_k] P_k^{-1} \\ &= P_k^{-1} [I - \theta P_k \bar{S}_k + P_k H_k^T R_k^{-1} H_k]\end{aligned}$$

因此

$$\begin{aligned}\lambda_k^T P_k \tilde{P}_k^{-1} P_k \lambda_k &= \lambda_k^T [I - \theta P_k \bar{S}_k + P_k H_k^T R_k^{-1} H_k] P_k \lambda_k \\ &= \lambda_k^T P_k \lambda_k - \theta \lambda_k^T P_k \bar{S}_k P_k \lambda_k + \lambda_k^T P_k H_k^T R_k^{-1} H_k P_k \lambda_k\end{aligned}$$

将上式代入 (64) 式中, 得到

$$\begin{aligned}
 & \lambda_{k+1}^T (P_{k+1} - Q_k) \lambda_{k+1} \\
 &= \lambda_k^T P_k \lambda_k - \theta \lambda_k^T P_k \bar{S}_k P_k \lambda_k + \lambda_k^T P_k H_k^T R_k^{-1} H_k P_k \lambda_k - \\
 & 2\theta (\mu_k - \hat{x}_k)^T \bar{S}_k P_k \lambda_k - 2(y_k - H_k \mu_k)^T R_k^{-1} H_k P_k \lambda_k + \theta^2 (\mu_k - \hat{x}_k)^T \times \\
 & \bar{S}_k \tilde{P}_k \bar{S}_k (\mu_k - \hat{x}_k) + 2\theta (\mu_k - \hat{x}_k)^T \bar{S}_k \tilde{P}_k H_k^T R_k^{-1} (y_k - H_k \mu_k) + \\
 & (y_k - H_k \mu_k)^T R_k^{-1} H_k \tilde{P}_k H_k^T R_k^{-1} (y_k - H_k \mu_k) \tag{65}
 \end{aligned}$$

将上式代入 (62) 式, 有

$$\begin{aligned}
 \mathbf{J} &= \sum_{k=0}^{N-1} [(\boldsymbol{\mu}_k - \hat{\mathbf{x}}_k)^T \bar{\mathbf{S}}_k (\boldsymbol{\mu}_k - \hat{\mathbf{x}}_k) - \epsilon (\mathbf{y}_k - \mathbf{H}_k \boldsymbol{\mu}_k)^T \mathbf{R}_k^{-1} (\mathbf{y}_k - \mathbf{H}_k \boldsymbol{\mu}_k) + \\
 &\quad \theta (\boldsymbol{\mu}_k - \hat{\mathbf{x}}_k)^T \bar{\mathbf{S}}_k \tilde{\mathbf{P}}_k \bar{\mathbf{S}}_k (\boldsymbol{\mu}_k - \hat{\mathbf{x}}_k) + 2 (\boldsymbol{\mu}_k - \hat{\mathbf{x}}_k)^T \bar{\mathbf{S}}_k \tilde{\mathbf{P}}_k \mathbf{H}_k^T \mathbf{R}_k^{-1} (\mathbf{y}_k - \mathbf{H}_k \boldsymbol{\mu}_k) + \\
 &\quad \epsilon (\mathbf{y}_k - \mathbf{H}_k \boldsymbol{\mu}_k)^T \mathbf{R}_k^{-1} \mathbf{H}_k \tilde{\mathbf{P}}_k \mathbf{H}_k^T \mathbf{R}_k^{-1} (\mathbf{y}_k - \mathbf{H}_k \boldsymbol{\mu}_k)] \\
 &= \sum_{k=0}^{N-1} [(\boldsymbol{\mu}_k - \hat{\mathbf{x}}_k)^T (\bar{\mathbf{S}}_k + \theta \bar{\mathbf{S}}_k \tilde{\mathbf{P}}_k \bar{\mathbf{S}}_k) (\boldsymbol{\mu}_k - \hat{\mathbf{x}}_k) + \\
 &\quad 2 (\boldsymbol{\mu}_k - \hat{\mathbf{x}}_k)^T \bar{\mathbf{S}}_k \tilde{\mathbf{P}}_k \mathbf{H}_k^T \mathbf{R}_k^{-1} (\mathbf{y}_k - \mathbf{H}_k \boldsymbol{\mu}_k) + \\
 &\quad \epsilon (\mathbf{y}_k - \mathbf{H}_k \boldsymbol{\mu}_k)^T (\mathbf{R}_k^{-1} \mathbf{H}_k \tilde{\mathbf{P}}_k \mathbf{H}_k^T \mathbf{R}_k^{-1} - \mathbf{R}_k^{-1}) (\mathbf{y}_k - \mathbf{H}_k \boldsymbol{\mu}_k)]
 \end{aligned}$$

现在我们来回顾本小节的目标: 找出 \mathbf{J} 关于 $\hat{\mathbf{x}}_k$ 和 \mathbf{y}_k 的驻点。利用上

式, 求 \mathbf{J} 关于 $\hat{\mathbf{x}}_k$ 和 \mathbf{y}_k 的偏导数并令其等于零, 可以得到如下方程:

$$\frac{\partial \mathbf{J}}{\partial \hat{\mathbf{x}}_k} = 2(\bar{\mathbf{S}}_k + \theta \bar{\mathbf{S}}_k \tilde{\mathbf{P}}_k \bar{\mathbf{S}}_k)(\hat{\mathbf{x}}_k - \boldsymbol{\mu}_k) + 2\bar{\mathbf{S}}_k \tilde{\mathbf{P}}_k \mathbf{H}_k^T \mathbf{R}_k^{-1}(\mathbf{H}_k \boldsymbol{\mu}_k - \mathbf{y}_k) = 0 \quad (66)$$

$$\begin{aligned} \frac{\partial \mathbf{J}}{\partial \mathbf{y}_k} &= 2\epsilon(\mathbf{y}_k - \mathbf{H}_k \boldsymbol{\mu}_k)^T \left(\mathbf{R}_k^{-1} \mathbf{H}_k \tilde{\mathbf{P}}_k \mathbf{H}_k^T \mathbf{R}_k^{-1} - \mathbf{R}_k^{-1} \right) (\mathbf{y}_k - \mathbf{H}_k \boldsymbol{\mu}_k) + \\ &2\mathbf{R}_k^{-1} \mathbf{H}_k \tilde{\mathbf{P}}_k \bar{\mathbf{S}}_k (\boldsymbol{\mu}_k - \hat{\mathbf{x}}_k) = 0 \end{aligned} \quad (67)$$

当 $\hat{\mathbf{x}}_k = \boldsymbol{\mu}_k$ 以及 $\mathbf{y}_k = \mathbf{H}_k \boldsymbol{\mu}_k$ 时, 上述方程组显然成立。

上述驻点条件是最优的必要条件，为了验证 $\hat{\mathbf{x}}_k = \boldsymbol{\mu}_k$ 是我们所求的最优解，我们可以导出 J 关于 $\hat{\mathbf{x}}_k$ 的二阶导数：

$$\frac{\partial^2 J}{\partial \hat{\mathbf{x}}_k^2} = 2(\bar{\mathbf{S}}_k + \theta \bar{\mathbf{S}}_k \tilde{\mathbf{P}}_k \bar{\mathbf{S}}_k) \quad (68)$$

如果 $(\bar{\mathbf{S}}_k + \theta \bar{\mathbf{S}}_k \tilde{\mathbf{P}}_k \bar{\mathbf{S}}_k) > 0$ ，那么 $\hat{\mathbf{x}}_k$ 为极小值点。通常情况下， $\bar{\mathbf{S}}_k$ 的正定性可以保证，如果 $\tilde{\mathbf{P}}_k$ 正定则 $\hat{\mathbf{x}}_k$ 为极小值点。

根据式中 $\tilde{\mathbf{P}}_k$ 的定义可知， $\hat{\mathbf{x}}_k$ 为极小值点的条件为

$$(\mathbf{P}_k^{-1} - \theta \bar{\mathbf{S}}_k + \mathbf{H}_k^T \mathbf{R}_k^{-1} \mathbf{H}_k)^{-1} > 0$$

等价于

$$(\mathbf{P}_k^{-1} - \theta \bar{\mathbf{S}}_k + \mathbf{H}_k^T \mathbf{R}_k^{-1} \mathbf{H}_k) > 0$$

其中, \mathbf{P}_k^{-1} 、 $\theta \bar{\mathbf{S}}_k$ 和 $\mathbf{H}_k^T \mathbf{R}_k^{-1} \mathbf{H}_k$ 均正定。因此, 为了保证正定性, $\theta \bar{\mathbf{S}}_k$ 应尽可能小。为了使 $\theta \bar{\mathbf{S}}_k$ 变小, 可采用如下 3 种方式:

1) $\theta = 1/\epsilon$ 变小可以使 $\theta \bar{\mathbf{S}}_k$ 变小, 这意味着 (22) 或 (23) 式中定义的性能要求不能太严格。如果性能要求不是很严格, 可以求解; 反之, 则无法求解。

2) \mathbf{L}_k 变小可以使 $\theta \bar{\mathbf{S}}_k$ 变小。这个结论是根据式中 $\bar{\mathbf{S}}_k$ 和 \mathbf{L}_k 的关系得出的。目标函数的分子为 $(\mathbf{x}_k - \hat{\mathbf{x}}_k)^T \mathbf{L}_k^T \mathbf{S}_k \mathbf{L}_k (\mathbf{x}_k - \hat{\mathbf{x}}_k)$ 。 \mathbf{L}_k 变小可以使目标函数的分子变小, 最小化目标函数将变得容易; \mathbf{L}_k 过大可能会导致问题无解。

3) S_k 变小可以使 $\theta \overline{S}_k$ 变小。与上面的结论类似。 S_k 变小可以使目标函数的分子变小，最小化目标函数将变得容易； S_k 过大可能会导致问题无解。

2.3 H_∞ 鲁棒滤波算法小结

总结以上两小节的结果，我们即可建立所谓的 H_∞ 鲁棒滤波算法。

2.3.1 系统模型

考虑如下动态系统及输出方程：

$$\begin{cases} \mathbf{x}_{k+1} = \mathbf{F}_k \mathbf{x}_k + \mathbf{w}_k \\ \mathbf{y}_k = \mathbf{H}_k \mathbf{x}_k + \mathbf{v}_k \\ \mathbf{z}_k = \mathbf{L}_k \mathbf{x}_k \end{cases} \quad (69)$$

式中， \mathbf{w}_k 和 \mathbf{v}_k 分别表示过程噪声和量测噪声，目标是估计状态 \mathbf{x}_k 。

2.3.2 目标函数

选取合适的初始估计及权重矩阵，构造如下目标函数：

$$J_1 = \frac{\sum_{k=0}^{N-1} \|z_k - \hat{z}_k\|_{S_k}^2}{\|x_0 - \hat{x}_0\|_{P_0}^2 + \sum_{k=0}^{N-1} (\|w_k\|_{Q_k}^2 + \|v_k\|_{R_k}^2)} \quad (70)$$

式中，矩阵 P_0 ， Q_k ， R_k 和 S_k 均为正定对称矩阵。

2.3.3 滤波算法

将 $\hat{\mathbf{x}}_k = \boldsymbol{\mu}_k$ 代入 (54), 并令

$$\mathbf{K}_k = \mathbf{P}_k [\mathbf{I} - \theta \overline{\mathbf{S}}_k \mathbf{P}_k + \mathbf{H}_k^T \mathbf{R}_k^{-1} \mathbf{H}_k \mathbf{P}_k]^{-1} \mathbf{H}_k^T \mathbf{R}_k^{-1}$$

可得

$$\hat{\mathbf{x}}_{k+1} = \mathbf{F}_k \hat{\mathbf{x}}_k + \mathbf{F}_k \mathbf{K}_k (\mathbf{y}_k - \mathbf{H}_k \hat{\mathbf{x}}_k), \quad \hat{\mathbf{x}}_0 = \hat{\mathbf{x}}_0$$

考虑到 P_k 的计算公式 (53) 以及 \bar{S}_k 的计算公式 (29), 如下称为 H_∞ 滤波的递推滤波算法使目标函数 J_1 小于 ϵ , 其中 $\theta = 1/\epsilon$.

$$\begin{cases} \hat{x}_{k+1} = F_k \hat{x}_k + F_k K_k (y_k - H_k \hat{x}_k), & \hat{x}_0 = \hat{x}_0 \\ P_{k+1} = F_k P_k [I - \theta \bar{S}_k P_k + H_k^T R_k^{-1} H_k P_k]^{-1} F_k^T + Q_k, & P_0 = P_0 \end{cases} \quad (71)$$

其中:

$$\begin{cases} K_k = P_k [I - \theta \bar{S}_k P_k + H_k^T R_k^{-1} H_k P_k]^{-1} H_k^T R_k^{-1} \\ \bar{S}_k = L_k^T S_k L_k \end{cases} \quad (72)$$

需要注意, H_∞ 滤波能够求解问题的前提条件是: 在每个采样时刻 k , 不等式 $P_k^{-1} - \theta \bar{S}_k + H_k^T R_k^{-1} H_k > 0$ 成立。

3. 卡尔曼滤波的另一种形式

为了比较 H_∞ 滤波与 Kalman 滤波，这里给出卡尔曼滤波的另外一种形式——基于一步预测的 Kalman 滤波算法。

仍然考虑如下线性动态系统：

$$\begin{cases} \mathbf{x}_{k+1} = \mathbf{F}_k \mathbf{x}_k + \mathbf{w}_k \\ \mathbf{y}_{k+1} = \mathbf{H}_{k+1} \mathbf{x}_{k+1} + \mathbf{v}_{k+1} \end{cases} \quad (73)$$

式中： \mathbf{w}_k 和 \mathbf{v}_{k+1} 均为零均值高斯分布白噪声，协方差分别为 \mathbf{Q}_k 和 \mathbf{R}_{k+1} 。

根据 Kalman 滤波理论, 我们有

$$\hat{\mathbf{x}}_{k+1|k} = \mathbf{F}_k \hat{\mathbf{x}}_{k|k} \quad (74)$$

$$\mathbf{P}_{k+1|k} = \mathbf{F}_k \mathbf{P}_{k|k} \mathbf{F}_k^T + \mathbf{Q}_k \quad (75)$$

$$\begin{aligned} \hat{\mathbf{x}}_{k+1|k+1} &= \hat{\mathbf{x}}_{k+1|k} + \mathbf{K}_{k+1}(\mathbf{y}_{k+1} - \mathbf{H}_{k+1} \hat{\mathbf{x}}_{k+1|k}) \\ &= \mathbf{P}_{k|+1k+1} [\mathbf{P}_{k+1|k}^{-1} \hat{\mathbf{x}}_{k+1|k} + \mathbf{H}_{k+1}^T \mathbf{R}_{k+1}^{-1} \mathbf{y}_{k+1}] \end{aligned} \quad (76)$$

其中:

$$\mathbf{P}_{k|+1k+1} = [\mathbf{P}_{k+1|k}^{-1} + \mathbf{H}_{k+1}^T \mathbf{R}_{k+1}^{-1} \mathbf{H}_{k+1}]^{-1} \quad (77)$$

$$\begin{aligned}
\mathbf{K}_{k+1} &= [\mathbf{P}_{k+1|k}^{-1} + \mathbf{H}_{k+1}^T \mathbf{R}_{k+1}^{-1} \mathbf{H}_{k+1}]^{-1} \mathbf{H}_{k+1}^T \mathbf{R}_{k+1}^{-1} \\
&= \mathbf{P}_{k+1|k} [\mathbf{I} + \mathbf{H}_{k+1}^T \mathbf{R}_{k+1}^{-1} \mathbf{H}_{k+1} \mathbf{P}_{k+1|k}]^{-1} \mathbf{H}_{k+1}^T \mathbf{R}_{k+1}^{-1}
\end{aligned} \quad (78)$$

将 (77) 代入 (75), 可知

$$\begin{aligned}
\mathbf{P}_{k+1|k} &= \mathbf{F}_k \mathbf{P}_{k|k} \mathbf{F}_k^T + \mathbf{Q}_k \\
&= \mathbf{F}_k [\mathbf{P}_{k|k-1}^{-1} + \mathbf{H}_k^T \mathbf{R}_k^{-1} \mathbf{H}_k]^{-1} \mathbf{F}_k^T + \mathbf{Q}_k \\
&= \mathbf{F}_k \mathbf{P}_{k|k-1} [\mathbf{I} + \mathbf{H}_k^T \mathbf{R}_k^{-1} \mathbf{H}_k \mathbf{P}_{k|k-1}]^{-1} \mathbf{F}_k^T + \mathbf{Q}_k
\end{aligned} \quad (79)$$

由 (74) 和 (76) 有

$$\hat{\mathbf{x}}_{k+1|k} = \mathbf{F}_k \hat{\mathbf{x}}_{k|k} = \mathbf{F}_k \hat{\mathbf{x}}_{k|k-1} + \mathbf{F}_k \mathbf{K}_k (\mathbf{y}_k - \mathbf{H}_k \hat{\mathbf{x}}_{k|k-1}) \quad (80)$$

综上，一步预测形式的卡尔曼滤波方程可表示为：

$$\hat{\mathbf{x}}_{k+1|k} = \mathbf{F}_k \hat{\mathbf{x}}_{k|k-1} + \mathbf{F}_k \mathbf{K}_k (\mathbf{y}_k - \mathbf{H}_k \hat{\mathbf{x}}_{k|k-1}) \quad (81)$$

$$\mathbf{K}_k = \mathbf{P}_{k|k-1} (\mathbf{I} + \mathbf{H}_k^T \mathbf{R}_k^{-1} \mathbf{H}_k \mathbf{P}_{k|k-1})^{-1} \mathbf{H}_k^T \mathbf{R}_k^{-1} \quad (82)$$

$$\mathbf{P}_{k+1|k} = \mathbf{F}_{k-1} \mathbf{P}_{k|k-1} (\mathbf{I} + \mathbf{H}_k^T \mathbf{R}_k^{-1} \mathbf{H}_k \mathbf{P}_{k|k-1})^{-1} \mathbf{F}_k^T + \mathbf{Q}_k \quad (83)$$

我们知道，卡尔曼滤波算法除了需要知道状态转移矩阵 \mathbf{F}_k 和量测矩阵 \mathbf{H}_k 外，需要知道过程噪声 \mathbf{w}_k 和量测噪声 \mathbf{v}_k 在每一时刻的均值（标准算法中假设为 0）以及协方差矩阵 \mathbf{Q}_k 和 \mathbf{R}_k 。只有当噪声服从高斯分布时，卡尔曼滤波是最小方差估计器；当噪声非高斯分布时，卡尔曼滤波是线性最小方差估计器。

4. H_∞ 滤波和卡尔曼滤波的区别和联系

对比分析 (71)、(72) 和 (81)~(83) 可以发现 H_∞ 滤波算法与卡尔曼滤波算法之间的区别和联系。

- 在 H_∞ 滤波算法中, Q_k 、 R_k 和 P_0 等权重矩阵是设计参数, 需要根据过程扰动 w_k 、量测扰动 v_k 和初始估计误差 $(x_0 - \hat{x}_0)$ 幅度的先验信息事先设置; 而在卡尔曼滤波算法中, 认为 w_k 、 v_k 和 $(x_0 - \bar{x}_0)$ 服从均值为零的高斯分布, Q_k 、 R_k 和 P_0 分别是它们各自已知的协方差矩阵。

- 在 H_∞ 滤波中取 $\mathbf{L}_k = \mathbf{S}_k = \mathbf{I}$ ，对应于对状态变量全体进行估计，同时同等对待所有的估计误差。此时。当取 $\epsilon = +\infty (\theta = 0)$ ， H_∞ 滤波变为卡尔曼滤波。由此可以重新定义卡尔曼滤波，即卡尔曼滤波为式 (70) 表示的性能指标上界为 ∞ 时的 min-max 滤波。尽管卡尔曼滤波能够最小化估计误差方差，但是并不能限制最差情况下的估计误差。因此，卡尔曼滤波不能保证目标函数的界限。
- 卡尔曼滤波和 H_∞ 滤波算法有一个很有趣的区别。如果想利用卡尔曼滤波估计状态的线性组合，与不考虑线性组合情况下是一致的。也就是，如果我们利用卡尔曼滤波估计 $\mathbf{L}_k \mathbf{x}_k$ ，那么结果与我们选择的 \mathbf{L}_k 矩阵无关。然而，当我们使用 H_∞ 滤波时，结果与 \mathbf{L}_k 和我们想要估计的状态组合有很大关系。

- 观察 (71) 和 (72) 式, 当去掉 K_k 和 P_{k+1} 方程中的 $\theta \bar{S}_k P_k$ 项后, H_∞ 滤波算法形式上变为卡尔曼滤波完全一样。
- 在 Kalman 滤波中, 对于未建模的动态系统和噪声, 可以通过增大 Q_k 以改善卡尔曼滤波的鲁棒性。这样做会使得协方差矩阵 $P_{k+1|k}$ 增大, 同时使得卡尔曼滤波增益矩阵 K_k 变大。
- 在 H_∞ 滤波中, 从 (71) 式可以看出, P_{k+1} 等式右边 $(-\theta \bar{S}_k P_k)$ 项相当于变大 P_{k+1} 。类似地, 也会使得矩阵 K_k 变大。

以上分析表明, H_∞ 滤波可以认为是一种鲁棒的卡尔曼滤波。但 P_{k+1} 不再具备估计误差协方差的含义!

5. 小结

H_∞ 滤波算法能够最小化最差情况下的估计误差，可以认为是一种鲁棒的卡尔曼滤波算法。与卡尔曼滤波相比， H_∞ 滤波的优势在于更适合处理系统模型存在不确定性的情况。不难验证， H_∞ 滤波比 Kalman 滤波对于参数的选取要敏感些。

References (参考文献)

- [1] Simon D. Optimal state estimation: Kalman, Hinfinity, and nonlinear approaches[M]. USA: John Wiley & Sons, 2006.
- [2] Lewis F L, Xie L, Popa D. Optimal and robust estimation: with an introduction to stochastic control theory[M]. USA: CRC press, 2017.
- [3] 韩崇昭, 朱洪艳, 段战胜, 等. 多源信息融合 [M]. 北京: 清华大学出版社, 2010.
- [4] Särkkä S. 贝叶斯滤波与平滑 [J]. 北京: 国防工业出版社, 2015.
- [5] Anderson B D O, Moore J B. Optimal filtering[M]. USA: Courier Corporation, 2012.

- [6] Kalman R E. A new approach to linear filtering and prediction problems[J]. Journal of Basic Engineering, 1960, 82(1): 35–45.
- [7] Reif K, Gunther S, Yaz E, et al. Stochastic stability of the discrete-time extended Kalman filter[J]. IEEE Transactions on Automatic Control, 1999, 44(4): 714-728.
- [8] Psiaki M L. Backward-smoothing extended Kalman filter[J]. Journal of Guidance, Control, and Dynamics, 2005, 28(5): 885-894.
- [9] 王小旭, 潘泉, 黄鹤, 等. 非线性系统确定采样型滤波算法综述 [J]. 控制与决策, 2012, 27(6): 801-812.
- [10] Julier S, Uhlmann J, Durrant-Whyte H F. A new method for the nonlinear transformation of means and covariances in filters and estimators[J]. IEEE

Transactions on Automatic Control, 2000, 45(3):477-482.

- [11] Julier S J, Uhlmann J K. Unscented filtering and nonlinear estimation[J]. Proceedings of the IEEE, 2004, 92(3):401-422.
- [12] Kandepu R, Foss B, Imsland L. Applying the unscented Kalman filter for nonlinear state estimation[J]. Journal of Process Control, 2008, 18(7-8):753-768.
- [13] Zhan R, Wan J. Iterated unscented Kalman filter for passive target tracking[J]. IEEE Transactions on Aerospace and Electronic Systems, 2007, 43(3): 1155-1163.
- [14] 廖瑛, 刘光明, 文援兰, 等. 空间非合作目标被动跟踪技术与应用 [M]. 北京: 国防工业出版社, 2015.

- [15] Arasaratnam I, Haykin S. Cubature Kalman filters[J]. IEEE Transactions on Automatic Control, 2009, 54(6): 1254-1269.
- [16] Arasaratnam I, Haykin S. Cubature Kalman smoothers[J]. Automatica, 2011, 47(10): 2245-2250.
- [17] Jia B, Xin M, Cheng Y. High-degree cubature Kalman filter[J]. Automatica, 2013, 49(2): 510-518.
- [18] Arasaratnam I, Haykin S, Hurd T R. Cubature Kalman filtering for continuous-discrete systems: theory and simulations[J]. IEEE Transactions on Signal Processing, 2010, 58(10): 4977-4993.
- [19] Arulampalam M S, Maskell S, Gordon N, et al. A tutorial on particle filters for online nonlinear/non-Gaussian Bayesian tracking[J]. IEEE Transactions

on Signal Processing, 2002, 50(2): 174-188.

- [20] 胡士强, 敬忠良. 粒子滤波算法综述 [J]. 控制与决策, 2005, 20(4): 361-365.
- [21] Carpenter J, Clifford P. Improved particle filter for nonlinear problems[J] . IEE Proceedings-Radar, Sonar and Navigation, 1999, 146(1): 2-7.
- [22] Handschin J E. Monte Carlo techniques for prediction and filtering of non-linear stochastic processes[J]. Automatica, 1970, 6(4): 555-563.
- [23] Dunik J, Straka O, Simandl M, et al. Random-point-based filters: Analysis and comparison in target tracking[J]. IEEE Transactions on Aerospace and Electronic Systems, 2015, 51(2): 1403-1421.
- [24] Alspach D, Sorenson H. Nonlinear Bayesian estimation using Gaussian sum

approximations[J]. IEEE Transactions on Automatic Control, 1972, 17(4): 439-448.

[25] Kotecha J H, Djuric P M. Gaussian sum particle filtering[J]. IEEE Transactions on Signal Processing, 2003, 51(10): 2602-2612.

[26] Gandhi M A, Mili L. Robust Kalman filter based on a generalized maximum-likelihood-type estimator[J]. IEEE Transactions on Signal Processing, 2009, 58(5): 2509-2520.

[27] Xie L, Soh Y C, De Souza C E. Robust Kalman filtering for uncertain discrete-time systems[J]. IEEE Transactions on Automatic Control, 1994, 39(6): 1310-1314.

[28] Chang L, Hu B, Chang G, et al. Huber-based novel robust unscented

Kalman filter[J]. IET Science, Measurement & Technology, 2012, 6(6): 502-509.

[29] Aidala V, Hammel S. Utilization of modified polar coordinates for bearings-only tracking[J]. IEEE Transactions on Automatic Control, 1983, 28(3): 283-294.

[30] Peach N. Bearings-only tracking using a set of range-parameterised extended Kalman filters[J]. IEE Proceedings-Control Theory and Applications, 1995, 142(1): 73-80.

[31] Li X R, Jilkov V P. Survey of maneuvering target tracking. Part I. Dynamic models[J]. IEEE Transactions on Aerospace and Electronic Systems, 2003, 39(4): 1333-1364.

- [32] Li X R, Jilkov V P. Survey of maneuvering target tracking. Part II: Motion models of ballistic and space targets[J]. IEEE Transactions on Aerospace and Electronic Systems, 2010, 46(1): 96-119.
- [33] Li X R, Jilkov V P. Survey of maneuvering target tracking. Part V. Multiple-model methods[J]. IEEE Transactions on Aerospace and Electronic Systems, 2005, 41(4): 1255-1321.



Questions?