

随机最优控制理论

Stochastic Optimal Control Theory

蔡远利 教授

Spring • 2026

西安交通大学 自动化学院

内容大纲

最优性原理

确定性最优控制基础

随机动态规划技术

连续时间 LQG 问题

离散时间 LQG 问题

非线性随机系统次优控制

最优性原理

最优性原理

- 美国理查德·贝尔曼 (Richard Bellman) 教授 1957 年在 *Dynamic Programming* 一书中提出

Principle of Optimality

“An optimal policy has the property that whatever the initial state and initial decision are, the remaining decisions must constitute an optimal policy with respect to the state resulting from the first decision.”

释义

最优策略的任何后段子策略，相对于该段起始状态而言仍然是最优的。
——最优控制中动态规划方法的理论基础。

确定性最优控制基础

连续时间系统模型

- 系统描述:

$$\dot{\mathbf{x}} = \mathbf{g}[\mathbf{x}(t), \mathbf{u}(t), t], \quad \mathbf{x}(t_0) = \mathbf{x}_0 \quad (1)$$

- 性能指标:

$$J = \varphi[\mathbf{x}(t_f), t_f] + \int_{t_0}^{t_f} L[\mathbf{x}(t), \mathbf{u}(t), t] dt \quad (2)$$

- 三种核心方法: 动态规划、变分法、极小值原理

哈密顿-雅可比-贝尔曼 (HJB) 方程

- 定义最优指标:

$$J^*[x(t), t] \triangleq \min_{u(\tau), t \leq \tau \leq t_f} J[x(t), t] \quad (3)$$

- Hamilton 函数:

$$H[x, u, J_x^*, t] = L[x, u, t] + J_x^{*T} g[x, u, t] \quad (4)$$

- HJB 方程:

$$-J_t^* = \min_{u(t)} H[x, u, J_x^*, t] \quad (5)$$

- 边界条件:

$$J^*[x(t_f), t_f] = \varphi[x(t_f), t_f] \quad (6)$$

欧拉-拉格朗日方程

- Hamilton 函数:

$$H[\mathbf{x}, u, \boldsymbol{\lambda}, t] = L[\mathbf{x}, u, t] + \boldsymbol{\lambda}^T(t) \mathbf{g}(\mathbf{x}, u, t) \quad (7)$$

- 协态方程:

$$\dot{\boldsymbol{\lambda}}(t) = -\frac{\partial H}{\partial \mathbf{x}}, \quad \boldsymbol{\lambda}(t_f) = -\frac{\partial \varphi}{\partial \mathbf{x}(t_f)} \quad (8)$$

- 控制方程 (无约束时):

$$\frac{\partial H}{\partial u} = 0 \quad (9)$$

以上为最优解的必要条件。充分条件需 $\delta^2 J > 0$ 。

当 $u(t)$ 存在容许集 $\mathcal{U}$ (约束集) 时, 边界处 $\partial H / \partial u = 0$ 不再成立。

$$u^*(t) = \arg \min_{u(t) \in \mathcal{U}} H[\mathbf{x}(t), u(t), \boldsymbol{\lambda}(t), t] \quad (10)$$

$$\dot{\boldsymbol{\lambda}}(t) = -\frac{\partial H}{\partial \mathbf{x}}, \quad \boldsymbol{\lambda}(t_f) = -\frac{\partial \varphi}{\partial \mathbf{x}(t_f)} \quad (11)$$

- 本质: 一个两点边值问题 (TPBVP)

连续时间 LQR 问题

系统与性能指标:

$$\dot{\mathbf{x}} = A(t)\mathbf{x} + B(t)\mathbf{u}, \quad \mathbf{x}(t_0) = \mathbf{x}_0 \quad (12)$$

$$J = \frac{1}{2}\mathbf{x}^T(t_f)S_f\mathbf{x}(t_f) + \frac{1}{2}\int_{t_0}^{t_f} (\mathbf{x}^T Q \mathbf{x} + \mathbf{u}^T R \mathbf{u}) dt \quad (13)$$

其中 $S_f \geq 0$, $Q \geq 0$, $R > 0$ 为对称加权矩阵。

LQR 最优解

- 最优控制:

$$\mathbf{u}^*(t) = -R^{-1}B^T P(t)\mathbf{x}(t) \quad (14)$$

- 矩阵 Riccati 微分方程:

$$\dot{P} + PA + A^T P - PBR^{-1}B^T P + Q = 0, \quad P(t_f) = S_f \quad (15)$$

- 最优指标:

$$J^*[\mathbf{x}_0, t_0] = \frac{1}{2}\mathbf{x}_0^T P(t_0)\mathbf{x}_0 \quad (16)$$

应用：拦截与交会——问题描述

简化运动模型（以初始视线为参考基准）：

$$\dot{v} = a(t), \quad \dot{y} = v \quad (17)$$

$$J = \frac{1}{2} (c_1 v^2 + c_2 y^2)_{t=t_f} + \frac{1}{2} \int_{t_0}^{t_f} a^2 dt \quad (18)$$

其中 y 为横向偏差， v 为横向速度， a 为横向加速度控制量； c_1, c_2 为终端加权系数。

写为 LQR 标准形式：

$$x = \begin{bmatrix} v \\ y \end{bmatrix}, \quad A = \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix}, \quad B = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad S_f = \begin{bmatrix} c_1 & 0 \\ 0 & c_2 \end{bmatrix}, \quad Q = 0, \quad R = 1$$

应用：拦截与交会——Riccati 方程求解

Riccati 方程 $\dot{P} + PA + A^T P - PBB^T P = 0$, $P(t_f) = S_f$ 。设 $P = \begin{bmatrix} p_{11} & p_{12} \\ p_{12} & p_{22} \end{bmatrix}$, 得

$$\dot{p}_{11} = p_{11}^2 - 2p_{12}, \quad p_{11}(t_f) = c_1$$

$$\dot{p}_{12} = p_{11}p_{12} - p_{22}, \quad p_{12}(t_f) = 0$$

$$\dot{p}_{22} = p_{12}^2, \quad p_{22}(t_f) = c_2$$

由 $u^* = -B^T P x$ 得 $a^* = -p_{11}v - p_{12}y$ 。记 $t_{go} = t_f - t$, 解为

$$\Lambda_v = p_{11} = \frac{c_2^{-1} + c_1^{-1}t_{go}^2 + t_{go}^3/3}{\Delta}, \quad \Lambda_y = p_{12} = \frac{c_1^{-1}t_{go} + t_{go}^2/2}{\Delta}$$

$$\Delta = (c_2^{-1} + t_{go}^3/3)(c_1^{-1} + t_{go}) - t_{go}^4/4$$

应用：拦截与交会——拦截问题

$c_1 \rightarrow 0$ (对终端速度不作要求), 且 $c_2 \rightarrow \infty$ ($y(t_f) \rightarrow 0$)

$$a(t) = -\frac{3}{t_{go}}v(t) - \frac{3}{t_{go}^2}y(t) \quad (19)$$

在小角近似下, $y \approx r\sigma$ 、 $v \approx V\sigma$, 则

$$a(t) \approx -3V\dot{\sigma} \quad (20)$$

此即拦截问题中的**比例导引** (PNG), 最优导航系数 $N = 3$; 工程中通常取 $3 \sim 5$ 。

应用：拦截与交会——交会问题

$c_1, c_2 \rightarrow \infty$ ($v(t_f) \rightarrow 0, y(t_f) \rightarrow 0$, 即交会问题)

$$a(t) = -\frac{4}{t_{go}}v(t) - \frac{6}{t_{go}^2}y(t) \quad (21)$$

也可写为

$$a(t) = -V\left(4\dot{\sigma} + \frac{2\sigma}{t_{go}}\right) \quad (22)$$

此为交会问题的变形比例导引。

- 可将标量 v, y, a 替换为向量，得到三维拦截律

微分对策——发展历程与基本思想

- 微分对策 (Differential Game) 由美国数学家 Rufus Isaacs 于 20 世纪 50 年代在兰德公司研究空间追逃问题时创立
- 将经典博弈论的思想引入连续时间动态系统，形成**双边最优控制**理论框架
- 与最优控制的关系：单边控制 → 双边对抗
- 与博弈论的关系：静态策略 → 动态连续时间策略
- 后续 Berkovitz、Fleming 等学者奠定了其数学基础
- 本节聚焦**零和微分对策** (两人零和、完全信息)

微分对策——基本特征与分类

核心特征

- 两个（或多个）决策方，各自优化自身性能指标
- 系统动态由微分方程描述，策略是时间的函数

典型分类

- **零和 / 非零和**：总收益是否恒定
- **完全信息 / 不完全信息**：是否知晓彼此的目标与动态
- **合作 / 非合作**：可否达成有约束力的协议

微分对策——系统模型与性能指标

一般形式系统模型（双方对抗）：

$$\dot{x} = f(x, u, v, t), \quad x(t_0) = x_0 \quad (23)$$

• $u(t)$ ：极小化者（追逐方）控制 $v(t)$ ：极大化者（逃逸方）控制

零和性能指标：

$$J = \phi(x(t_f)) + \int_{t_0}^{t_f} L(x, u, v, t) dt \quad (24)$$

极小化方追求 $\min_u J$ ，极大化方追求 $\max_v J$ 。信息结构可分为开环、反馈与闭环。

微分对策——鞍点均衡

鞍点 (Saddle Point)

策略对 (u^*, v^*) 构成鞍点, 当且仅当:

$$J(u^*, v) \leq J(u^*, v^*) \leq J(u, v^*) \quad (25)$$

此时极小-极大与极大-极小等价:

$$\min_u \max_v J = \max_v \min_u J = J(u^*, v^*) \quad (26)$$

- 鞍点均衡是零和微分对策中最重要的解概念
- 鞍点存在性依赖于信息结构和系统特性

微分对策——HJI 方程

定义值函数 (Value Function):

$$V(\mathbf{x}, t) = \min_u \max_v \left\{ \phi(\mathbf{x}(t_f)) + \int_t^{t_f} L \, d\tau \right\} \quad (27)$$

Hamilton-Jacobi-Isaacs (HJI) 方程

$$-\frac{\partial V}{\partial t} = \min_u \max_v \left[L(\mathbf{x}, u, v, t) + \left(\frac{\partial V}{\partial \mathbf{x}} \right)^T f(\mathbf{x}, u, v, t) \right] \quad (28)$$

终端条件: $V(\mathbf{x}, t_f) = \phi(\mathbf{x}(t_f))$

- HJI 方程是 HJB 方程在双边对抗下的推广
- 一般情形需数值求解; **线性二次型 (LQ) 情形**有解析解

微分对策——LQ 问题描述与 Riccati 方程

线性系统与二次型代价:

$$\dot{x} = Ax + Bu + Cv$$

$$J = \frac{1}{2}x^T(t_f)Fx(t_f) + \frac{1}{2} \int (u^T R_u u - v^T R_v v + x^T Q x) dt$$

值函数取二次型 $V = \frac{1}{2}x^T P(t)x$, 代入 HJI 方程:

$$-\dot{P} = PA + A^T P + Q - PBR_u^{-1}B^T P + PCR_v^{-1}C^T P \quad (29)$$

终端条件 $P(t_f) = F$ (Riccati 型微分方程)

微分对策——LQ 最优策略与鞍点条件

求解 Riccati 方程得到 $P(t)$ 后, 双方最优策略为:

$$u^* = -R_u^{-1} B^T P(t) x \quad (\text{极小化方}) \quad (30)$$

$$v^* = R_v^{-1} C^T P(t) x \quad (\text{极大化方}) \quad (31)$$

鞍点存在的充分条件

Riccati 方程在 $[t_0, t_f]$ 上有界解, 且 $R_u > 0$, $R_v > 0$ 。此时 (u^*, v^*) 构成唯一鞍点均衡。

- 注意符号差异: 极大化方的 R_v 项在哈密顿量中符号为负

应用实例：空间追逃博弈——问题描述

空间追逃博弈：追逐方 p 与逃逸方 e

$$\dot{\mathbf{v}}_p = \mathbf{g}_p + \mathbf{a}_p, \quad \dot{\mathbf{r}}_p = \mathbf{v}_p, \quad \dot{\mathbf{v}}_e = \mathbf{g}_e + \mathbf{a}_e, \quad \dot{\mathbf{r}}_e = \mathbf{v}_e$$

距离远小于地心距，引力差可忽略。性能指标 (min-max 问题):

$$J = \frac{b}{2} \|\mathbf{r}_p - \mathbf{r}_e\|_{t_f}^2 + \frac{1}{2} \int_0^{t_f} (c_p^{-1} \mathbf{a}_p^T \mathbf{a}_p - c_e^{-1} \mathbf{a}_e^T \mathbf{a}_e) dt \quad (32)$$

- 追逐方 $\mathbf{a}_p$: **极小化** J
- 逃逸方 $\mathbf{a}_e$: **极大化** J

应用实例——求解思路

构造相对运动状态 $\mathbf{x} = \mathbf{r}_p - \mathbf{r}_e$, $\mathbf{v} = \mathbf{v}_p - \mathbf{v}_e$:

$$\dot{\mathbf{x}} = \mathbf{v}, \quad \dot{\mathbf{v}} = \mathbf{a}_p - \mathbf{a}_e$$

$$J = \frac{b}{2} \|\mathbf{x}(t_f)\|^2 + \frac{1}{2} \int (c_p^{-1} \mathbf{a}_p^T \mathbf{a}_p - c_e^{-1} \mathbf{a}_e^T \mathbf{a}_e) dt$$

应用极小(大)值原理, 构造 Hamilton 函数:

$$H = \frac{1}{2} (c_p^{-1} \mathbf{a}_p^T \mathbf{a}_p - c_e^{-1} \mathbf{a}_e^T \mathbf{a}_e) + \boldsymbol{\lambda}_x^T \mathbf{v} + \boldsymbol{\lambda}_v^T (\mathbf{a}_p - \mathbf{a}_e) \quad (33)$$

应用实例——最优性条件

最优性条件：

$$\partial H / \partial \mathbf{a}_p = 0 \Rightarrow \mathbf{c}_p^{-1} \mathbf{a}_p + \boldsymbol{\lambda}_v = 0$$

$$\partial H / \partial \mathbf{a}_e = 0 \Rightarrow -\mathbf{c}_e^{-1} \mathbf{a}_e - \boldsymbol{\lambda}_v = 0$$

由于 $\mathbf{a}_p$ 和 $\mathbf{a}_e$ 分别出现在 $\pm \boldsymbol{\lambda}_v$ 项中，可得双方最优策略关系：

$$\mathbf{a}_p = -\mathbf{c}_p \boldsymbol{\lambda}_v, \quad \mathbf{a}_e = \mathbf{c}_e \boldsymbol{\lambda}_v \quad (34)$$

即追逐方与逃逸方的最优控制方向相反、幅值受各自能量加权系数调节。

应用实例——最优策略

求解协态方程并与终端条件联立，可得双方最优控制策略：

$$a_p = \frac{-c_p(t_f - t)[r_p - r_e + (v_p - v_e)(t_f - t)]}{1/b + (c_p - c_e)(t_f - t)^3/3} \quad (35)$$

$$a_e = \frac{c_e}{c_p} a_p \quad (36)$$

当 $b \rightarrow \infty$ （精确拦截）时简化为

$$a_p = \frac{-3[r_p - r_e + (v_p - v_e)(t_f - t)]}{(1 - c_e/c_p)(t_f - t)^2} \quad (37)$$

$$a_p^\perp = \frac{3}{1 - c_e/c_p} V \dot{\sigma} \quad (38)$$

应用实例——有效导引系数

侧向最优控制：

$$a_p^\perp = \frac{3}{1 - c_e/c_p} V \dot{\sigma} \quad (39)$$

定义**有效导引系数（有效导航比）**

$$N \triangleq \frac{3}{1 - c_e/c_p} \quad (40)$$

特例分析：

- $c_e = 0$ （目标不机动）： $N = 3$ ，退化为经典比例导引
- $c_e/c_p = 2/5$ ： $N = 5$ ；工程中通常取 $N = 3 \sim 5$ ，与经验一致

结论：微分对策理论解释了比例导引中导航系数 $3 \sim 5$ 的取值依据。

离散时间最优控制

系统模型:

$$\mathbf{x}_{k+1} = \mathbf{g}(\mathbf{x}_k, \mathbf{u}_k), \quad k = 0, \dots, N-1 \quad (41)$$

性能指标:

$$J_0(\mathbf{x}_0) = \varphi(\mathbf{x}_N, N) + \sum_{k=0}^{N-1} L_k(\mathbf{x}_k, \mathbf{u}_k) \quad (42)$$

贝尔曼方程:

$$J_k^*(\mathbf{x}_k) = \min_{\mathbf{u}_k} [L_k(\mathbf{x}_k, \mathbf{u}_k) + J_{k+1}^*(\mathbf{x}_{k+1})] \quad (43)$$

边界条件: $J_N^*(\mathbf{x}_N) = \varphi(\mathbf{x}_N, N)$

离散 LQR 问题

系统与指标:

$$\mathbf{x}_{k+1} = A_k \mathbf{x}_k + B_k \mathbf{u}_k, \quad \mathbf{x}_0 \text{ 给定} \quad (44)$$

$$J_0 = \frac{1}{2} \mathbf{x}_N^T S_N \mathbf{x}_N + \frac{1}{2} \sum_{k=0}^{N-1} (\mathbf{x}_k^T Q_k \mathbf{x}_k + \mathbf{u}_k^T R_k \mathbf{u}_k) \quad (45)$$

- 最优控制:

$$\mathbf{u}_k^* = -K_k \mathbf{x}_k, \quad K_k = (R_k + B_k^T P_{k+1} B_k)^{-1} B_k^T P_{k+1} A_k \quad (46)$$

- 离散 Riccati 方程:

$$P_k = Q_k + K_k^T R_k K_k + (A_k + B_k K_k)^T P_{k+1} (A_k + B_k K_k), \quad P_N = S_N \quad (47)$$

数值解法分类

间接法

- 极小值原理 $\rightarrow$ TPBVP
- 打靶法、拟线性化、配置法
- 缺点：协态初值难猜、收敛域小

直接法


- 泛函优化 $\rightarrow$ 数学规划
- 梯度法、伪谱法
- 不需求解协态方程

智能优化方法：遗传算法、模拟退火、粒子群、蚁群等

粒子群优化算法——基本原理

核心思想——模拟鸟群/鱼群寻找食物的协同行为

- 将搜索空间中的候选解看作一群**粒子**，每个粒子同时跟踪自身历史最优和群体最优
- 适用于**非凸、不可导**目标函数的随机优化
- 每个粒子有位置 x_i 和速度 v_i
- 个体最优 p_i 表示该粒子自身经历过的最优位置
- 全局最优 g 表示整个种群到目前为止发现的最优位置



搜索空间中的粒子群

粒子群优化算法——速度更新机制

标准 PSO 的更新公式：

$$\begin{aligned}v_i(t+1) &= wv_i(t) + c_1r_1[p_i - x_i(t)] + c_2r_2[g - x_i(t)] \\x_i(t+1) &= x_i(t) + v_i(t+1)\end{aligned}$$

其中 $r_1, r_2 \sim U(0, 1)$ 为随机数。

三项分量的物理意义

- **惯性项** $wv_i(t)$ ：维持原有搜索方向，平衡全局与局部搜索
- **认知项** $c_1r_1(p_i - x_i)$ ：向自身历史最优学习， c_1 为认知系数
- **社会项** $c_2r_2(g - x_i)$ ：向种群最优学习， c_2 为社会系数

粒子群优化算法——参数取值经验

经验取值建议

- 惯性权重 w : 通常取 $0.4 \sim 0.9$, 可随迭代递减以从全局搜索过渡到局部收敛
- 认知系数 c_1 : 常见取值 $1.5 \sim 2.0$, 强调粒子自身历史经验
- 社会系数 c_2 : 常见取值 $1.5 \sim 2.0$, 强调群体协作与全局信息
- 经验组合: $w = 0.9, c_1 = c_2 = 2.0$ 是常用默认配置

参数调整提示

- 增大 w 有助于全局搜索, 减小 w 有助于局部收敛
- 若解振荡, 可适当减小 c_1, c_2 ; 若收敛过慢, 可适当增大

粒子群优化算法——算法流程

1. 初始化粒子群：随机生成每个粒子的位置 $x_i(0)$ 和速度 $v_i(0)$
2. 评估适应度：计算每个粒子的目标函数值 $f(x_i)$
3. 更新个体最优：若 $f(x_i) < f(p_i)$ 则 $p_i = x_i$
4. 更新全局最优： $g = \arg \min_i f(p_i)$
5. 更新速度与位置：按速度公式和位置公式更新所有粒子
6. 若满足终止条件（最大迭代次数或精度），输出 g ；否则转步骤 2

粒子群优化算法——在最优控制中的应用

PSO 方法在最优控制数值求解中的典型应用：

- **控制器参数优化**：对 LQR、PID 等控制器的参数进行整定
- **最优控制直接法替代**：用 PSO 代替梯度型 NLP 求解器，直接优化控制量参数化后的数学规划问题
- **混合策略**：PSO 全局搜索 + 局部精化（如与伪谱法结合）

与传统方法的对比

- 优点：不需求梯度/协态，对初值不敏感，易并行
- 缺点：计算量大，无严格收敛保证，高维问题性能下降

随机动态规划技术

离散时间随机系统模型

系统描述:

$$\mathbf{x}_{k+1} = \mathbf{g}_k(\mathbf{x}_k, \mathbf{u}_k) + \mathbf{G}_k \mathbf{w}_k \quad (48)$$

其中 $\mathbf{w}_k$ 为白噪声序列。完全状态信息假设 ($\mathbf{x}_k$ 准确可测)。

性能指标 (随机变量):

$$J_i(\mathbf{x}_i) = \phi(N, \mathbf{x}_N) + \sum_{k=i}^{N-1} L_k(\mathbf{x}_k, \mathbf{u}_k) \quad (49)$$

目标: 选取控制序列 $\{\mathbf{u}_i, \dots, \mathbf{u}_{N-1}\}$ 最小化期望代价。

期望代价与条件期望

两种期望代价的定义：

$$j_i(\mathbf{x}_i) = E[J_i(\mathbf{x}_i)] \quad (\text{全期望代价}) \quad (50)$$

$$\bar{j}_i(\mathbf{x}_i) = E[J_i(\mathbf{x}_i) \mid \mathbf{x}_i] \quad (\text{条件期望代价}) \quad (51)$$

由全期望公式（塔性质）：

$$j_i(\mathbf{x}_i) = E_{\mathbf{x}_i}[\bar{j}_i(\mathbf{x}_i)] \quad (52)$$

可以证明（Åström, 1970），最小化顺序可交换：

$$j_i^*(\mathbf{x}_i) = \min_{u_k} j_i(\mathbf{x}_i) = E_{\mathbf{x}_i}[\bar{j}_i^*(\mathbf{x}_i)] \quad (53)$$

即先求解每个 $\mathbf{x}_i$ 下的最优条件期望代价，再对外层状态求期望。

代价的递推分解

将代价函数分解为当前步代价与未来代价：

$$J_k(\mathbf{x}_k) = L_k(\mathbf{x}_k, \mathbf{u}_k) + J_{k+1}(\mathbf{x}_{k+1}) \quad (54)$$

对 $\mathbf{x}_{k+1}$ 取条件期望：

$$\begin{aligned} E[J_k(\mathbf{x}_k) \mid \mathbf{x}_{k+1}] \\ = E[L_k(\mathbf{x}_k, \mathbf{u}_k) \mid \mathbf{x}_{k+1}] + E[J_{k+1}(\mathbf{x}_{k+1}) \mid \mathbf{x}_{k+1}] \end{aligned} \quad (55)$$

$$= L_k(\mathbf{x}_k, \mathbf{u}_k) + \bar{J}_{k+1}(\mathbf{x}_{k+1}) \quad (56)$$

其中 $L_k(\mathbf{x}_k, \mathbf{u}_k)$ 在给定 $\mathbf{x}_k$ 后为确定性函数。

随机贝尔曼方程的推导

根据最优性原理, $k+1$ 步采用最优策略, 故:

$$E[J_k(\mathbf{x}_k) | \mathbf{x}_{k+1}] = L_k(\mathbf{x}_k, \mathbf{u}_k) + \bar{J}_{k+1}^*(\mathbf{x}_{k+1}) \quad (57)$$

利用贝叶斯法则对 $\mathbf{x}_{k+1}$ 取期望:

$$\bar{J}_k(\mathbf{x}_k) = L_k(\mathbf{x}_k, \mathbf{u}_k) + E_{\mathbf{x}_{k+1}} [\bar{J}_{k+1}^*(\mathbf{x}_{k+1})] \quad (58)$$

再次应用最优性原理 (对 $\mathbf{u}_k$ 极小化):

$$\boxed{\bar{J}_k^*(\mathbf{x}_k) = \min_{\mathbf{u}_k} \left\{ L_k(\mathbf{x}_k, \mathbf{u}_k) + E_{\mathbf{x}_{k+1}} [\bar{J}_{k+1}^*(\mathbf{x}_{k+1})] \right\}} \quad (59)$$

——离散时间随机贝尔曼方程

随机贝尔曼方程——紧凑形式与边界

由于 L_k 是确定性的，可将其移入期望算子内部：

$$\bar{J}_k^*(\mathbf{x}_k) = \min_{u_k} E_{\mathbf{x}_{k+1}} \left\{ L_k(\mathbf{x}_k, u_k) + \bar{J}_{k+1}^*(\mathbf{x}_{k+1}) \right\} \quad (60)$$

边界条件（终端时刻 $k = N$ ，无需决策）：

$$\bar{J}_N^*(\mathbf{x}_N) = \phi(N, \mathbf{x}_N) \quad (61)$$

与确定性贝尔曼方程的区别

- 确定性： $J_k^*(\mathbf{x}_k) = \min_{u_k} [L_k + J_{k+1}^*(\mathbf{x}_{k+1})]$
- 随机性：需对噪声 w_k 的分布计算条件期望 $E_{\mathbf{x}_{k+1}} \{\cdot\}$

伊藤随机微分方程简介

标量伊藤 (Itô) 随机微分方程 (SDE):

$$dx = a(x, u, t) dt + \sigma(x, u, t) dw \quad (62)$$

其中 $dw \sim \mathcal{N}(0, dt)$ 为维纳过程 (Wiener process) 增量。

与确定性系统的关键区别:

- 伊藤引理 (Itô's Lemma) 替代普通链式法则
- 代价函数的期望动态中包含二阶扩散项 $(\partial^2 / \partial x^2) \sigma^2$
- 随机 HJB 方程由此导出

标量系统随机 HJB 方程

标量随机系统:

$$\dot{x} = a(x, u, t) + w, \quad w(t) \sim \mathcal{N}(0, \sigma^2) \quad (63)$$

期望代价:

$$j(t_0) = E\{J[x(t_0), t_0]\} \quad (64)$$

由伊藤引理与最优性原理可导出**随机 HJB 方程**:

$$-\frac{\partial \bar{J}^*}{\partial t} = \min_{u(t)} \left[L + \frac{\partial \bar{J}^*}{\partial x} a + \frac{1}{2} \frac{\partial^2 \bar{J}^*}{\partial x^2} \sigma^2 \right] \quad (65)$$

与确定性 HJB 相比, 增加了扩散项 $\frac{1}{2} \bar{J}_{xx}^* \sigma^2$ 。

向量随机系统 HJB 方程

对于向量系统 $\dot{x} = A(x, u, t) + Gw$, $w \sim \mathcal{N}(0, Q')$, 随机 HJB 方程推广为:

$$-\frac{\partial \bar{J}^*}{\partial t} = \min_{u(t)} \left[L + \left(\frac{\partial \bar{J}^*}{\partial x} \right)^T A + \frac{1}{2} \text{tr} \left(\frac{\partial^2 \bar{J}^*}{\partial x^2} G Q' G^T \right) \right] \quad (66)$$

- 扩散项为 $\frac{1}{2} \text{tr}(\bar{J}_{xx}^* G Q' G^T)$, 源于伊藤引理
- 当 $G = 0$ 时退化为确定性 HJB 方程
- 求解一般 HJB 方程非常困难, 需借助数值方法或机器学习

连续时间 LQG 问题

问题描述

系统:

$$\dot{\mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{u} + \mathbf{G}\mathbf{w}, \quad \mathbf{w}(t) \sim \mathcal{N}(0, \mathbf{Q}') \quad (67)$$

初始状态:

$$\mathbf{x}(t_0) \sim \mathcal{N}(\bar{\mathbf{x}}_0, \mathbf{P}_0)$$

性能指标:

$$J = \frac{1}{2} \mathbf{x}^T(T) \mathbf{S}_T \mathbf{x}(T) + \frac{1}{2} \int_{t_0}^T (\mathbf{x}^T \mathbf{Q} \mathbf{x} + \mathbf{u}^T \mathbf{R} \mathbf{u}) dt \quad (68)$$

目标: 求解 $\mathbf{u}^*(t)$ 最小化期望代价 $j(t_0) = E[J]$

由随机 HJB 方程导出柯尔莫哥洛夫方程：

$$-\bar{J}_t^* = \frac{1}{2} \mathbf{x}^T \mathbf{Q} \mathbf{x} - \frac{1}{2} (\bar{J}_x^*)^T \mathbf{B} \mathbf{R}^{-1} \mathbf{B}^T \bar{J}_x^* + (\bar{J}_x^*)^T \mathbf{A} \mathbf{x} + \frac{1}{2} \text{tr}(\bar{J}_{xx}^* \mathbf{G} \mathbf{Q}' \mathbf{G}^T) \quad (69)$$

试凑解 $\bar{J}^* = \frac{1}{2} [\mathbf{x}^T \mathbf{S} \mathbf{x} + \text{tr} \int_t^T \mathbf{S} \mathbf{G} \mathbf{Q}' \mathbf{G}^T d\tau]$ ：

$$-\dot{\mathbf{S}} = \mathbf{A}^T \mathbf{S} + \mathbf{S} \mathbf{A} - \mathbf{S} \mathbf{B} \mathbf{R}^{-1} \mathbf{B}^T \mathbf{S} + \mathbf{Q}, \quad \mathbf{S}(T) = \mathbf{S}_T \quad (70)$$

最优控制：

$$\mathbf{u}^*(t) = -\mathbf{R}^{-1} \mathbf{B}^T \mathbf{S} \mathbf{x}(t) = -\mathbf{K}(t) \mathbf{x}(t) \quad (71)$$

最优性能评估

闭环系统:

$$\dot{x} = (A - BK)x + Gw \quad (72)$$

均方状态满足 Lyapunov 方程:

$$\dot{X} = (A - BK)X + X(A - BK)^T + GQ'G^T \quad (73)$$

$$X(t_0) = P_0 + \bar{x}_0 \bar{x}_0^T \quad (74)$$

控制信号的均方值:

$$E[uu^T] = KXK^T \quad (75)$$

非完全状态信息与分离原理

量测方程:

$$z = Hx + v, \quad v(t) \sim \mathcal{N}(0, R') \quad (76)$$

分离原理 (确定性等价原理)

非完全状态信息下 LQG 问题的最优解 = 确定性 LQR 最优控制 + 卡尔曼滤波器, 即 $u^*(t) = -K(t)\hat{x}(t)$, 其中 $\hat{x}(t)$ 为卡尔曼滤波给出的最优状态估计。

分离原理——推导要点 i

设连续时间线性系统与量测：

$$\dot{\mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{u} + \mathbf{G}\mathbf{w}, \quad \mathbf{z} = \mathbf{H}\mathbf{x} + \mathbf{v}$$

记估计与误差： $\hat{\mathbf{x}}$ 为滤波器给出估计， $\tilde{\mathbf{x}} = \mathbf{x} - \hat{\mathbf{x}}$ 。误差动力学为：

$$\dot{\tilde{\mathbf{x}}} = (\mathbf{A} - \mathbf{L}\mathbf{H})\tilde{\mathbf{x}} + \mathbf{G}\mathbf{w} - \mathbf{L}\mathbf{v}.$$

考虑二次型期望代价 $J = E[\frac{1}{2}\mathbf{x}(T)^T \mathbf{S}_T \mathbf{x}(T) + \frac{1}{2} \int (\mathbf{x}^T \mathbf{Q} \mathbf{x} + \mathbf{u}^T \mathbf{R} \mathbf{u}) dt]$ ，将 $\mathbf{x} = \hat{\mathbf{x}} + \tilde{\mathbf{x}}$ 代入并取期望，得到

$$E[\mathbf{x}^T \mathbf{Q} \mathbf{x}] = E[\hat{\mathbf{x}}^T \mathbf{Q} \hat{\mathbf{x}}] + E[\tilde{\mathbf{x}}^T \mathbf{Q} \tilde{\mathbf{x}}] + 2E[\hat{\mathbf{x}}^T \mathbf{Q} \tilde{\mathbf{x}}].$$

分离原理——推导要点 ii

对于卡尔曼滤波器有正交性 $E[\hat{\mathbf{x}}(t)\tilde{\mathbf{x}}(t)^T] = 0$, 故交叉项为零, 于是

$$J = E\left[\frac{1}{2}\hat{\mathbf{x}}(T)^T S_T \hat{\mathbf{x}}(T) + \frac{1}{2} \int (\hat{\mathbf{x}}^T Q \hat{\mathbf{x}} + \mathbf{u}^T R \mathbf{u}) dt\right] + J_e,$$

其中 $J_e = E[\frac{1}{2}\tilde{\mathbf{x}}(T)^T S_T \tilde{\mathbf{x}}(T) + \frac{1}{2} \int \tilde{\mathbf{x}}^T Q \tilde{\mathbf{x}} dt]$ 与控制 u 无关 (若 u 仅为 $\hat{\mathbf{x}}$ 的函数)。

因此关于 u 的最优化等价于对以 $\hat{\mathbf{x}}$ 为状态的确定性 LQR 问题求解, 得到

$$\mathbf{u}^*(t) = -K(t) \hat{\mathbf{x}}(t),$$

其中 $K(t)$ 由 Riccati 方程给出。这便是**分离原理的数学要点**: 估计与控制可分开设计, 且最优控制可直接作用于最优估计。

分离原理的实现：滤波器与最优代价

Kalman 滤波器：

$$\dot{\hat{\mathbf{x}}} = A\hat{\mathbf{x}} + B\mathbf{u} + L(\mathbf{z} - H\hat{\mathbf{x}}), \quad \hat{\mathbf{x}}(0) = \bar{\mathbf{x}}_0 \quad (77)$$


$$L = PH^T R'^{-1} \quad (78)$$

$$\dot{P} = AP + PA^T + GQ'G^T - PH^T R'^{-1}HP \quad (79)$$

最优平均代价：

$$j^*(t_0) = \frac{1}{2} \text{tr}[S(t_0)X(t_0)] + \frac{1}{2} \text{tr} \int_{t_0}^{t_f} SGQ'G^T dt + \frac{1}{2} \text{tr} \int_{t_0}^{t_f} K^T R K P dt \quad (80)$$

分离原理的实现：示意图



LQG 调节器结构

- 闭环系统构成:

- 被控对象: $\dot{x} = Ax + Bu + Gw$
- 卡尔曼滤波器 (状态观测器)
- 状态反馈控制律 $u = -K\hat{x}$

- 主方程:

$$\dot{\hat{x}} = (A - LH)\hat{x} + Bu + Lz$$

$$u = -K\hat{x}$$

- 分离原理的关键: 估计误差 $\tilde{x} = x - \hat{x}$ 独立于控制

实例：导弹滚动姿态调节器

状态变量： $\mathbf{x} = [\delta, \omega, \phi]^T$

$$\dot{\delta} = u, \quad \dot{\omega} = -\frac{1}{\tau}\omega + \frac{q}{\tau}\delta + n, \quad \dot{\phi} = \omega$$





性能指标：

$$J = \lim_{t_f \rightarrow \infty} \frac{1}{2} \int \left(\frac{\phi^2}{\phi_0^2} + \frac{\delta^2}{\delta_0^2} + \frac{u^2}{u_0^2} \right) dt$$


求解结果 ($\phi_0 = \pi/180$, $\delta_0 = \pi/12$, $u_0 = \pi$):

$$K^T = [27, 29, 180], \quad \sqrt{E(\delta^2)} = 2.50^\circ, \quad \sqrt{E(\phi^2)} = 0.24^\circ$$


仿真结果：时域响应



仿真结果：稳态分布



仿真结果：典型样本时域响应



实例：飞机横向自动驾驶仪

五阶横向扰动运动方程：

- 状态： β (侧滑角), r (偏航角速率), p (滚转角速率), ϕ (滚转角), ψ (偏航角)
- 控制： δ_r (方向舵), δ_a (副翼)

稳态最优反馈：


$$\delta_r = -0.317\beta - 1.01r - 0.069p - 0.076\phi - 0.551\psi$$

$$\delta_a = 0.177\beta + 0.388r + 0.737p + 1.03\phi + 0.834\psi$$





性能评估：

$$\sqrt{E(\beta + \psi)^2} = 0.60^\circ, \quad \sqrt{E(\phi^2)} = 2.87^\circ, \quad \sqrt{E(\delta_r^2)} = 2.48^\circ, \quad \sqrt{E(\delta_a^2)} = 3.30^\circ$$


仿真结果：状态时域响应




仿真结果：关键输出变量



仿真结果：稳态分布



仿真结果：典型样本时域响应



离散时间 LQG 问题

离散 LQG 完全状态信息

系统与指标:

$$\mathbf{x}_{k+1} = F\mathbf{x}_k + B\mathbf{u}_k + G\mathbf{w}_k, \quad \mathbf{w}_k \sim \mathcal{N}(0, Q') \quad (81)$$


$$J_i = \frac{1}{2}\mathbf{x}_N^T S_N \mathbf{x}_N + \frac{1}{2} \sum_{k=i}^{N-1} (\mathbf{x}_k^T Q \mathbf{x}_k + \mathbf{u}_k^T R \mathbf{u}_k) \quad (82)$$

最优控制:

$$\mathbf{u}_k^* = -K_k \mathbf{x}_k, \quad K_k = (B^T S_{k+1} B + R)^{-1} B^T S_{k+1} F \quad (83)$$

离散 LQG: Riccati 方程

$$S_k = F^T [S_{k+1} - S_{k+1} B (B^T S_{k+1} B + R)^{-1} B^T S_{k+1}] F + Q \quad (84)$$



离散 LQG 非完全状态信息

量测: $\mathbf{z}_k = H\mathbf{x}_k + \mathbf{v}_k$, $\mathbf{v}_k \sim \mathcal{N}(0, R')$

分离原理同样成立:


$$\mathbf{u}_k = -K_k \hat{\mathbf{x}}_k \tag{85}$$

$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_{k|k-1} + L_k(\mathbf{z}_k - H\hat{\mathbf{x}}_{k|k-1}) \tag{86}$$

$$\hat{\mathbf{x}}_{k+1|k} = F\hat{\mathbf{x}}_k + B\mathbf{u}_k \tag{87}$$

离散 LQG: 最优平均代价

$$J_i^* = \frac{1}{2} \text{tr} \left[S_i X_i + \sum_{k=i}^{N-1} (S_{k+1} G Q' G^T + S_{k+1} B K_k P_k F^T) \right] \quad (88)$$



非线性随机系统次优控制

摄动法

DP 理论上可解非线性随机最优控制，但存在“维数灾难”。

摄动法步骤：

1. 忽略不确定性，设计确定性最优标称轨线 $\bar{x}(t)$ 、 $\bar{u}(t)$
2. 在标称轨线附近线性化，设计 LQR 摄动控制 $\delta u^* = K_\delta \delta x$
3. 设计摄动系统最优滤波器，获得 $\delta \hat{x}$
4. 实际控制： $u(t) = \bar{u}(t) + K_\delta(t) \delta \hat{x}(t)$

优点：简单实用，工程中广泛应用

摄动法算例

非线性系统:

$$\dot{x} = -x + ax^3 + u + w, \quad y = x + v$$

设计控制使 $y(t)$ 跟踪设定值 y_d 。

解: 平衡状态 $\bar{x} = y_d$, 标称控制 $\bar{u} = y_d - ay_d^3$ 。

线性化摄动系统:

$$\delta\dot{x} = (-1 + 3ay_d^2)\delta x + \delta u + w$$

对摄动系统应用 LQG 理论得 δu^* , 实际控制 $u = \bar{u} + \delta u^*$ 。

强迫分离法

直接应用 LQG 分离原理的思想（最优性无理论保证，但工程可行）：

1. 忽略不确定性，设计确定性最优控制 $\hat{u}(t) = \hat{u}[x(t)]$
2. 设计非线性滤波器（EKF/UKF/CKF），获得状态估计 $\hat{x}(t)$
3. 实际控制： $\hat{u}(t) = \hat{u}[\hat{x}(t)]$

注：与人工智能、机器学习结合是值得关注的方向发展。

本章小结

小结

核心理论与方法


- **最优性原理**——动态规划的理论基石
- **LQG 理论**——线性二次型最优解
- **分离原理**——估计与控制可独立设计
- **黎卡提方程**——LQR/LQG 核心工具

工程应用

- 飞行器最优追逃策略
- 导弹滚动姿态调节器
- 飞机横向自动驾驶仪

非线性扩展

- 数值解 / 摄动法 / 强迫分离法



当前发展趋势

- 基于**强化学习**的非线性随机最优控制
- **模型预测控制** (MPC) 与随机优化的深度融合
- **数据驱动**控制——利用在线数据更新模型
- **鲁棒 LQG** 与**风险敏感**控制
- **多智能体**随机博弈——集群分布式控制
- 与**深度学习**结合求解高维 HJB 方程

关键挑战

- 高维状态/控制空间的维数灾难
- 模型未知时的探索-利用权衡
- 安全关键系统的实时性与鲁棒性



♡ Wishing Everyone ♡

Success in Your Work and Studies,
and Achieving Excellent Results!

