



# 『经典参数估计与融合估计算法』

Dr. Yuan-Li Cai

Spring 2024

# 0. Outline

- 1 最小二乘估计 / 3
- 2 极大似然估计 / 6
- 3 极大验后估计 / 8
- 4 最小方差估计 / 12
- 5 融合估计 / 17

考虑量测方程

$$\boxed{z = Hx + v} \quad (1)$$

其中,  $z \in \mathbb{R}^N$ ,  $x \in \mathbb{R}^n$ ,  $H \in \mathbb{R}^{N \times n}$ ,  $v \in \mathbb{R}^N \sim N(0, R)$ . 此外,  $R \in \mathbb{R}^{N \times N}$ .  
我们的问题是基于量测  $z$ , 对未知量  $x$  进行估计.

# 1. 最小二乘估计

取权重矩阵为  $W = R^{-1}$ , (加权) 最小二乘估计意味着

$$\begin{aligned} J &= \frac{1}{2} \|z - Hx\|_{R^{-1}}^2 \\ &= \frac{1}{2} (z - Hx)^T R^{-1} (z - Hx) \Rightarrow \min \end{aligned} \quad (2)$$

由此可得

$$\hat{x}_{LMS} = (H^T R^{-1} H)^{-1} H^T R^{-1} z$$

估计误差为

$$\begin{aligned}\tilde{\mathbf{x}}_{LMS} &= \hat{\mathbf{x}}_{LMS} - \mathbf{x} \\ &= (\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H})^{-1} \mathbf{H}^T \mathbf{R}^{-1} (\mathbf{H} \mathbf{x} + \mathbf{v}) - \mathbf{x} \\ &= (\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H})^{-1} \mathbf{H}^T \mathbf{R}^{-1} \mathbf{v}\end{aligned}$$

根据量测噪声  $\mathbf{v}$  的性质, 易知

$$\begin{aligned}E \tilde{\mathbf{x}}_{LMS} &= \mathbf{0} \\ \mathbf{P}_{\tilde{\mathbf{x}}_{LMS}} &= E \tilde{\mathbf{x}}_{LMS} \tilde{\mathbf{x}}_{LMS}^T = (\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H})^{-1}\end{aligned}$$

对于确定性未知量  $x$ , 有

$$E\hat{x}_{LMS} = x$$

$$\begin{aligned} P_{\hat{x}_{LMS}} &= E(\hat{x}_{LMS} - x)(\hat{x}_{LMS} - x)^T \\ &= (H^T R^{-1} H)^{-1} = P_{\tilde{x}_{LMS}} \end{aligned}$$

所以, 最小二乘估计可以表示为

$$\begin{cases} \hat{x}_{LMS} = (H^T R^{-1} H)^{-1} H^T R^{-1} z \\ P_{\tilde{x}_{LMS}} = (H^T R^{-1} H)^{-1} \end{cases} \quad (3)$$

## 2. 极大似然估计

极大似然估计是指

$$f_{z|x}(z|x) \Rightarrow \max \quad (4)$$

或

$$\ln f_{z|x}(z|x) \Rightarrow \max \quad (5)$$

对于系统 (1), 注意到给定  $x$  时  $z \sim N(Hx, R)$ , 上述极值问题变为

$$J = \frac{1}{2}(z - Hx)^T R^{-1}(z - Hx) \Rightarrow \min \quad (6)$$

由此可得

$$\begin{cases} \hat{x}_{ML} = (H^T R^{-1} H)^{-1} H^T R^{-1} z \\ P_{\tilde{x}_{ML}} = (H^T R^{-1} H)^{-1} \end{cases} \quad (7)$$

不难发现，和最小二乘估计是一致的。



# 3. 极大验后估计

极大验后估计是指

$$\ln f_{x|z}(\mathbf{x}|z) \Rightarrow \max \quad (8)$$

根据贝叶斯公式, 有

$$f_{x|z}(\mathbf{x}|z) = \frac{f_{z|x}(z|\mathbf{x})f_x(\mathbf{x})}{f_z(z)}$$

如果  $\mathbf{x} \sim N(\bar{\mathbf{x}}, \mathbf{P}_x)$ , 而且与  $v$  无关, 极大似然估计意指

$$J = \frac{1}{2}(z - \mathbf{H}\mathbf{x})^T \mathbf{R}^{-1}(z - \mathbf{H}\mathbf{x}) + \frac{1}{2}(\mathbf{x} - \bar{\mathbf{x}})^T \mathbf{P}_x^{-1}(\mathbf{x} - \bar{\mathbf{x}}) \Rightarrow \min \quad (9)$$

由  $\frac{\partial J}{\partial \mathbf{x}}|_{\hat{\mathbf{x}}} = \mathbf{0}$ , 可得

$$-\mathbf{H}^T \mathbf{R}^{-1}(\mathbf{z} - \mathbf{H}\hat{\mathbf{x}}) + \mathbf{P}_x^{-1}(\hat{\mathbf{x}} - \bar{\mathbf{x}}) = \mathbf{0}$$

$$\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H} \hat{\mathbf{x}} + \mathbf{P}_x^{-1} \hat{\mathbf{x}} = \mathbf{P}_x^{-1} \bar{\mathbf{x}} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{z}$$

即

$$\hat{\mathbf{x}}_{MA} = (\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H} + \mathbf{P}_x^{-1})^{-1} (\mathbf{P}_x^{-1} \bar{\mathbf{x}} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{z}) \quad (10)$$

同时可以容易验证估计的无偏性,  $E\hat{\mathbf{x}}_{MA} = \bar{\mathbf{x}}$ . 此外

$$\begin{aligned}\tilde{\mathbf{x}}_{MA} &= \hat{\mathbf{x}}_{MA} - \mathbf{x} \\ &= (\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H} + \mathbf{P}_x^{-1})^{-1} \\ &\quad \times [\mathbf{P}_x^{-1} \bar{\mathbf{x}} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{z} - (\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H} + \mathbf{P}_x^{-1}) \mathbf{x}] \\ &= (\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H} + \mathbf{P}_x^{-1})^{-1} [\mathbf{H}^T \mathbf{R}^{-1} \mathbf{v} - \mathbf{P}_x^{-1} \hat{\mathbf{x}}]\end{aligned}$$

由此, 可得

$$\begin{aligned}\mathbf{P}_{\tilde{\mathbf{x}}_{MA}} &= E\tilde{\mathbf{x}}_{MA}\tilde{\mathbf{x}}_{MA}^T \\ &= (\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H} + \mathbf{P}_x^{-1})^{-1} [\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H} + \mathbf{P}_x^{-1}] (\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H} + \mathbf{P}_x^{-1})^{-1} \\ &= (\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H} + \mathbf{P}_x^{-1})^{-1}\end{aligned}$$

总结起来，极大验后估计即为

$$\begin{cases} \hat{x}_{MA} = P_{\tilde{x}_{MA}}(P_x^{-1}\bar{x} + H^T R^{-1}z) \\ P_{\tilde{x}_{MA}} = (H^T R^{-1}H + P_x^{-1})^{-1} \end{cases} \quad (11)$$

当无先验信息时， $P_x^{-1} = 0$ 。可见，此时极大验后估计与最小二乘估计、极大似然估计都是一致的。

# 4. 最小方差估计

对于系统 (1), 最小方差估计即为线性最小方差估计。假设  $x \sim N(\bar{x}, P_x)$ , 且与  $v \sim N(0, R)$  无关。因为  $\hat{x}_{MV} = \bar{x} + P_{xz}P_z^{-1}(z - \bar{z})$ , 注

意到

$$\bar{z} = H\bar{x}$$

$$P_z = E\dot{z}\dot{z}^T = E(H\dot{x} + v)(H\dot{x} + v)^T$$

$$= HP_x H^T + R$$

$$P_{xz} = E\dot{x}\dot{z}^T = E\dot{x}(H\dot{x} + v)^T$$

$$= P_x H^T$$

所以

$$\hat{x}_{MV} = \bar{x} + P_x H^T (H P_x H^T + R)^{-1} (z - H\bar{x}) \quad (12)$$

$$\begin{aligned} P_{\tilde{x}_{MV}} &= P_x - P_{xz}P_z^{-1}P_{zx} \\ &= P_x - P_x H^T (H P_x H^T + R)^{-1} H P_x \end{aligned} \quad (13)$$

由矩阵求逆引理 (Matrix Inversion Lemma)

$$(A + BCD)^{-1} = A^{-1} - A^{-1}B(DA^{-1}B + C^{-1})^{-1}DA^{-1} \quad (14)$$

对照取  $A = P_x^{-1}$ ,  $B = H^T$ ,  $D = H$ ,  $C = R^{-1}$ , 式 (13) 可化为

$$P_{\tilde{x}_{MV}} = (P_x^{-1} + H^T R^{-1} H)^{-1} \quad (15)$$

另外, 式 (12) 可以化为

$$\hat{x}_{MV} = [I - P_x H^T (H P_x H^T + R)^{-1} H] \bar{x} + P_x H^T (H P_x H^T + R)^{-1} z$$

注意到

$$\begin{aligned}
 & [I - P_x H^T (H P_x H^T + R)^{-1} H] \\
 &= [P_x - P_x H^T (H P_x H^T + R)^{-1} H P_x] P_x^{-1} \\
 &= P_{\tilde{x}_{MV}} P_x^{-1} \\
 &= (P_x^{-1} + H^T R^{-1} H)^{-1} P_x^{-1}
 \end{aligned}$$

$$\begin{aligned}
 & P_x H^T (H P_x H^T + R)^{-1} \\
 &= (**)^{-1} \underbrace{(P_x^{-1} + H^T R^{-1} H)}_{**} \underbrace{(P_x H^T)}_{\text{blue circle}} (H P_x H^T + R)^{-1} \\
 &= (P_x^{-1} + H^T R^{-1} H)^{-1} H^T R^{-1}
 \end{aligned}$$



因此, 有

$$\hat{x}_{MV} = (P_x^{-1} + H^T R^{-1} H)^{-1} (P_x^{-1} \bar{x} + H^T R^{-1} z) = \hat{x}_{MA} \quad (16)$$

上述讨论表明, 对于系统 (1), 最小方差估计与极大验后估计是一致的.

# 5. 融合估计

对于未知的  $x$ , 设独立地获得了两个估计:  $(\hat{x}_1, P_1)$  和  $(\hat{x}_2, P_2)$ . 可以认为

$$\begin{aligned}\hat{x}_1 &= x + v_1, & v_1 &\sim N(0, P_1) \\ \hat{x}_2 &= x + v_2, & v_2 &\sim N(0, P_2)\end{aligned}$$

即

$$\begin{bmatrix} \hat{x}_1 \\ \hat{x}_2 \end{bmatrix} = \begin{bmatrix} I_n \\ I_n \end{bmatrix} x + \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

记

$$\mathcal{H} = \begin{bmatrix} \mathbf{I}_n \\ \mathbf{I}_n \end{bmatrix}, \mathcal{V} = \begin{bmatrix} \mathbf{v}_1 \\ \mathbf{v}_2 \end{bmatrix}$$

那么

$$E\mathcal{V} = \begin{bmatrix} \mathbf{0} \\ \mathbf{0} \end{bmatrix}, E\mathcal{V}\mathcal{V}^T \triangleq \mathcal{R} = \begin{bmatrix} \mathbf{P}_1 & \mathbf{0} \\ \mathbf{0} & \mathbf{P}_2 \end{bmatrix},$$

注意到

$$\mathcal{H}^T \mathcal{R}^{-1} = [\mathbf{I}_n, \mathbf{I}_n] \begin{bmatrix} \mathbf{P}_1^{-1} & \mathbf{0} \\ \mathbf{0} & \mathbf{P}_2^{-1} \end{bmatrix} = [\mathbf{P}_1^{-1}, \mathbf{P}_2^{-1}]$$

$$\mathcal{H}^T \mathcal{R}^{-1} \begin{bmatrix} \hat{\mathbf{x}}_1 \\ \hat{\mathbf{x}}_2 \end{bmatrix} = \mathbf{P}_1^{-1} \hat{\mathbf{x}}_1 + \mathbf{P}_2^{-1} \hat{\mathbf{x}}_2$$

$$(\mathcal{H}^T \mathcal{R}^{-1} \mathcal{H})^{-1} = (\mathbf{P}_1^{-1} + \mathbf{P}_2^{-1})^{-1}$$

由最小二乘估计可知

$$\hat{\mathbf{x}} = (\mathbf{P}_1^{-1} + \mathbf{P}_2^{-1})^{-1} (\mathbf{P}_1^{-1} \hat{\mathbf{x}}_1 + \mathbf{P}_2^{-1} \hat{\mathbf{x}}_2)$$

$$\mathbf{P} = E(\hat{\mathbf{x}}_1 - \mathbf{x})(\hat{\mathbf{x}}_1 - \mathbf{x})^T = (\mathbf{P}_1^{-1} + \mathbf{P}_2^{-1})^{-1}$$

将上述结论可以总结为如下定理.

**Theorem 5.1** 如果对于  $x$  有两个独立的最优估计  $(\hat{x}_1, P_1)$  和  $(\hat{x}_2, P_2)$ , 那么融合后的最优估计为

$$\begin{cases} P^{-1} = P_1^{-1} + P_2^{-1} \\ \hat{x} = P(P_1^{-1}\hat{x}_1 + P_2^{-1}\hat{x}_2) \end{cases} \quad (17)$$

**Example 5.1** 已知  $(\hat{x}_1 = 1, P_1 = 0.1)$ ,  $(\hat{x}_2 = 2, P_2 = 0.5)$ , 求融合估计  $\hat{x}$ .

【解】因为  $P^{-1} = P_1^{-1} + P_2^{-1} = 10 + 2 = 12$ , 所以

$$\begin{aligned}\hat{x} &= P(P_1^{-1}(\hat{x}_1) + P_2^{-1}(\hat{x}_2)) = \frac{1}{12}(10\hat{x}_1 + 2\hat{x}_2) \\ &= \frac{10}{12} + \frac{4}{12} = \frac{14}{12} \approx 1.167 \\ P &= \frac{1}{12} \approx 0.083\end{aligned}$$

□

进一步, 我们可以建立如下更一般的结论。

**Theorem 5.2** 如果对于  $x$  有  $N$  个相互独立的最优估计  $(\hat{x}_1, P_1), (\hat{x}_2, P_2), \dots, (\hat{x}_N, P_N)$ . 那么, 融合后的最优估计为

$$\begin{cases} P^{-1} = \sum_{i=1}^N P_i^{-1} \\ \hat{x} = P \sum_{i=1}^N P_i^{-1} \hat{x}_i \end{cases} \quad (18)$$

算法 (18) 是集中式融合算法. 可以容易地建立如下序贯式融合算法:

$$\begin{cases} P_{(k+1)}^{-1} = P_{(k)}^{-1} + P_{k+1}^{-1} \\ \hat{x}_{(k+1)} = P_{(k+1)} [P_{(k)}^{-1} \hat{x}_{(k)} + P_{k+1}^{-1} \hat{x}_{k+1}] \end{cases} \quad (19)$$

其中,  $(\hat{\mathbf{x}}_{(k)}, \mathbf{P}_{(k)}^{-1})$  表示前  $k$  个传感器的融合估计结果,  $(\hat{\mathbf{x}}_{k+1}, \mathbf{P}_{k+1}^{-1})$  表示第  $k+1$  个传感器的最优估计,  $(\hat{\mathbf{x}}_{(k+1)}, \mathbf{P}_{(k+1)}^{-1})$  表示  $k+1$  个传感器的融合估计结果.

## 5.1 融合估计的最优性

对于估计问题

$$\begin{cases} z = \mathbf{H}\mathbf{x} + \mathbf{v}, & \mathbf{v} \sim N(0, \mathbf{R}) \\ \mathbf{x} \sim N(\bar{\mathbf{x}}, \mathbf{P}_x) \end{cases}$$



相当于

$$\begin{cases} z = Hx + v, & v \sim N(0, R) \\ \bar{x} = x + \epsilon, & \epsilon \sim N(0, P_x) \end{cases}$$

可见，融合估计对应的优化问题为

$$J = \frac{1}{2}(z - Hx)^T R^{-1}(z - Hx) + \frac{1}{2}(x - \bar{x})^T P_x^{-1}(x - \bar{x}) \Rightarrow \min \quad (20)$$

这与极大验后估计是一致的。

## 5.2 融合估计的等价解算方法

对于未知的  $x$ , 基于两个独立估计  $(\hat{x}_1, P_1)$  和  $(\hat{x}_2, P_2)$  的综合估计假设为

$$\hat{x} = K_1 \hat{x}_1 + K_2 \hat{x}_2 \quad (21)$$

式中,  $K_1, K_2$  是两个待定系数矩阵. 根据估计的无偏性要求, 可知

$$K_1 + K_2 = I \quad (22)$$

记  $K_1 = K$ , 那么  $K_2 = I - K$ . 因此

$$\hat{x} = K\hat{x}_1 + (I - K)\hat{x}_2$$

$$\tilde{x} = \hat{x} - x = K\tilde{x}_1 + (I - K)\tilde{x}_2$$

由此可得估计误差指标函数

$$\begin{aligned} J &= E\|\tilde{x}\|^2 = tr(E\tilde{x}\tilde{x}^T) \\ &= tr[KP_1K^T + (I - K)P(I - K)^T] \end{aligned}$$

注意到  $\frac{\partial}{\partial A} \text{tr}(ABA^T) = AB^T + AB$ . 当  $B^T = B$  时,  $\frac{\partial}{\partial A} \text{tr}(ABA^T) = 2AB$ . 由  $\frac{\partial J}{\partial K} = 0$ , 可导出

$$KP_1 - (I - K)P_2 = 0$$

$$K(P_1 + P_2) = P_2$$

因此

$$K = P_2(P_1 + P_2)^{-1} = (P_1^{-1} + P_2^{-1})^{-1}P_1^{-1}$$

$$I - K = I - (P_1^{-1} + P_2^{-1})^{-1}P_1^{-1} = (P_1^{-1} + P_2^{-1})^{-1}P_2^{-1}$$

因此

$$\hat{x} = (P_1^{-1} + P_2^{-1})^{-1}(P_1^{-1}\hat{x}_1 + P_2^{-1}\hat{x}_2)$$

$$P = P_{\tilde{x}} = (P_1^{-1} + P_2^{-1})^{-1}(P_1^{-1} + P_2^{-1})(P_1^{-1} + P_2^{-1})^{-1}$$

即

$$\begin{cases} \hat{x} = P(P_1^{-1}\hat{x}_1 + P_2^{-1}\hat{x}_2) \\ P^{-1} = P_1^{-1} + P_2^{-1} \end{cases} \quad (23)$$

### 5.3 融合估计与最小方差估计

对于参数估计问题

$$z = Hx + v, \quad v \sim N(0, R)$$

我们首先可以容易地获得最小二乘估计（或极大似然估计）

$$\begin{cases} \hat{x}_1 = (H^T R^{-1} H)^{-1} H^T R^{-1} z \\ P_1 = (H^T R^{-1} H)^{-1} \end{cases} \quad (24)$$

如果我们有关于  $x$  的先验知识，即  $x \sim N(\bar{x}, P_x)$ ，可以认为是获得了如下估计：

$$\begin{cases} \hat{x}_2 = \bar{x} \\ P_2 = P_x \end{cases} \quad (25)$$

根据融合估计定理5.1，将估计 (24) 和 (25) 融合可得

$$\begin{cases} P^{-1} = P_x^{-1} + (H^T R^{-1} H)^{-1} \\ \hat{x} = P(P_x^{-1} \bar{x} + H^T R^{-1} z) \end{cases} \quad (26)$$

注意到最小方差估计 (15)、(16), 即

$$\begin{cases} P_{\tilde{x}_{MV}} = (P_x^{-1} + H^T R^{-1} H)^{-1} \\ \hat{x}_{MV} = (P_x^{-1} + H^T R^{-1} H)^{-1} (P_x^{-1} \bar{x} + H^T R^{-1} z) \end{cases} \quad (27)$$

比较 (26) 和 (27), 不难发现两者是一致的, 这进一步说明了上面介绍的融合估计算法的最优性.

## 5.4 递推最小二乘估计

由  $k+1$  时刻的量测

$$z_{k+1} = H_{k+1}x + v_{k+1} \quad (28)$$

可以获得附加的估计

$$\begin{cases} \hat{x}_a = (H_{k+1}^T w_{k+1} H_{k+1})^{-1} H_{k+1}^T w_{k+1} z_{k+1} \\ P_a = (H_{k+1}^T w_{k+1} H_{k+1})^{-1} \end{cases} \quad (29)$$



与已经获得被估计量  $x$  在  $k$  时刻的估计  $(\hat{x}_k, P_k)$  进行融合, 得

$$\begin{cases} \hat{x}_{k+1} = P_{k+1}(P_k^{-1}\hat{x}_k + P_a^{-1}\hat{x}_a) \\ P_{k+1} = (P_k^{-1} + P_a^{-1})^{-1} \end{cases} \quad (30)$$

因而有

$$P_{k+1} = (P_k^{-1} + H_{k+1}^T w_{k+1} H_{k+1})^{-1} \quad (31)$$

同时

$$\begin{aligned} \hat{x}_{k+1} &= P_{k+1}[(P_k^{-1} + P_a^{-1})\hat{x}_k + P_a^{-1}\hat{x}_a - P_a^{-1}\hat{x}_k] \\ &= \hat{x}_k + P_{k+1}H_{k+1}^T w_{k+1} z_{k+1} - P_{k+1}H_{k+1}^T w_{k+1} H_{k+1}\hat{x}_k \end{aligned}$$

即

$$\hat{\mathbf{x}}_{k+1} = \hat{\mathbf{x}}_k + \mathbf{P}_{k+1} \mathbf{H}_{k+1}^T \mathbf{w}_{k+1} (\mathbf{z}_{k+1} - \mathbf{H}_{k+1} \hat{\mathbf{x}}_k) \quad (32)$$

式 (31) 和 (32) 便构成了递推最小二乘估计, 即

$$\begin{cases} \hat{\mathbf{x}}_{k+1} = \hat{\mathbf{x}}_k + \mathbf{P}_{k+1} \mathbf{H}_{k+1}^T \mathbf{w}_{k+1} (\mathbf{z}_{k+1} - \mathbf{H}_{k+1} \hat{\mathbf{x}}_k) \\ \mathbf{P}_{k+1} = (\mathbf{P}_k^{-1} + \mathbf{H}_{k+1}^T \mathbf{w}_{k+1} \mathbf{H}_{k+1})^{-1} \end{cases} \quad (33)$$

以上讨论表明基于融合估计的思想, 建立递推最小二乘估计比传统方法要简明、容易得多.

□